APRENDIZAJE AUTOMÁTICO · DOCTORADO EN INGENIERÍA · UNIVERSIDAD DE TALCA

Diagnóstico de entrada

Este cuestionario no se califica y no incide en su nota. Se aplica al cierre de la sesión 1 con dos propósitos: que el profesor calibre el ritmo de las semanas 2 a 5, y que usted identifique con precisión qué necesita nivelar antes de que el módulo lo dé por supuesto.

Veinte preguntas, cuatro áreas, veinte minutos. Cada pregunta tiene una sola alternativa correcta. Si no sabe una respuesta, marque la casilla «No lo sé» en lugar de adivinar: para el propósito de este instrumento, esa respuesta es más informativa que un acierto al azar.

Nombre: _____

Campus: _____

Tema de tesis (en una línea): _____

¿Dispone de un conjunto de datos propio para el proyecto? Sí ☐ No ☐ Aún no lo sé ☐

Área A · Python y ecosistema científico

A1. En NumPy, se suman dos arreglos de forma (3, 1) y (1, 4). ¿Cuál es la forma del resultado?

- ☐ a) (3, 1)
- ☐ b) (1, 4)
- ☐ c) (3, 4)
- ☐ d) La operación produce un error porque las formas no coinciden
- ☐ *No lo sé*

A2. En pandas, ¿qué devuelve df.groupby('grupo')['x'].transform('mean')?

- ☐ a) Una serie con una fila por grupo
- ☐ b) Una serie con el mismo número de filas que df, con la media del grupo repetida en cada fila
- ☐ c) Un DataFrame con los grupos como índice
- ☐ d) Lo mismo que agg('mean'), solo que con otro nombre
- ☐ *No lo sé*

A3. Se quiere aplicar una operación elemento a elemento sobre un arreglo de un millón de valores. ¿Qué implementación es preferible?

- ☐ a) Un bucle for sobre una lista de Python
- ☐ b) Una list comprehension
- ☐ c) Una operación vectorizada de NumPy sobre el arreglo
- ☐ d) Es indiferente: las tres tienen el mismo costo
- ☐ *No lo sé*

A4. ¿Qué garantiza que dos ejecuciones de train_test_split de scikit-learn produzcan exactamente la misma partición?

- ☐ a) Usar la misma versión de scikit-learn
- ☐ b) Fijar el parámetro random_state a un valor entero
- ☐ c) Ordenar el DataFrame antes de particionar
- ☐ d) Nada lo garantiza: la partición siempre es aleatoria
- ☐ *No lo sé*

A5. Un revisor quiere reproducir sus resultados en su propio computador. ¿Qué es lo más determinante para que lo consiga?

- ☐ a) Que el código esté comentado
- ☐ b) Que el cuaderno esté ordenado en secciones

☐ c) Declarar el entorno con versiones fijadas de las bibliotecas, además de las semillas

☐ d) Que el repositorio tenga un README

☐ *No lo sé*

Área B · Álgebra lineal

B1. Sea X una matriz de n × p, con n > p y rango p. ¿Qué se puede afirmar de X^TX?

☐ a) Es de n × n y singular

☐ b) Es de p × p, simétrica e invertible

☐ c) Es de p × p pero no necesariamente simétrica

☐ d) No está definida porque las dimensiones no lo permiten

☐ *No lo sé*

B2. Los valores propios de una matriz de covarianza son siempre…

☐ a) reales y no negativos

☐ b) reales y estrictamente positivos

☐ c) reales, pudiendo ser negativos

☐ d) en general complejos

☐ *No lo sé*

B3. La solución de mínimos cuadrados ordinarios del modelo $y = X\beta + \varepsilon$ es:

☐ a) $\beta = X^Ty$

☐ b) $\beta = (XX^T)^{-1}Xy$

☐ c) $\beta = (X^TX)^{-1}X^Ty$

☐ d) $\beta = X^{-1}y$, siempre que X sea cuadrada

☐ *No lo sé*

B4. Dos columnas de X son combinación lineal exacta una de otra. ¿Qué ocurre?

☐ a) X^TX se vuelve singular y la solución de mínimos cuadrados no es única

☐ b) El error de entrenamiento aumenta

☐ c) No ocurre nada relevante: el algoritmo elige una de las dos

☐ d) El rango de X aumenta en uno

☐ *No lo sé*

B5. El análisis de componentes principales proyecta los datos sobre…

☐ a) las columnas de X con mayor varianza

☐ b) los vectores propios de la matriz de covarianza asociados a los mayores valores propios

☐ c) los vectores propios asociados a los menores valores propios

☐ d) una base ortonormal elegida al azar

☐ *No lo sé*

Área C · Probabilidad y estadística inferencial

C1. Dos sucesos A y B son independientes si y solo si:

☐ a) $P(A \cup B) = P(A) + P(B)$

☐ b) $P(A \cap B) = P(A) \cdot P(B)$

☐ c) $P(A \mid B) = P(B \mid A)$

☐ d) A y B no pueden ocurrir simultáneamente

☐ *No lo sé*

C2. Si X tiene varianza σ^2, ¿cuál es la varianza de $aX + b$?

- ☐ a) $a\sigma^2 + b$
- ☐ b) $a^2\sigma^2$
- ☐ c) $a^2\sigma^2 + b^2$
- ☐ d) $a\sigma^2$
- ☐ *No lo sé*

C3. El valor p de una prueba de hipótesis es:

- ☐ a) la probabilidad de que la hipótesis nula sea verdadera
- ☐ b) la probabilidad de observar un estadístico al menos tan extremo como el observado, suponiendo que la hipótesis nula es verdadera
- ☐ c) la probabilidad de equivocarse al rechazar la hipótesis alternativa
- ☐ d) el tamaño del efecto observado
- ☐ *No lo sé*

C4. Un intervalo de confianza del 95 % significa que:

- ☐ a) hay un 95 % de probabilidad de que el parámetro esté en este intervalo
- ☐ b) el 95 % de los datos cae dentro del intervalo
- ☐ c) si se repitiera el muestreo muchas veces, el 95 % de los intervalos así construidos contendría el parámetro
- ☐ d) el error de estimación es menor al 5 %
- ☐ *No lo sé*

C5. Una prueba tiene 99 % de sensibilidad y 99 % de especificidad. La prevalencia de la condición es 1 %. Un individuo da positivo. ¿Cuál es aproximadamente la probabilidad de que efectivamente tenga la condición?

- ☐ a) 99 %
- ☐ b) cerca de 90 %
- ☐ c) cerca de 50 %
- ☐ d) cerca de 1 %
- ☐ *No lo sé*

Área D · Nociones previas de aprendizaje automático

D1. Un modelo alcanza 100 % de acierto en entrenamiento y 60 % en un conjunto de prueba independiente. La explicación más plausible es:

- ☐ a) subajuste: el modelo es demasiado simple
- ☐ b) sobreajuste: el modelo memorizó particularidades de la muestra de entrenamiento
- ☐ c) el conjunto de prueba está mal etiquetado
- ☐ d) la métrica elegida es inadecuada
- ☐ *No lo sé*

D2. Se estandarizan todas las variables usando la media y la desviación del conjunto completo, y recién después se separa entrenamiento y prueba. ¿Qué problema introduce esto?

- ☐ a) Ninguno, es la práctica habitual
- ☐ b) Aumenta el error de entrenamiento
- ☐ c) Fuga de información: el conjunto de prueba influyó en una transformación aplicada al entrenamiento, y la estimación de desempeño queda sesgada
- ☐ d) Solo afecta a los modelos basados en árboles
- ☐ *No lo sé*

D3. En un problema donde el 99 % de los casos pertenece a la clase mayoritaria, un modelo obtiene 99 % de exactitud (accuracy). ¿Qué se concluye?

☐ a) Que el modelo es excelente

☐ b) Que el modelo es al menos tan bueno como el clasificador trivial que predice siempre la clase mayoritaria, y la exactitud no permite distinguirlos

☐ c) Que el conjunto de datos está mal construido

☐ d) Que hay que aumentar la complejidad del modelo

☐ *No lo sé*

D4. ¿Para qué sirve principalmente la validación cruzada de k pliegues?

☐ a) Para aumentar el tamaño del conjunto de entrenamiento

☐ b) Para obtener una estimación del desempeño fuera de muestra con menor varianza que la de un único hold-out, y una medida de su dispersión

☐ c) Para eliminar el sobreajuste

☐ d) Para elegir la métrica adecuada al problema

☐ *No lo sé*

D5. Se prueban treinta configuraciones de hiperparámetros y se reporta el desempeño de la mejor, medido sobre el conjunto de prueba. ¿Qué objeción corresponde?

☐ a) Ninguna: es el procedimiento correcto

☐ b) El conjunto de prueba participó en la selección, de modo que la cifra reportada está sesgada de forma optimista; se requiere una partición adicional o validación anidada

☐ c) Treinta configuraciones son demasiado pocas

☐ d) Habría que reportar el error de entrenamiento en su lugar

☐ *No lo sé*

Gracias. Recibirá su resultado por área junto con material de nivelación específico para las áreas por debajo del umbral.