El aprendizaje como estimación de riesgo

Clase 1 · Riesgo esperado y riesgo empírico

Unidad 1 · Formulación del aprendizaje inductivo

¿Con qué derecho?

> Usted ajusta un modelo con los datos que tiene.

¿Con qué derecho afirma algo sobre los datos que no tiene?

SITUACIÓN

Partamos de un problema, no de una fórmula

Una planta tiene 400 bombas instrumentadas. Con los registros de los últimos tres años queremos predecir, para cada bomba, si fallará dentro de los próximos 30 días.

- **¿Qué es un caso?** ¿Una bomba? ¿Una bomba-mes? ¿Una ventana deslizante? La respuesta cambia el tamaño de la muestra y la independencia entre casos.
- **¿Qué observamos y qué predecimos?** Vibración, temperatura, horas de operación → una etiqueta binaria que aún no existe: hay que construirla.
- **¿De dónde salen los datos y a qué se aplicarán?** Tres años de esta planta; la predicción se usará el próximo año, aquí y quizá en otra. No es la misma población.
- **¿Qué cuesta cada tipo de error?** Una falla no anticipada detiene la línea; una alerta falsa cuesta una inspección. No son comparables.

1

La formalización

Tres objetos y una definición. Todo lo demás del semestre se deriva de aquí.

Tres objetos

$\mathcal{X}, \mathcal{Y}$

Espacio de entrada y de salida. Definirlos ya es una decisión modeladora: qué se mide, con qué resolución, qué se descarta.

$\mathcal{D}$

Distribución conjunta sobre $\mathcal{X} \times \mathcal{Y}$. El mecanismo que genera los pares. Es fija, es desconocida, y **nunca la vamos a observar**.

S

La muestra: n pares (x_i, y_i) extraídos i.i.d. de $\mathcal{D}$. Todo lo que tenemos.

$$S = \{(x_1, y_1), \ldots, (x_n, y_n)\} \overset{\text{i.i.d.}}{\sim} \mathcal{D}^n$$

Una hipótesis y una función de pérdida

Una hipótesis h es una regla que asigna una predicción a cada entrada. Elegir una familia de modelos es elegir el conjunto $\mathcal{H}$ que estamos dispuestos a considerar.

Una función de pérdida L dice cuánto cuesta predecir $h(x)$ cuando la verdad es y. Es donde entra el costo asimétrico del problema real.

$$h : \mathcal{X} \to \mathcal{Y}, \quad h \in \mathcal{H} \qquad L(h(x), y) \geq 0$$

Dos decisiones que casi nadie declara

Elegir $\mathcal{H}$ es introducir un sesgo inductivo

Se decide de antemano qué formas de dependencia son admisibles. Sin ese sesgo no hay generalización posible.

Semana 2: No Free Lunch.

Elegir L es codificar la estructura de costos

Usar 0–1 por defecto equivale a afirmar que todos los errores cuestan lo mismo. En su tesis, casi nunca es cierto.

LA DEFINICIÓN CENTRAL DEL MÓDULO

Riesgo esperado

$$R_{\mathcal{D}}(h) \;=\; \mathbb{E}_{(x,y)\sim\mathcal{D}}\big[L(h(x),y)\big]$$

- La pérdida promedio de h sobre toda la distribución, no sobre nuestra muestra.
- Es una propiedad de h y de $\mathcal{D}$: no depende de la muestra que a usted le tocó.
- Este —y solo este— es el objetivo. Es el número que le interesa a quien vaya a usar su modelo.

> Y aquí está el problema: $\mathcal{D}$ es desconocida. La esperanza no se puede evaluar. Nunca.

Lo único que sí podemos calcular

$$R_S(h) \;=\; \frac{1}{n}\sum_{i=1}^{n} L\big(h(x_i), y_i\big)$$

El **riesgo empírico**: la misma pérdida, promediada sobre los n casos de la muestra S en lugar de sobre $\mathcal{D}$.

$$\mathbb{E}_{S\sim\mathcal{D}^n}\big[R_S(h)\big] \;=\; R_{\mathcal{D}}(h) \qquad \text{para } h \text{ fijada de antemano}$$

Todo depende de la palabra «fijada»

Lo bueno

Para h elegida sin mirar S, el riesgo empírico es insesgado. La garantía es real.

Lo peligroso

En cuanto usamos S para elegir h, la garantía deja de valer. Y eso es exactamente lo que hace el entrenamiento.

$$\hat{h} \;=\; \arg\min_{h \in \mathcal{H}} \; R_S(h) \qquad \text{(minimización del riesgo empírico, ERM)}$$

En el mismo acto de minimizar R_S sobre S, el entrenamiento destruye el insesgamiento que hacía confiable a R_S.

Por qué el error de entrenamiento miente hacia abajo

1. Se evalúan muchas hipótesis sobre la misma muestra. Cada una tiene un error empírico con su propia fluctuación aleatoria.
2. Se conserva la de menor error empírico. Se está seleccionando, entre otras cosas, la fluctuación más favorable.
3. El riesgo empírico de $\hat{h}$ queda sesgado hacia abajo. El sesgo crece con la capacidad de $\mathcal{H}$ y decrece con n.
4. El número que usted reporta no es el que obtendrá en producción.

> Cuanto más flexible es su familia de modelos, menos informativo es su error de entrenamiento. Y las familias flexibles son las que están de moda.

La hipótesis que memoriza

$$h(x) = \begin{cases} y_i & \text{si } (x_i, y_i) \in S \\ 0 & \text{en cualquier otro caso} \end{cases}$$

$R_S(h) = 0$

Error de entrenamiento perfecto. No hay modelo que lo supere.

$R_{\mathcal{D}}(h)$ pésimo

Sobre cualquier punto nuevo predice 0. Su riesgo esperado es el de un modelo trivial.

Y sin embargo, gana

Si el criterio de selección es el error de entrenamiento, es el óptimo de $\mathcal{H}$.

Lo mismo, con números

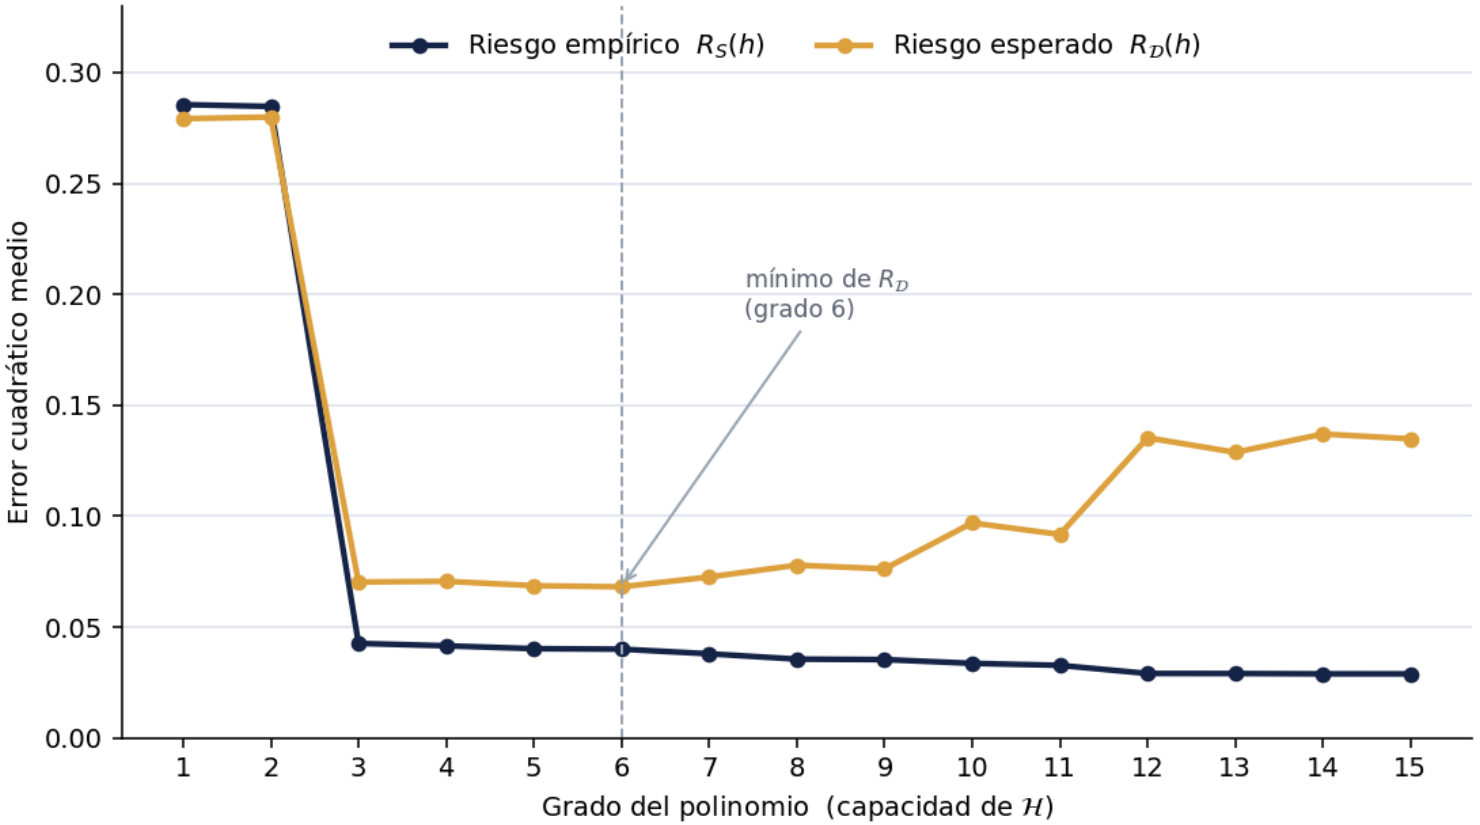


Figura 1: Riesgo empírico y riesgo esperado frente a la capacidad.

$n = 30$ observaciones de $y = \operatorname{sen}(2\pi x) + \varepsilon$, con $\varepsilon \sim N(0,\ 0{,}25^2)$; riesgo esperado estimado sobre 2 000 casos nuevos, semilla 7. La figura la genera `codigo/clase01_riesgo_empirico_vs_esperado.ipynb`, que además verifica estos valores.

2

Las consecuencias

Cuatro corolarios que gobiernan todo lo que haremos en las quince semanas.

COROLARIO 1

De dónde viene el error, en tres partes

$$\underbrace{R(\tilde{h}) - R(h^\star)}_{\text{exceso de riesgo}} = \underbrace{R(h^\star_{\mathcal{H}}) - R(h^\star)}_{\text{aproximación}} + \underbrace{R(\hat{h}) - R(h^\star_{\mathcal{H}})}_{\text{estimación}} + \underbrace{R(\tilde{h}) - R(\hat{h})}_{\text{optimización}}$$

donde $h^\star$ es la mejor función posible, $h^\star_{\mathcal{H}}$ la mejor dentro de $\mathcal{H}$, $\hat{h}$ el minimizador del riesgo empírico y $\tilde{h}$ lo que su algoritmo efectivamente devuelve.

- **Aproximación** — $\mathcal{H}$ no contiene la mejor función. Depende de la familia elegida, no de sus datos: más datos no lo reducen.
- **Estimación** — la muestra es finita y ruidosa. Depende de n y de la capacidad. Es el término que las garantías teóricas acotan.
- **Optimización** — el algoritmo no encuentra el mínimo exacto. Suele ignorarse, y en modelos profundos no es despreciable.

COROLARIO 2

El conjunto de prueba es un recurso que se gasta

> El error de prueba es insesgado únicamente si el conjunto de prueba no participó en ninguna decisión.

Ninguna: ni en la selección del modelo, ni en los hiperparámetros, ni en la imputación, ni en el escalado, ni en la selección de atributos.

COROLARIO 2

Cuatro formas de gastarlo sin darse cuenta

- ❌ Escalar o imputar antes de particionar. La media y la desviación se calcularon con datos de prueba.
- ❌ Seleccionar atributos sobre el conjunto completo. El filtro de correlación miró las etiquetas de prueba. Es la fuga más común y la más invisible en un cuaderno.
- ❌ Ajustar hiperparámetros contra el test. Después de veinte configuraciones probadas contra el test, el test es un conjunto de entrenamiento caro.
- ❌ Particionar al azar con datos dependientes. Series temporales, mediciones repetidas del mismo equipo, pacientes con varias visitas.

Kapoor y Narayanan (2023) documentan fuga de información en 294 artículos publicados de 17 disciplinas. Es la lectura del seminario 3, en la semana 7. No es un problema de estudiantes.

COROLARIO 3

El número que usted reporta es una variable aleatoria

Su estimación de $R_{\mathcal{D}}(\hat{h})$ depende de qué muestra le tocó, qué partición hizo y qué semilla usó.

> La pregunta relevante no es cuál número obtuvo usted, sino cuánto varía.

COROLARIO 3

Lo que no basta y lo que sí

Lo que no basta

«Nuestro modelo alcanza 0,91 de AUC, superando el 0,89 del método de referencia.»

- ✗ Un solo split, una sola semilla
- ✗ Sin dispersión: ¿0,02 es señal o ruido?
- ✗ Sin justificar por qué AUC
- ✗ Sin prueba que respalde el «superando»

Lo que sí

«0,91 ± 0,03 (media y desviación sobre 10 repeticiones de validación cruzada estratificada de 5 pliegues, semillas 1–10).»

- ✓ La variabilidad está reportada
- ✓ Admite una prueba estadística (semana 8)
- ✓ Un tercero reproduce el número exacto
- ✓ La métrica se justifica antes de verla

COROLARIO 4

Traducido a su trabajo de tesis

1. **Su afirmación empírica es una afirmación sobre $\mathcal{D}$** — y $\mathcal{D}$ es la población a la que se aplicará el modelo, no la muestra que consiguió. Si difieren, hay que decirlo en las limitaciones.
2. **Su protocolo de evaluación es su argumento** — no un trámite posterior a los resultados. Se diseña antes del primer experimento: por eso el hito de la semana 9 es el diseño experimental.
3. **Su revisor va a buscar exactamente esto** — fuga, ausencia de variabilidad, comparación sin prueba estadística, métrica elegida a posteriori. Los cuatro reproches más frecuentes, y los cuatro se previenen en el diseño.

EN UNA LÍNEA

Lo que hay que llevarse

> Aprender es estimar $R_{\mathcal{D}}(h)$ sin poder calcularlo, y todo el rigor del área consiste en no engañarse en esa estimación.

- El riesgo esperado es el objetivo; el empírico es lo único calculable. Confundirlos es el error fundacional del área.
- R_S es insesgado solo para h fijada de antemano. El entrenamiento rompe esa condición por construcción.
- El sesgo optimista crece con la capacidad y decrece con n. Los modelos flexibles exigen protocolos más estrictos, no menos.

Para la próxima sesión

Clase: sesgo inductivo y No Free Lunch

Si el riesgo empírico no basta para elegir h, ¿qué lo hace? Las restricciones que imponemos sobre $\mathcal{H}$ antes de ver los datos —y qué precio tienen.

Taller 1: entorno reproducible

Control de versiones, semillas, declaración del entorno y registro de experimentos. Fija el estándar con que se corrigen los cinco siguientes.

Lectura obligatoria — Domingos (2012), *A few useful things to know about machine learning*. Corto; las secciones 3, 6 y 7 son esta clase con otras palabras.

Lectura recomendada — Hastie, Tibshirani y Friedman (2009), secciones 2.4 y 2.9.

El detalle del trabajo de la semana, con tiempos y entregables, está en la guía de la semana 1.