El aprendizaje como estimación de riesgo

Clase 1 · Riesgo esperado y riesgo empírico

Unidad 1 · Formulación del aprendizaje inductivo

Invalid Date

¿Con qué derecho?

> Usted ajusta un modelo con los datos que tiene.
>
> ¿Con qué derecho afirma algo sobre los datos que **no** tiene?

SITUACIÓN

Partamos de un problema, no de una fórmula

Una planta tiene **400 bombas** instrumentadas. Con los registros de los últimos tres años queremos predecir, para cada bomba, si fallará dentro de los próximos 30 días.

- **¿Qué es un caso?** ¿Una bomba? ¿Una bomba-mes? ¿Una ventana deslizante? La respuesta cambia el tamaño de la muestra y la independencia entre casos.
- **¿Qué observamos y qué predecimos?** Vibración, temperatura, horas de operación → una etiqueta binaria que aún no existe: hay que construirla.
- **¿De dónde salen los datos y a qué se aplicarán?** Tres años de esta planta; la predicción se usará el próximo año, aquí y quizá en otra. No es la misma población.
- **¿Qué cuesta cada tipo de error?** Una falla no anticipada detiene la línea; una alerta falsa cuesta una inspección. No son comparables.

1

La formalización

Tres objetos y una definición. Todo lo demás del semestre se deriva de aquí.

Tres objetos

$\mathcal{X}, \mathcal{Y}$

Espacio de entrada y de salida. Definirlos ya es una decisión modeladora: qué se mide, con qué resolución, qué se descarta.

$\mathcal{D}$

Distribución conjunta sobre $\mathcal{X} \times \mathcal{Y}$. El mecanismo que genera los pares. Es fija, es desconocida, y **nunca la vamos a observar**.

S

La muestra: n pares (x_i, y_i) extraídos i.i.d. de $\mathcal{D}$. Todo lo que tenemos.

$$S = \{(x_1, y_1), \ldots, (x_n, y_n)\} \overset{\text{i.i.d.}}{\sim} \mathcal{D}^n$$

Una hipótesis y una función de pérdida

$$h : \mathcal{X} \to \mathcal{Y}, \quad h \in \mathcal{H} \qquad\qquad L\big(h(x),\, y\big) \;\geq\; 0$$

- Una **hipótesis** h es una regla que asigna una predicción a cada entrada. Elegir una familia de modelos es elegir el conjunto $\mathcal{H}$ que estamos dispuestos a considerar.
- Una **función de pérdida** L dice cuánto cuesta predecir $h(x)$ cuando la verdad es y. Es donde entra el costo asimétrico del problema real.

Dos decisiones que casi nadie declara

Elegir $\mathcal{H}$ es introducir un sesgo inductivo

Se decide de antemano qué formas de dependencia son admisibles. **Sin ese sesgo no hay generalización posible.**

Semana 2: No Free Lunch.

Elegir L es codificar la estructura de costos

Usar 0–1 por defecto equivale a afirmar que todos los errores cuestan lo mismo.

En su tesis, casi nunca es cierto.

Riesgo esperado

$$R_{\mathcal{D}}(h) \;=\; \mathbb{E}_{(x,y)\sim\mathcal{D}}\big[L(h(x),y)\big]$$

- La pérdida promedio de h sobre **toda la distribución**, no sobre nuestra muestra.
- Es una propiedad de h y de $\mathcal{D}$: **no depende de la muestra que a usted le tocó**.
- Este —y solo este— es el objetivo. Es el número que le interesa a quien vaya a usar su modelo.

> Y aquí está el problema: $\mathcal{D}$ es desconocida. La esperanza no se puede evaluar. Nunca.

Lo único que sí podemos calcular

$$R_S(h) \;=\; \frac{1}{n}\sum_{i=1}^{n} L\big(h(x_i),\, y_i\big)$$

El **riesgo empírico**: la misma pérdida, promediada sobre los n casos de la muestra S en lugar de sobre $\mathcal{D}$.

$$\mathbb{E}_{S\sim\mathcal{D}^n}\big[R_S(h)\big] \;=\; R_{\mathcal{D}}(h) \qquad \text{para } h \text{ fijada de antemano}$$

Todo depende de la palabra «fijada»

Lo bueno

Para h elegida **sin mirar** S, el riesgo empírico es insesgado. La garantía es real.

Lo peligroso

En cuanto usamos S para **elegir** h, la garantía deja de valer. Y eso es exactamente lo que hace el entrenamiento.

$$\hat{h} \;=\; \arg\min_{h \in \mathcal{H}} \; R_S(h) \qquad \text{(minimización del riesgo empírico, ERM)}$$

En el mismo acto de minimizar sobre S, el entrenamiento destruye el insesgamiento que hacía confiable a R_S.

Por qué el error de entrenamiento miente hacia abajo

1. **Se evalúan muchas hipótesis sobre la misma muestra.** Cada una tiene un error empírico con su propia fluctuación aleatoria.
2. **Se conserva la de menor error empírico.** Se está seleccionando, entre otras cosas, la fluctuación más favorable.
3. **El riesgo empírico de $\hat{h}$ queda sesgado hacia abajo.** El sesgo crece con la capacidad de $\mathcal{H}$ y decrece con n.
4. **El número que usted reporta no es el que obtendrá en producción.**

> Cuanto más flexible es su familia de modelos, menos informativo es su error de entrenamiento. Y las familias flexibles son las que están de moda.

La hipótesis que memoriza

$$h(x) = \begin{cases} y_i & \text{si } (x_i, y_i) \in S \\ 0 & \text{en cualquier otro caso} \end{cases}$$

$R_S(h) = 0$

Error de entrenamiento perfecto. No hay modelo que lo supere.

$R_{\mathcal{D}}(h)$ **pésimo**

Sobre cualquier punto nuevo predice 0. Su riesgo esperado es el de un modelo trivial.

Y sin embargo, gana

Si el criterio de selección es el error de entrenamiento, es el óptimo de $\mathcal{H}$.

Lo mismo, con números

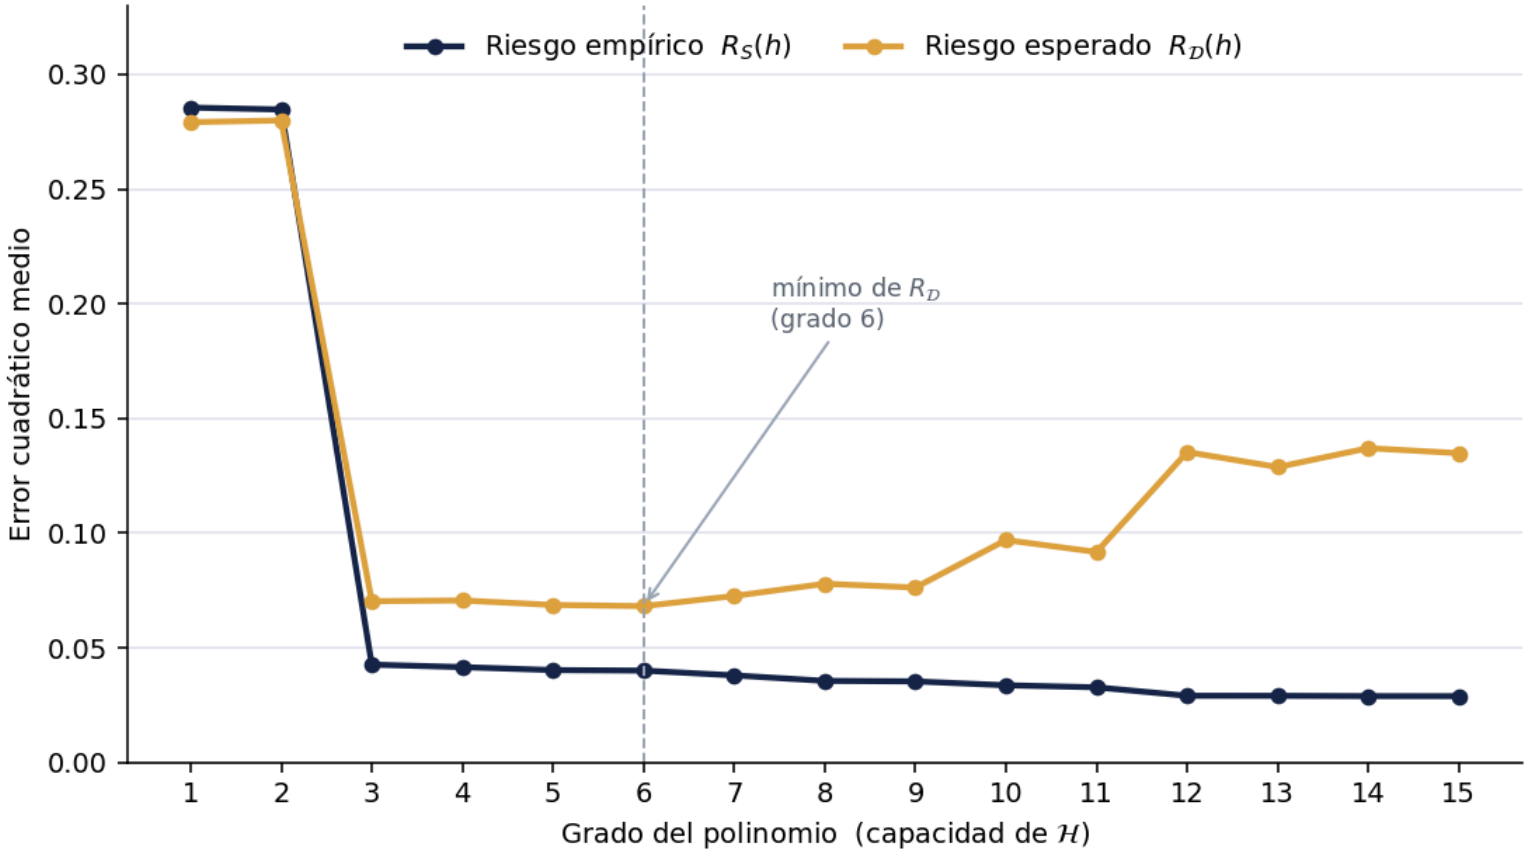


Figura 1: Riesgo empírico y riesgo esperado frente a la capacidad.

$n = 30$ observaciones de $y = \operatorname{sen}(2\pi x) + \varepsilon$, con $\varepsilon \sim N(0,\ 0{,}25^2)$; riesgo esperado estimado sobre 2 000 casos nuevos, semilla 7. La figura la genera `codigo/clase01_riesgo_empirico_vs_esperado.ipynb`, que además verifica estos valores.

2

Las consecuencias

Cuatro corolarios que gobiernan todo lo que haremos en las quince semanas.

COROLARIO 1

De dónde viene el error, en tres partes

$$\underbrace{R(\tilde{h}) - R(h^\star)}_{\text{exceso de riesgo}} = \underbrace{R(h^\star_{\mathcal{H}}) - R(h^\star)}_{\text{aproximación}} + \underbrace{R(\hat{h}) - R(h^\star_{\mathcal{H}})}_{\text{estimación}} + \underbrace{R(\tilde{h}) - R(\hat{h})}_{\text{optimización}}$$

donde $h^\star$ es la mejor función posible, $h^\star_{\mathcal{H}}$ la mejor dentro de $\mathcal{H}$, $\hat{h}$ el minimizador del riesgo empírico y $\tilde{h}$ lo que su algoritmo efectivamente devuelve.

- **Aproximación** — $\mathcal{H}$ no contiene la mejor función. Depende de la familia elegida, no de sus datos: **más datos no lo reducen**.
- **Estimación** — la muestra es finita y ruidosa. Depende de n y de la capacidad. Es el término que las garantías teóricas acotan.
- **Optimización** — el algoritmo no encuentra el mínimo exacto. Suele ignorarse, y en modelos profundos no es despreciable.

COROLARIO 2

El conjunto de prueba es un recurso que se gasta

> El error de prueba es insesgado únicamente si el conjunto de prueba no participó en **ninguna** decisión.

Ninguna: ni en la selección del modelo, ni en los hiperparámetros, ni en la imputación, ni en el escalado, ni en la selección de atributos.

COROLARIO 2

Cuatro formas de gastarlo sin darse cuenta

- ✕ **Escalar o imputar antes de particionar.** La media y la desviación se calcularon con datos de prueba.
- ✕ **Seleccionar atributos sobre el conjunto completo.** El filtro de correlación miró las etiquetas de prueba. Es la fuga más común y la más invisible en un cuaderno.
- ✕ **Ajustar hiperparámetros contra el test.** Después de veinte configuraciones probadas contra el test, el test es un conjunto de entrenamiento caro.
- ✕ **Particionar al azar con datos dependientes.** Series temporales, mediciones repetidas del mismo equipo, pacientes con varias visitas.

Kapoor y Narayanan (2023) documentan fuga de información en **294 artículos publicados** de 17 disciplinas. Es la lectura del seminario 3, en la semana 7. No es un problema de estudiantes.

COROLARIO 3

El número que usted reporta es una variable aleatoria

Su estimación de $R_{\mathcal{D}}(\hat{h})$ depende de qué muestra le tocó, qué partición hizo y qué semilla usó.

> La pregunta relevante no es cuál número obtuvo usted, sino **cuánto varía**.

COROLARIO 3

Lo que no basta y lo que sí

Lo que no basta

«Nuestro modelo alcanza 0,91 de AUC, superando el 0,89 del método de referencia.»

- Un solo split, una sola semilla
- Sin dispersión: ¿0,02 es señal o ruido?
- Sin justificar por qué AUC
- Sin prueba que respalde el «superando»

Lo que sí

«0,91 ± 0,03 (media y desviación sobre 10 repeticiones de validación cruzada estratificada de 5 pliegues, semillas 1–10).»

- La variabilidad está reportada
- Admite una prueba estadística (semana 8)
- Un tercero reproduce el número exacto
- La métrica se justifica antes de verla

COROLARIO 4

Traducido a su trabajo de tesis

1. **Su afirmación empírica es una afirmación sobre $\mathcal{D}$** — y $\mathcal{D}$ es la población a la que se aplicará el modelo, no la muestra que consiguió. Si difieren, hay que decirlo en las limitaciones.
2. **Su protocolo de evaluación es su argumento** — no un trámite posterior a los resultados. Se diseña antes del primer experimento: por eso el hito de la semana 9 es el diseño experimental.
3. **Su revisor va a buscar exactamente esto** — fuga, ausencia de variabilidad, comparación sin prueba estadística, métrica elegida a posteriori. Los cuatro reproches más frecuentes, y los cuatro se previenen en el diseño.

EN UNA LÍNEA

Lo que hay que llevarse

> Aprender es estimar $R_{\mathcal{D}}(h)$ sin poder calcularlo, y todo el rigor del área consiste en no engañarse en esa estimación.

- El riesgo esperado es el objetivo; el empírico es lo único calculable. Confundirlos es el error fundacional del área.
- R_S es insesgado **solo** para h fijada de antemano. El entrenamiento rompe esa condición por construcción.
- El sesgo optimista crece con la capacidad y decrece con n. Los modelos flexibles exigen protocolos más estrictos, no menos.

Para la próxima sesión

Clase: sesgo inductivo y No Free Lunch

Si el riesgo empírico no basta para elegir h, ¿qué lo hace? Las restricciones que imponemos sobre $\mathcal{H}$ antes de ver los datos —y qué precio tienen.

Taller 1: entorno reproducible

Control de versiones, semillas, declaración del entorno y registro de experimentos. Fija el estándar con que se corrigen los cinco siguientes.

- **Lectura obligatoria** — Domingos (2012), *A few useful things to know about machine learning*. Corto; las secciones 3, 6 y 7 son esta clase con otras palabras.
- **Lectura recomendada** — Hastie, Tibshirani y Friedman (2009), secciones 2.4 y 2.9.

El detalle del trabajo de la semana, con tiempos y entregables, está en la **guía de la semana 1**.