El sesgo inductivo

Clase 2, primera parte · Por qué sin supuestos no hay generalización

Unidad 1 · Formulación del aprendizaje inductivo

La semana pasada dejamos un problema abierto

> El riesgo empírico es lo único calculable, y minimizarlo no basta para elegir h.

- R_S es insesgado **solo** para h fijada antes de ver la muestra.
- El entrenamiento rompe esa condición: elige h mirando S.
- El memorizador tiene $R_S(h) = 0$ y es inútil.

> Entonces: si el error de entrenamiento no basta, **¿qué hace que elegir sea posible?**

1

El problema de la inducción

Antes del sesgo inductivo hay que ver por qué es necesario. El argumento es de conteo, y es más incómodo de lo que parece.

Cinco atributos binarios

Suponga el problema más simple imaginable: cinco atributos binarios, una etiqueta binaria, sin ruido.

Entradas posibles

$$2^5 = 32$$

Todas las combinaciones de los cinco atributos.

Funciones posibles

$$2^{32} \approx 4{,}3 \times 10^9$$

Una por cada forma de asignar 0 o 1 a las 32 entradas.

Usted observa **20 casos**. ¿Cuántas de esas funciones siguen siendo compatibles con lo que vio?

La muestra no elimina casi nada

$$\#\{h \text{ consistentes con } S\} \;=\; 2^{32-20} \;=\; 2^{12} \;=\; 4096$$

- Los 20 casos observados fijan 20 salidas. **Las 12 restantes quedan libres.**
- Las 4096 hipótesis supervivientes **coinciden en todo lo que usted vio**.
- Y **discrepan entre sí de todas las formas posibles** en lo que no vio.

> Para cada punto no observado, exactamente la mitad de las hipótesis consistentes predice 1 y la otra mitad predice 0.

El cuaderno de esta semana lo comprueba **por enumeración exhaustiva**, con cuatro atributos en vez de cinco: con cuatro el espacio completo tiene 65 536 funciones y cabe en memoria, así que el 0,5 no se estima, se cuenta.

Los datos, solos, no deciden

> Cualquier procedimiento que elija una hipótesis usando **solo** la muestra está eligiendo arbitrariamente entre miles de candidatas igual de compatibles.

- El algoritmo **sí** devuelve una respuesta. Siempre devuelve una.
- Pero lo que la determina no está en los datos: está en el algoritmo.
- Ese «lo que la determina» es lo que vamos a nombrar.

El espacio de hipótesis

$\mathcal{H} \subseteq \mathcal{Y}^{\mathcal{X}}$ el conjunto de reglas que estamos dispuestos a considerar

Antes de ver los datos

Usted descarta, de un plumazo, la inmensa mayoría de las funciones posibles. Nunca las evalúa. Nunca aparecen.

Ese descarte es el aprendizaje

Sin él, ERM elige al azar entre las consistentes. Con él, elige entre las que usted declaró admisibles.

2

El sesgo inductivo

Ya tenemos el problema. Ahora el nombre y la definición.

DEFINICIÓN

Sesgo inductivo

> El conjunto de supuestos que, añadidos a la muestra, hacen que la predicción sobre casos no vistos se siga deductivamente.

$$S \cup B \vdash h(x) \qquad \text{para todo } x \in \mathcal{X}$$

Sin B, la muestra S no implica nada sobre los puntos no observados. Con B, la predicción queda determinada.

DÓNDE VIVE

El sesgo no está en un solo lugar

1. **En la elección de $\mathcal{H}$** — restricción de lenguaje. Qué formas de dependencia son siquiera expresables.
2. **En el criterio de preferencia** — dentro de $\mathcal{H}$, cuál se prefiere cuando varias ajustan igual. Regularización, márgenes, navaja de Occam.
3. **En el algoritmo de búsqueda** — qué encuentra primero y dónde se detiene. Descenso de gradiente con detención temprana es un sesgo, aunque nadie lo declare.

> Los tres operan siempre. Los tres son decisiones. Casi ninguna tesis declara la tercera.

EJEMPLOS

Qué supone cada familia

FAMILIA	QUÉ SUPONE SOBRE EL MUNDO
Regresión lineal	La relación es aditiva y de pendiente constante
k vecinos más cercanos	Los puntos cercanos en la métrica elegida tienen etiqueta parecida
Árboles de decisión	La frontera es paralela a los ejes, y por regiones
Máquinas de soporte vectorial	Existe un margen amplio en el espacio del kernel
Redes convolucionales	La señal es local, estacionaria y jerárquica
Naive Bayes	Los atributos son independientes dada la clase

> Elegir una familia es afirmar todo eso. La pregunta de su tesis es si es cierto en **su** problema.

Un sesgo es un supuesto verificable

Lo que se declara

«Usamos un bosque aleatorio con 500 árboles.»

Describe la implementación. No dice nada sobre el mundo.

Lo que se debería declarar

«Suponemos que la frontera es aproximadamente paralela a los ejes y que las interacciones son de orden bajo. Esto es plausible aquí porque los atributos son mediciones independientes de sensores.»

Es una afirmación sobre el problema. **Se puede discutir, y se puede refutar.**

3

Capacidad

Restringir $\mathcal{H}$ tiene un costo. Nombrarlo prepara la semana 3.

Dos maneras de acotar $\mathcal{H}$

Restricción dura

$\mathcal{H}$ se define pequeño de entrada: solo polinomios de grado ≤ 3, solo árboles de profundidad ≤ 5.

Lo que queda fuera **no existe** para el algoritmo.

Restricción blanda

$\mathcal{H}$ es grande, pero se penaliza la complejidad:

$$\hat{h} = \arg\min_{h \in \mathcal{H}} \; R_S(h) + \lambda\, \Omega(h)$$

Lo que queda fuera es **caro**, no imposible. Es la semana 4.

Restringir de más también se paga

$\mathcal{H}$ demasiado grande

Contiene la buena función, pero la muestra no alcanza a distinguirla de las malas. **Error de estimación alto.**

$\mathcal{H}$ demasiado pequeño

La muestra basta para elegir bien dentro de $\mathcal{H}$, pero la buena función no está ahí. **Error de aproximación alto.**

$$R(\hat{h}) - R(h^\star) = \underbrace{R(h^\star_{\mathcal{H}}) - R(h^\star)}_{\text{aproximación}} + \underbrace{R(\hat{h}) - R(h^\star_{\mathcal{H}})}_{\text{estimación}}$$

Es la descomposición de la semana 1, leída ahora como una decisión sobre el tamaño de $\mathcal{H}$. La forma cuantitativa es el compromiso sesgo-varianza, la semana que viene.

Lo que se le va a pedir

1. **Declarar el sesgo inductivo de su método**, en términos del problema y no de la biblioteca. Es parte de la propuesta de la semana 5.
2. **Justificar por qué es plausible** en su dominio, con lo que usted sabe del fenómeno y no con lo que dice la documentación.
3. **Decir bajo qué condiciones dejaría de serlo.** Es la sección de limitaciones, y es lo que separa un trabajo defendible de uno que solo funcionó.

EN UNA LÍNEA

Lo que hay que llevarse

> Sin supuestos no hay generalización: los datos, solos, son compatibles con demasiadas respuestas. Aprender es elegir supuestos, y elegirlos bien es una afirmación sobre el problema, no sobre el algoritmo.