# El sesgo inductivo

Clase 2, primera parte · Por qué sin supuestos no hay generalización

Unidad 1 · Formulación del aprendizaje inductivo

Invalid Date

# La semana pasada dejamos un problema abierto

> El riesgo empírico es lo único calculable, y minimizarlo no basta para elegir $h$.

- $R_S$ es insesgado **solo** para $h$ fijada antes de ver la muestra.
- El entrenamiento rompe esa condición: elige $h$ mirando $S$.
- El memorizador tiene $R_S(h) = 0$ y es inútil.

> Entonces: si el error de entrenamiento no basta, **¿qué hace que elegir sea posible?**

1

# El problema de la inducción

Antes del sesgo inductivo hay que ver por qué es necesario. El argumento es de conteo, y es más incómodo de lo que parece.

# Cinco atributos binarios

Suponga el problema más simple imaginable: cinco atributos binarios, una etiqueta binaria, sin ruido.

### Entradas posibles

$$2^5 = 32$$

Todas las combinaciones de los cinco atributos.

### Funciones posibles

$$2^{32} \approx 4{,}3 \times 10^9$$

Una por cada forma de asignar 0 o 1 a las 32 entradas.

Usted observa **20 casos**. ¿Cuántas de esas funciones siguen siendo compatibles con lo que vio?

# La muestra no elimina casi nada

$$\#\{h \text{ consistentes con } S\} \;=\; 2^{32-20} \;=\; 2^{12} \;=\; 4096$$

- Los 20 casos observados fijan 20 salidas. **Las 12 restantes quedan libres.**
- Las 4096 hipótesis supervivientes **coinciden en todo lo que usted vio**.
- Y **discrepan entre sí de todas las formas posibles** en lo que no vio.

> Para cada punto no observado, exactamente la mitad de las hipótesis consistentes predice 1 y la otra mitad predice 0.

El cuaderno de esta semana lo comprueba **por enumeración exhaustiva**, con cuatro atributos en vez de cinco: con cuatro el espacio completo tiene 65 536 funciones y cabe en memoria, así que el 0,5 no se estima, se cuenta.

# Los datos, solos, no deciden

> Cualquier procedimiento que elija una hipótesis usando **solo** la muestra está eligiendo arbitrariamente entre miles de candidatas igual de compatibles.

- El algoritmo **sí** devuelve una respuesta. Siempre devuelve una.
- Pero lo que la determina no está en los datos: está en el algoritmo.
- Ese «lo que la determina» es lo que vamos a nombrar.

# El espacio de hipótesis

$\mathcal{H} \subseteq \mathcal{Y}^{\mathcal{X}}$ el conjunto de reglas que estamos dispuestos a considerar

### Antes de ver los datos

Usted descarta, de un plumazo, la inmensa mayoría de las funciones posibles. Nunca las evalúa. Nunca aparecen.

### Ese descarte es el aprendizaje

Sin él, ERM elige al azar entre las consistentes. Con él, elige entre las que usted declaró admisibles.

2

# El sesgo inductivo

Ya tenemos el problema. Ahora el nombre y la definición.

DEFINICIÓN

# Sesgo inductivo

> El conjunto de supuestos que, añadidos a la muestra, hacen que la predicción sobre casos no vistos se siga deductivamente.

$$S \cup B \vdash h(x) \qquad \text{para todo } x \in \mathcal{X}$$

Sin $B$, la muestra $S$ no implica nada sobre los puntos no observados. Con $B$, la predicción queda determinada.

DÓNDE VIVE

# El sesgo no está en un solo lugar

1. **En la elección de $\mathcal{H}$** — restricción de lenguaje. Qué formas de dependencia son siquiera expresables.
2. **En el criterio de preferencia** — dentro de $\mathcal{H}$, cuál se prefiere cuando varias ajustan igual. Regularización, márgenes, navaja de Occam.
3. **En el algoritmo de búsqueda** — qué encuentra primero y dónde se detiene. Descenso de gradiente con detención temprana es un sesgo, aunque nadie lo declare.

> Los tres operan siempre. Los tres son decisiones. Casi ninguna tesis declara la tercera.

EJEMPLOS

# Qué supone cada familia

| FAMILIA | QUÉ SUPONE SOBRE EL MUNDO |
|---|---|
| Regresión lineal | La relación es aditiva y de pendiente constante |
| $k$ vecinos más cercanos | Los puntos cercanos en la métrica elegida tienen etiqueta parecida |
| Árboles de decisión | La frontera es paralela a los ejes, y por regiones |
| Máquinas de soporte vectorial | Existe un margen amplio en el espacio del kernel |
| Redes convolucionales | La señal es local, estacionaria y jerárquica |
| Naive Bayes | Los atributos son independientes dada la clase |

> Elegir una familia es afirmar todo eso. La pregunta de su tesis es si es cierto en **su** problema.

# Un sesgo es un supuesto verificable

### Lo que se declara

«Usamos un bosque aleatorio con 500 árboles.»

Describe la implementación. No dice nada sobre el mundo.

### Lo que se debería declarar

«Suponemos que la frontera es aproximadamente paralela a los ejes y que las interacciones son de orden bajo. Esto es plausible aquí porque los atributos son mediciones independientes de sensores.»

Es una afirmación sobre el problema. **Se puede discutir, y se puede refutar.**

3

# Capacidad

Restringir $\mathcal{H}$ tiene un costo. Nombrarlo prepara la semana 3.

# Dos maneras de acotar $\mathcal{H}$

### Restricción dura

$\mathcal{H}$ se define pequeño de entrada: solo polinomios de grado $\leq 3$, solo árboles de profundidad $\leq 5$.

Lo que queda fuera **no existe** para el algoritmo.

### Restricción blanda

$\mathcal{H}$ es grande, pero se penaliza la complejidad:

$$\hat{h} = \arg\min_{h \in \mathcal{H}} \; R_S(h) + \lambda\, \Omega(h)$$

Lo que queda fuera es **caro**, no imposible. Es la semana 4.

# Restringir de más también se paga

### $\mathcal{H}$ demasiado grande

Contiene la buena función, pero la muestra no alcanza a distinguirla de las malas. **Error de estimación alto.**

### $\mathcal{H}$ demasiado pequeño

La muestra basta para elegir bien dentro de $\mathcal{H}$, pero la buena función no está ahí. **Error de aproximación alto.**

$$R(\hat{h}) - R(h^\star) = \underbrace{R(h^\star_{\mathcal{H}}) - R(h^\star)}_{\text{aproximación}} + \underbrace{R(\hat{h}) - R(h^\star_{\mathcal{H}})}_{\text{estimación}}$$

Es la descomposición de la semana 1, leída ahora como una decisión sobre el tamaño de $\mathcal{H}$. La forma cuantitativa es el compromiso sesgo-varianza, la semana que viene.

# Lo que se le va a pedir

1. **Declarar el sesgo inductivo de su método**, en términos del problema y no de la biblioteca. Es parte de la propuesta de la semana 5.
2. **Justificar por qué es plausible** en su dominio, con lo que usted sabe del fenómeno y no con lo que dice la documentación.
3. **Decir bajo qué condiciones dejaría de serlo.** Es la sección de limitaciones, y es lo que separa un trabajo defendible de uno que solo funcionó.

# Lo que hay que llevarse

> Sin supuestos no hay generalización: los datos, solos, son compatibles con demasiadas respuestas. Aprender es elegir supuestos, y elegirlos bien es una afirmación sobre el problema, no sobre el algoritmo.