No Free Lunch

Clase 2, segunda parte · Qué significa que un método sea «mejor»

Unidad 1 · Formulación del aprendizaje inductivo

Si el sesgo es inevitable, ¿hay alguno mejor?

En la primera parte establecimos que sin supuestos no hay generalización. La pregunta natural es la siguiente:

> ¿Existe un sesgo inductivo universalmente superior? ¿Un algoritmo que, sin saber nada del problema, sea mejor que los demás?

La respuesta es **no**, y es un teorema. Pero el teorema se cita mal con frecuencia, y las conclusiones que se sacan de él suelen ser falsas.

1

El teorema

Wolpert (1996). Primero el enunciado, después lo que realmente afirma.

ENUNCIADO INFORMAL

Promediado sobre todos los problemas, todo empata

> Si se promedia el desempeño sobre **todas** las funciones objetivo posibles, dos algoritmos cualesquiera tienen exactamente el mismo error esperado fuera de la muestra de entrenamiento.

- «Todas» significa las 2^{2^n} funciones del conteo de la primera parte.
- «Fuera de la muestra» es esencial: sobre los puntos ya vistos sí puede haber diferencias.
- «Cualesquiera» incluye su método favorito y **también predecir siempre cero**.

ENUNCIADO PRECISO

La forma que conviene recordar

Sean a_1 y a_2 dos algoritmos, m el tamaño de la muestra, f la función objetivo y e el error fuera de la muestra:

$$\sum_f P(e \mid m, a_1, f) \;=\; \sum_f P(e \mid m, a_2, f)$$

- La suma recorre **todas** las funciones $f : \mathcal{X} \to \mathcal{Y}$.
- Equivale a poner una distribución **uniforme** sobre las funciones objetivo.
- Ese supuesto de uniformidad es todo el teorema, y es donde hay que mirar.

Es un argumento de simetría

1. Fije la muestra S y un punto no observado x.
2. Para cada función f compatible con S que asigna $f(x) = 1$, existe **otra** función f', igualmente compatible con S, idéntica a f en todas partes salvo en x, donde $f'(x) = 0$.
3. Las funciones compatibles vienen **emparejadas**. Cualquier predicción acierta en una y falla en la otra.
4. Al sumar sobre todas, los aciertos y los fallos se cancelan. El promedio no depende del algoritmo.

> El teorema no dice que aprender sea imposible. Dice que la uniformidad sobre funciones destruye toda información.

LO QUE SÍ DICE

Tres afirmaciones correctas

- ✓ **No existe un algoritmo universalmente mejor.** Toda superioridad es relativa a una clase de problemas.
- ✓ **Todo desempeño superior se paga.** Un método que gana en unos problemas pierde exactamente lo mismo en otros.
- ✓ **El sesgo inductivo no es opcional ni neutral.** Es el mecanismo por el cual un algoritmo apuesta a que su problema pertenece a cierta clase.

2

Las tres lecturas incorrectas

Aquí es donde el teorema se usa mal, y donde conviene no equivocarse.

«Todos los algoritmos son igual de buenos»

Lo que se concluye

«Da lo mismo qué método use: el teorema dice que empatan.»

Por qué es falso

Empatan promediando sobre **todas** las funciones posibles. Los problemas reales no son una muestra uniforme de ese conjunto: son minúsculamente pocos y tienen estructura.

> Casi todas las 2^{2^n} funciones son ruido puro sin estructura. Ninguna de ellas describe una planta industrial, un tejido o un texto.

«Entonces no sirve comparar algoritmos»

Lo que se concluye

«Como todo empata en promedio, comparar en un conjunto de datos no dice nada.»

Por qué es falso

Comparar sobre la distribución que le interesa es exactamente lo que hay que hacer. Lo que el teorema prohíbe es **extrapolar** esa comparación a todos los problemas posibles.

> La conclusión correcta no es «no compare», sino «declare sobre qué clase de problemas vale su comparación».

«Hay que probarlos todos y quedarse con el mejor»

Lo que se concluye

«Como no se puede saber a priori, probemos veinte modelos y reportemos el que gane.»

Por qué es falso

Probar veinte y quedarse con el mejor es el **sesgo optimista** de la semana 1, amplificado veinte veces. Y desperdicia lo único que el teorema deja en pie: que usted sabe algo de su problema.

> El conocimiento del dominio no es un adorno del capítulo de introducción. Es la información que decide qué sesgo inductivo es apropiado.

3

Qué significa «mejor»

La parte constructiva: cómo se afirma correctamente que un método es superior.

«Mejor» necesita tres complementos

1. **Mejor ¿en qué clase de problemas?** Datos tabulares con atributos heterogéneos; series de sensores industriales; imágenes de microscopía.
2. **Mejor ¿según qué pérdida?** Y por qué esa pérdida representa el costo real del problema.
3. **Mejor ¿con qué evidencia?** Sobre cuántos conjuntos, con qué protocolo, con qué variabilidad y con qué prueba estadística.

> Una afirmación de superioridad sin los tres complementos no es refutable, y por tanto no es una afirmación científica.

UN CASO

Cómo se ve una afirmación bien acotada

Grinsztajn, Oyallon y Varoquaux (2022)

«En conjuntos **tabulares de tamaño medio con atributos heterogéneos**, los modelos basados en árboles superan a las redes profundas bajo un presupuesto equivalente de ajuste de hiperparámetros.»

- La clase de problemas está delimitada, y se justifica por qué.
- El presupuesto de cómputo se declara: sin eso la comparación no significa nada.
- La conclusión **no** se extiende a imágenes, texto ni series temporales.

Es la lectura del seminario 4, en la semana 11. Al leerla, busquen exactamente estos tres complementos.

Dos consecuencias operativas

1. **Su elección de método necesita un argumento sustantivo**, no una encuesta de qué está de moda. El argumento une lo que usted sabe del fenómeno con el sesgo inductivo de la familia.
2. **Su afirmación de superioridad necesita alcance declarado.** Escriba la frase completa —clase de problemas, pérdida, evidencia— antes de correr el primer experimento. Si no puede escribirla, el experimento aún no está diseñado.

EN UNA LÍNEA

Lo que hay que llevarse

> Ningún sesgo inductivo es mejor a priori. Por eso elegir el suyo con argumentos sobre el problema —y declarar el alcance en que vale— no es una formalidad: es lo único que hace defendible el resultado.

Taller 1 y lecturas

Taller 1 · Entorno reproducible

2 hp. Control de versiones, semillas, declaración del entorno y registro de experimentos.

Se entrega **cuaderno + bitácora de una página**. Es el taller que fija el estándar con que se corrigen los cinco siguientes.

Seminario 1 · Semana 3

Wolpert (1996) y Domingos (2012).

La reseña 1 se entrega 48 horas antes. Reciben la rúbrica y una reseña de ejemplo ya calificada.

El detalle del trabajo de la semana, con tiempos y entregables, está en la **guía de la semana 2**.