El compromiso sesgo-varianza

Clase 3 · Capacidad, complejidad y el alcance real de las garantías

Unidad 1 · Formulación del aprendizaje inductivo

Dos semanas de tensión sin cuantificar

- **Semana 1** — el error se descompone en aproximación, estimación y optimización. Reducir uno suele aumentar otro.
- **Semana 2** — restringir $\mathcal{H}$ hace posible aprender, y restringir de más impide acertar.

> Hoy le ponemos números a esa tensión, y vemos hasta dónde llega la teoría que pretende gobernarla.

1

La descomposición

Un experimento mental que no se puede hacer en la vida real, y por eso mismo aclara.

Si pudiéramos repetir el estudio mil veces

Imagine que puede extraer **muchas muestras distintas** $S_1, S_2, \ldots$ de la misma distribución, y entrenar un modelo con cada una.

- Obtiene muchos modelos: $\hat{h}_{S_1}, \hat{h}_{S_2}, \ldots$
- Fije un punto x_0. Cada modelo predice algo distinto en él.
- Esa nube de predicciones tiene un **centro** y una **dispersión**.

> El centro y la dispersión son dos formas independientes de equivocarse, y hay que mirarlas por separado.

Error cuadrático, en tres términos

Con $y = f(x) + \varepsilon$ y ε de media cero y varianza σ^2:

$$\mathbb{E}\big[(y - \hat{h}_S(x_0))^2\big] = \underbrace{\big(f(x_0) - \bar{h}(x_0)\big)^2}_{\text{sesgo}^2} + \underbrace{\mathbb{E}\big[(\hat{h}_S(x_0) - \bar{h}(x_0))^2\big]}_{\text{varianza}} + \underbrace{\sigma^2}_{\text{ruido}}$$

donde $\bar{h}(x_0) = \mathbb{E}_S[\hat{h}_S(x_0)]$ es la predicción **promedio sobre muestras**.

Qué es cada uno

Sesgo²

Cuánto se equivoca el modelo **promedio**. Mide si la familia $\mathcal{H}$ puede siquiera representar el fenómeno.

Alto = la familia es demasiado rígida.

Varianza

Cuánto cambia el modelo al cambiar la **muestra de entrenamiento**. Mide sensibilidad al azar de los datos.

Alta = el modelo está leyendo ruido.

Ruido σ^2

La parte de y que ningún modelo puede predecir a partir de x.

Es el piso. No hay método que lo baje.

> Si su error de prueba está cerca de σ^2, el problema está resuelto —y seguir buscando modelos es perder el tiempo.

EL COMPROMISO

Por qué no se pueden bajar los dos

AL AUMENTAR LA CAPACIDAD DE $\mathcal{H}$	
El sesgo	**baja** — la familia puede representar más formas
La varianza	**sube** — hay más maneras de ajustarse al ruido de esta muestra
El ruido	no cambia

Las dos primeras filas son **el mismo hecho**: la flexibilidad que permite seguir a f es la que permite seguir a ε, y el modelo no puede distinguirlos —llegan sumados dentro del mismo y—.

> La capacidad que minimiza el error total no es la que minimiza ninguno de los dos por separado.

Es la curva en U de la figura de la semana 1: el riesgo esperado baja, toca un mínimo y vuelve a subir. Ahora sabemos qué la produce.

La descomposición, medida

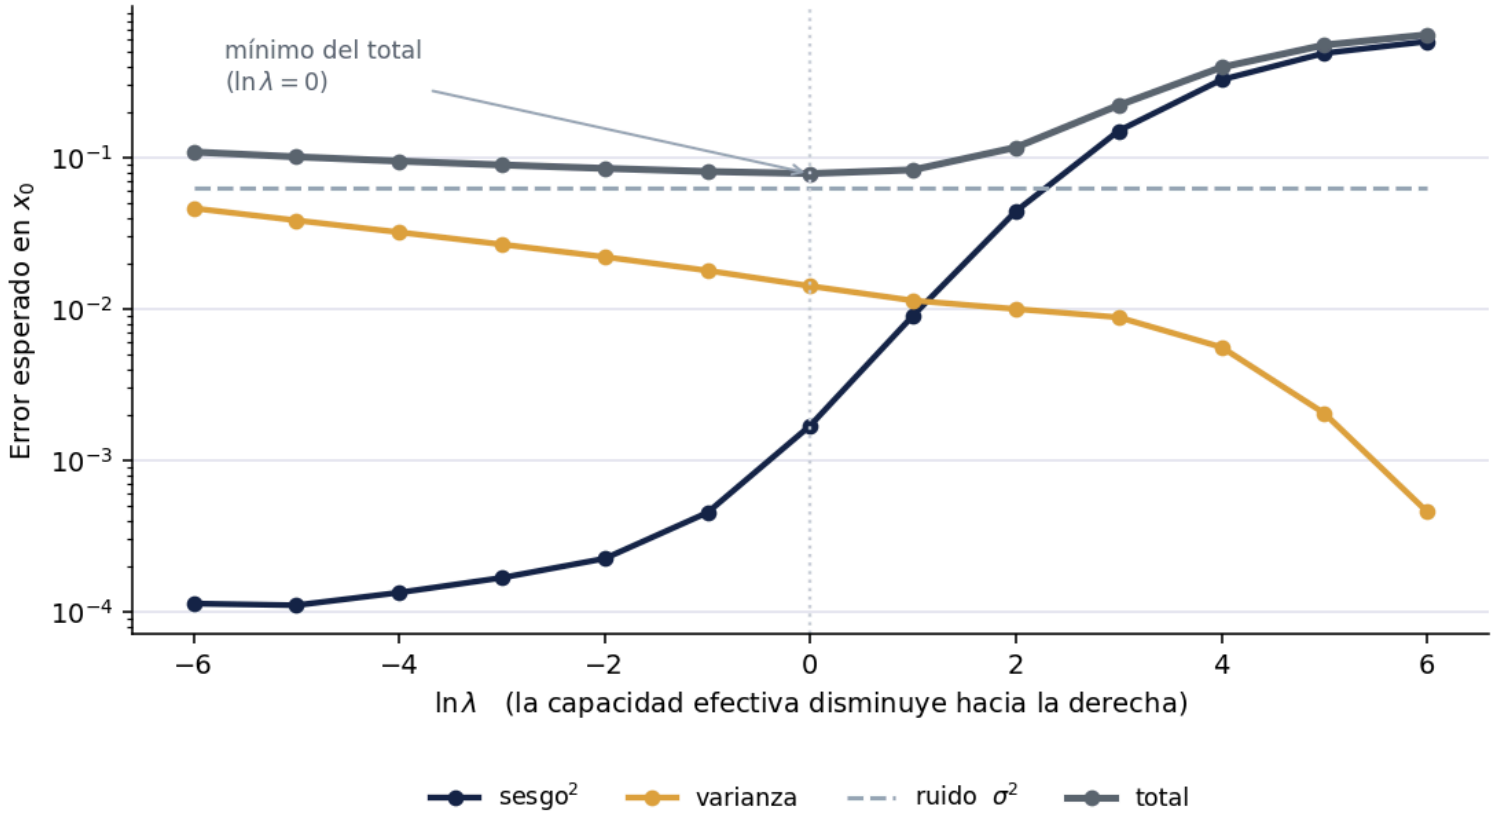


Figura 1: Sesgo al cuadrado, varianza y ruido en función de la regularización.

Base gaussiana de 24 funciones más el sesgo —**25 parámetros, fijos**— sobre 3000 muestras de $n = 25$. Mínimo en $\ln \lambda = 0$: total $0{,}0784$, con $0{,}0625$ de ruido. **«Total» es la única de las cuatro curvas estimable en un problema real.** Bishop (2006), §3.2.

2

Capacidad y garantías

Si el compromiso depende de la capacidad, hace falta medirla.

No es el número de parámetros

> La capacidad de $\mathcal{H}$ es cuántos patrones distintos puede reproducir, no cuántos números tiene adentro.

- $h(x) = \sin(\alpha x)$ tiene **un** parámetro y capacidad infinita: con α adecuado separa cualquier conjunto finito de puntos.
- Una red con millones de parámetros y regularización fuerte puede tener capacidad efectiva baja.
- Contar parámetros es una aproximación cómoda y a veces muy mala.

La medida clásica

> La dimensión de Vapnik-Chervonenkis de $\mathcal{H}$ es el mayor d tal que existen d puntos que $\mathcal{H}$ puede etiquetar de **todas** las 2^d formas posibles.

Ejemplos

Rectas en el plano: $d_{VC} = 3$.

Hiperplanos en $\mathbb{R}^p$: $d_{VC} = p + 1$.

$h(x) = \text{signo}(\sin(\alpha x))$: $d_{VC} = \infty$.

Qué mide

Cuántos puntos puede «memorizar» la familia en el peor caso.

Es el contraejemplo del memorizador de la semana 1, convertido en número.

Lo que la teoría promete

Con probabilidad al menos $1 - \delta$ sobre la muestra, **para toda $h \in \mathcal{H}$**:

$$R_{\mathcal{D}}(h) \;\leq\; R_S(h) \;+\; \sqrt{\frac{d_{VC}\left(\log \frac{2n}{d_{VC}} + 1\right) + \log \frac{4}{\delta}}{n}}$$

- El término de la derecha **crece con d_{VC}** y **decrece con n**.
- Vale **uniformemente sobre todo $\mathcal{H}$**: por eso cubre el caso de elegir h mirando S.
- Es exactamente la formalización del sesgo optimista de la semana 1.

Por qué nadie usa estas cotas

- **Son del peor caso.** Valen para cualquier distribución $\mathcal{D}$, incluida la más adversa. La suya no lo es.
- **Son numéricamente inútiles.** Con valores típicos dan cotas mayores que 1 sobre un error acotado por 1.
- **Necesitan d_{VC}**, que para modelos modernos no se conoce o es astronómica.

> Y sin embargo importan: no por el número que dan, sino por la **estructura** que revelan.

Tres cosas que la cota deja establecidas

1. **La brecha entre entrenamiento y prueba crece con la capacidad y decae con n.** No es una impresión: es un teorema.
2. **Existe una capacidad óptima**, y depende del tamaño de la muestra. Con más datos conviene más capacidad.
3. **Controlar la capacidad es un mecanismo legítimo**, y de ahí sale la regularización de la semana que viene.

> La teoría no predice su error. Justifica el procedimiento con el que usted lo estima y lo controla.

3

Lo que la curva en U no cuenta

Un matiz que la literatura reciente obliga a incluir.

La U no siempre es una U

En modelos muy sobreparametrizados el error de prueba **vuelve a bajar** después del punto de interpolación, donde $R_S(h) = 0$.

Qué no significa

Que el compromiso sesgo-varianza sea falso, ni que la capacidad ya no importe.

Qué significa

Que la capacidad **efectiva** no es la nominal. El algoritmo de optimización introduce su propia regularización implícita —el tercer lugar del sesgo inductivo, semana 2.

Con los tamaños de muestra y los modelos de una tesis en ingeniería, usted va a vivir del lado izquierdo de la curva. Pero conviene saber que el lado derecho existe, porque va a leerlo.

Tres cosas que sí se le van a pedir

1. **Estimar el piso de ruido** de su problema, o argumentar por qué no puede. Sin eso no sabe si su margen de mejora es real.
2. **Diagnosticar de qué lado está.** Error de entrenamiento alto = sesgo. Brecha grande entre entrenamiento y prueba = varianza. El remedio es distinto.
3. **Controlar la capacidad de forma declarada**, no por defecto de la biblioteca.

EN UNA LÍNEA

Lo que hay que llevarse

> El error tiene un piso que no se puede bajar y dos partes que se compensan entre sí. Elegir capacidad es elegir cómo repartirse el error, y la teoría dice que ese reparto existe aunque no diga dónde está.

Semana 4: regresión lineal y logística como máxima verosimilitud; regularización L_1 y L_2 y su lectura bayesiana. Es el mecanismo concreto para controlar la capacidad. **Taller 2.**