Modelos lineales como máxima verosimilitud

Clase 4, primera parte · De dónde salen realmente las funciones de pérdida

Unidad 2 · Modelos supervisados y su fundamento

Una pregunta que quedó sin responder

En la semana 1 dijimos que elegir la función de pérdida L es codificar la estructura de costos del problema, y que casi nadie lo declara.

> Pero, ¿de dónde salen las pérdidas que todo el mundo usa? ¿Por qué error cuadrático en regresión y entropía cruzada en clasificación?

Hoy veremos que **no son elecciones arbitrarias**: cada una es el negativo del logaritmo de una verosimilitud, y por tanto encierra un supuesto probabilístico concreto sobre cómo se generan los datos.

1

Regresión lineal

El modelo más simple, y el que mejor deja ver el argumento.

Una hipótesis lineal en los parámetros

$$h_\beta(x) \;=\; \beta_0 + \sum_{j=1}^{p} \beta_j x_j \;=\; \beta^\top \tilde{x}$$

donde $\tilde{x} = (1, x_1, \ldots, x_p)^\top$ —léase «equis tilde»— es x **con un 1 al frente**, para que β_0 entre en el producto punto.

- **Lineal en β, no necesariamente en x.** x^2, $\log x$ y $x_1 x_2$ son atributos como cualquier otro.
- El sesgo inductivo, en los términos de la semana 2: *el efecto de cada atributo es aditivo y de pendiente constante*.
- $\mathcal{H}$ tiene dimensión VC $p + 1$: exactamente el número de atributos más uno.

Mínimos cuadrados es minimización del riesgo empírico

Con pérdida cuadrática, el riesgo empírico —el error promedio sobre sus n datos— es

$$R_S(\beta) \;=\; \frac{1}{n}\sum_{i=1}^{n}\left(y_i - \beta^\top \tilde{x}_i\right)^2$$

Su **minimizador** es el β que hace ese promedio lo más pequeño posible: $\hat{\beta} = \arg\min_\beta R_S(\beta)$. Aquí no hay que buscarlo, se calcula de una vez.

$$\hat{\beta} \;=\; \left(X^\top X\right)^{-1} X^\top y$$

El gorro de $\hat{\beta}$ marca que es una estimación sacada de los datos. Es el mismo `np.polyfit` de la clase 1: mínimos cuadrados ordinarios sobre una base polinomial.

¿Por qué el cuadrado, y no otra cosa?

- ¿Por qué no $|y - \hat{y}|$, que también penaliza errores en ambas direcciones?
- ¿Por qué no la cuarta potencia?
- ¿Por qué no algo asimétrico, si sobreestimar cuesta distinto que subestimar?

> La respuesta habitual —«porque es derivable y tiene solución cerrada»— es cierta y es una racionalización. La respuesta real es probabilística.

Suponga ruido gaussiano y derive

Suponga que los datos se generan como $y_i = \beta^\top \tilde{x}_i + \varepsilon_i$ con $\varepsilon_i \sim N(0, \sigma^2)$ independientes. Entonces

$$p(y_i \mid x_i, \beta) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\!\left(-\frac{(y_i - \beta^\top \tilde{x}_i)^2}{2\sigma^2}\right)$$

Tomando logaritmo de la verosimilitud conjunta y descartando lo que no depende de β:

$$-\log \mathcal{L}(\beta) = \frac{1}{2\sigma^2} \sum_{i=1}^{n} \left(y_i - \beta^\top \tilde{x}_i\right)^2 + \text{const}$$

El cuadrado no era una elección

> Minimizar el error cuadrático **es** estimar por máxima verosimilitud bajo el supuesto de ruido gaussiano de varianza constante.

Lo que usted creía elegir

Una función de pérdida conveniente.

Lo que estaba afirmando

Que los errores son gaussianos, independientes, de media cero y **de la misma varianza en todo el rango**.

CUÁNDO FALLA

Tres supuestos que se rompen a menudo

- ✕ **Varianza constante.** Si el error crece con la magnitud de y —lo habitual en medición física—, mínimos cuadrados da demasiado peso a los valores grandes.
- ✕ **Colas ligeras.** Un solo valor atípico mueve $\hat{\beta}$ de forma desproporcionada, porque el cuadrado castiga los desvíos grandes con enorme severidad.
- ✕ **Independencia.** Series temporales, mediciones repetidas del mismo equipo, casos agrupados: los errores están correlacionados y la verosimilitud está mal escrita.

> Hay un remedio para cada uno, y los tres consisten en lo mismo: escribir la verosimilitud correcta.

Ponderados — cada dato entra con un peso inverso a su varianza: los más ruidosos pesan menos. **Huber** — cuadrática cerca de cero y lineal más allá de un umbral: el atípico paga mucho, no infinito. **Mixtos** — un término aleatorio por grupo (parcela, paciente, equipo), que admite errores correlacionados. Los tres, con lecturas, en la guía §4.

2

Regresión logística

El mismo argumento, con otra verosimilitud.

Por qué no basta con ajustar una recta a etiquetas 0/1

Una etiqueta binaria es una variable **Bernoulli**: vale 1 con probabilidad π y 0 con probabilidad $1 - \pi$ —una moneda cargada—. Todo el modelo se reduce a estimar ese π para cada caso.

- Una recta no está acotada: predice $1{,}4$ y $-0{,}3$, que no son probabilidades.
- El supuesto de varianza constante es insostenible: la varianza de una Bernoulli es $\pi(1 - \pi)$, y depende de la media.
- Un caso muy alejado de la frontera arrastra el ajuste aunque esté correctamente clasificado.

> La solución no es parchear la recta: es escribir la verosimilitud que corresponde a una etiqueta binaria.

Lineal en el logaritmo de las probabilidades relativas

$$\Pr(y = 1 \mid x) \;=\; \sigma\big(\beta^\top \tilde{x}\big) \;=\; \frac{1}{1 + e^{-\beta^\top \tilde{x}}}$$

Equivalentemente, lo que es lineal son las **log-probabilidades relativas**:

$$\log \frac{\Pr(y = 1 \mid x)}{\Pr(y = 0 \mid x)} \;=\; \beta^\top \tilde{x}$$

De ahí que β_j se interprete como el cambio en el logaritmo de la razón de probabilidades por unidad de x_j, manteniendo lo demás constante.

Bernoulli, y sale la entropía cruzada

Con $\pi_i = \sigma(\beta^\top \tilde{x}_i)$ y $y_i \in \{0, 1\}$:

$$p(y_i \mid x_i, \beta) \;=\; \pi_i^{\,y_i}\,(1-\pi_i)^{\,1-y_i}$$

$$-\log \mathcal{L}(\beta) = -\sum_{i=1}^{n}\Big[y_i \log \pi_i + (1-y_i)\log(1-\pi_i)\Big]$$

> Eso es exactamente la entropía cruzada binaria. Nadie la eligió: es lo que sale de suponer que la etiqueta es Bernoulli.

Entropía cruzada: cada caso paga $-\log$ de la probabilidad que el modelo le asignó a lo que de verdad ocurrió. Si acertó con $0{,}99$, paga casi nada; si dijo $0{,}01$, paga mucho; si dijo 0 y ocurrió, paga infinito. La suma de esos precios es la expresión de arriba.

Y por qué eso importa

No existe una fórmula como $(X^\top X)^{-1} X^\top y$: hay que **buscar** $\hat{\beta}$ paso a paso.

El **descenso de gradiente** parte de un β cualquiera y repite $\beta \leftarrow \beta - \eta \nabla R_S(\beta)$: un paso corto en la dirección en que el error baja más rápido, hasta que deje de bajar.

Funciona porque $-\log \mathcal{L}$ es **convexa**: forma de tazón, un solo fondo.

La buena noticia

Convexidad: no hay mínimos locales. El error de optimización de la semana 1 es despreciable aquí.

La mala

Si las clases son separables, la verosimilitud no tiene máximo: $\|\beta\|$ crece sin límite. El ajuste no converge.

La regularización de la segunda parte lo arregla.

3

Lo que esto aclara

LA REGLA GENERAL

Toda pérdida es una verosimilitud

SUPUESTO SOBRE $Y \mid X$	PÉRDIDA QUE RESULTA	CUÁNDO ES LA BUENA ELECCIÓN
Gaussiana de varianza constante	Error cuadrático	Respuesta continua, error simétrico y del mismo tamaño en todo el rango
Laplace	Error absoluto	Continua con atípicos; le importa la mediana, no la media
Bernoulli	Entropía cruzada binaria	Dos clases
Multinomial	Entropía cruzada	Más de dos clases, excluyentes
Poisson	Desviación de Poisson	Conteos $0, 1, 2, \ldots$ sin tope: fallas, eventos por unidad de tiempo

> Elegir la pérdida es elegir el modelo probabilístico. Si su respuesta es un conteo, usar error cuadrático afirma que los conteos son gaussianos.

Dos exigencias concretas

1. **Declare qué distribución supone para su variable de respuesta**, y por qué. Es una afirmación sobre el fenómeno, y por tanto discutible —que es lo que la hace valiosa.
2. **Verifique los supuestos que puede verificar.** Residuos contra predicción para la varianza constante; residuos contra tiempo o contra grupo para la independencia. Son dos gráficos y casi nadie los muestra.

EN UNA LÍNEA

Lo que hay que llevarse

> La función de pérdida no es una preferencia del investigador: es el supuesto probabilístico del modelo, escrito de otra manera. Elegirla por costumbre es adoptar un supuesto sin haberlo examinado.