Regularización

Clase 4, segunda parte · L_1, L_2 y su lectura bayesiana

Unidad 2 · Modelos supervisados y su fundamento

ERM puro se rompe en tres situaciones

ERM es *minimización del riesgo empírico*: quedarse con la hipótesis que menor error comete sobre los datos de entrenamiento, y nada más. Es lo que hemos hecho hasta aquí.

- **Más atributos que casos** ($p > n$): $X^\top X$ es singular y hay infinitas soluciones exactas.
- **Atributos colineales**: la solución existe pero es inestable —cambios mínimos en los datos mueven $\hat{\beta}$ enormemente.
- **Clases separables** en logística: la verosimilitud no tiene máximo y $\|\beta\| \to \infty$.

> Los tres son el mismo problema: **la muestra no basta para determinar** β. Y de la semana 2 sabemos qué hace falta entonces —un supuesto añadido.

1

Ridge, o L_2

Añadir un término que no viene de los datos

$$\hat{\beta}_{\text{ridge}} = \arg\min_{\beta} \underbrace{\sum_{i=1}^{n} \left(y_i - \beta^\top \tilde{x}_i\right)^2}_{\text{ajuste a los datos}} + \lambda \underbrace{\sum_{j=1}^{p} \beta_j^2}_{\text{complejidad}}$$

- $\lambda = 0$ devuelve mínimos cuadrados. $\lambda \to \infty$ lleva todos los coeficientes a cero.
- **El intercepto no se penaliza.** Penalizarlo haría que el modelo dependiera del origen de la escala de y.
- **Los atributos deben estandarizarse antes**, o la penalización castigará más a los medidos en unidades pequeñas.

Sigue habiendo forma cerrada

$$\hat{\beta}_{\text{ridge}} = \left(X^\top X + \lambda I\right)^{-1} X^\top y$$

Sumar λI hace la matriz invertible **siempre**, incluso con $p > n$ o con colinealidad perfecta.

Por qué. Una matriz no se puede invertir cuando alguno de sus valores propios es cero. Los de $X^\top X$ nunca son negativos, pero sí pueden ser cero —eso *es* la colinealidad—. Sumar λI desplaza todos los valores propios en $+\lambda$: los que valían 0 ahora valen $\lambda > 0$, y ya ninguno es cero.

Históricamente, ese fue el motivo por el que ridge se inventó: no para generalizar mejor, sino para poder resolver. Hoerl y Kennard (1970); la demostración, en Hastie et al. §3.4.1.

EL EFECTO

Sesgo a cambio de varianza

Lo que se pierde

$\hat{\beta}_{\text{ridge}}$ es **sesgado**: encoge los coeficientes hacia cero, y en promedio subestima su magnitud.

Lo que se gana

La varianza cae, y cae más de lo que sube el sesgo al cuadrado.

El error total baja.

> Es la semana 3, hecha una palanca: λ es el mando que reparte el error entre sesgo y varianza.

Existe siempre un $\lambda > 0$ que reduce el error esperado respecto de mínimos cuadrados. La demostración está en Hastie et al., §3.4.

2

Lasso, o L_1

Un cambio de exponente con una consecuencia cualitativa.

Valor absoluto en vez de cuadrado

$$\hat{\beta}_{\text{lasso}} = \arg\min_{\beta} \sum_{i=1}^{n} \left(y_i - \beta^\top \tilde{x}_i\right)^2 + \lambda \sum_{j=1}^{p} |\beta_j|$$

- No hay forma cerrada: se resuelve numéricamente, pero sigue siendo convexo.
- **Produce ceros exactos.** Con λ suficientemente grande, algunos coeficientes valen exactamente cero, no «casi cero».
- **Un coeficiente en cero es un atributo fuera del modelo:** si $\beta_j = 0$, x_j no interviene en ninguna predicción. Eso es *seleccionar atributos*.

Ridge también encoge, pero deja valores pequeños y no nulos: el atributo sigue en el modelo. El porqué de la diferencia, en la lámina siguiente.

La geometría de la restricción

Ambos problemas equivalen a minimizar el error dentro de una región:

L_2: una bola

$\sum_j \beta_j^2 \leq t$ es una esfera. Su superficie es lisa: las curvas de nivel del error la tocan, casi seguro, en un punto con todas las coordenadas distintas de cero.

L_1: un rombo

$\sum_j |\beta_j| \leq t$ tiene vértices sobre los ejes. Las curvas de nivel tocan la región en un vértice con alta probabilidad, y en un vértice hay coordenadas que valen cero.

> Los ceros de Lasso no son un efecto numérico: son las esquinas de la región de restricción.

No son intercambiables

	RIDGE (L_2)	LASSO (L_1)
Coeficientes nulos	No	Sí
Atributos correlacionados	Los encoge juntos	Elige uno casi al azar
Cuando muchos atributos importan poco	Mejor	Peor
Cuando pocos atributos importan mucho	Peor	Mejor
Interpretabilidad del modelo final	Baja: sobreviven todos	Alta: sobreviven pocos
Solución cerrada	Sí	No

> Elegir entre L_1 y L_2 es un supuesto sobre el problema: L_1 si pocos atributos importan mucho, L_2 si muchos importan poco.

Cuando hace falta lo de ambos

$$\lambda\left[\alpha\sum_j|\beta_j| + \tfrac{1-\alpha}{2}\sum_j\beta_j^2\right]$$

Selecciona como L_1 pero mantiene juntos los grupos de atributos correlacionados como L_2. El precio es un hiperparámetro más, y con él una oportunidad más de ajustar contra el conjunto de prueba.

3

La lectura bayesiana

De dónde sale, en realidad, el término de penalización.

Qué se cree antes y qué se cree después

$$p(\beta \mid X, y) \;=\; \frac{p(y \mid X, \beta)\, p(\beta)}{p(y \mid X)}$$

Es decir: **posterior** $\propto$ **verosimilitud** $\times$ **previa**.

- **Previa**, $p(\beta)$: lo que considero creíble sobre los coeficientes *antes* de ver los datos.
- **Verosimilitud**, $p(y \mid X, \beta)$: cuánto explican esos coeficientes los datos vistos.
- **Posterior**, $p(\beta \mid X, y)$: lo que creo sobre los coeficientes *después* de verlos.

El denominador no depende de β, así que para buscar el máximo se descarta: por eso basta el «$\propto$». Y atención a qué es lo incierto: aquí la posterior es **sobre** β, no sobre y. En la primera parte calculamos $\Pr(y = 1 \mid x)$, una posterior sobre la etiqueta; misma operación, otro objeto.

Máxima verosimilitud con una distribución previa

MAP es *máximo a posteriori*: el β que hace más creíble la posterior. Tomando logaritmo, el producto de la lámina anterior se convierte en una suma:

$$\hat{\beta}_{\text{MAP}} = \arg\max_{\beta} \log p(y \mid X, \beta) + \log p(\beta)$$

El primer término es la verosimilitud —**la pérdida**—. El segundo es la previa —**la penalización**—. Maximizar esa suma es exactamente minimizar «error $+ \lambda \times$ complejidad».

L_2 es gaussiana, L_1 es de Laplace

Previa gaussiana $N(0, \tau^2)$ → ridge

$$p(\beta_j) \propto e^{-\beta_j^2/2\tau^2}$$

$$-\log p(\beta) \propto \sum_j \beta_j^2$$

Redondeada en cero: «pequeños, ninguno cero exacto».

Previa de Laplace$(0, b)$ → lasso

$$p(\beta_j) \propto e^{-|\beta_j|/b}$$

$$-\log p(\beta) \propto \sum_j |\beta_j|$$

Pico en cero: «casi todos cero, unos pocos grandes».

Y λ resulta ser σ^2/τ^2: **el ruido de los datos sobre la dispersión que usted admite.**

Por qué Laplace y no otra. Cada penalización es el $-\log$ de una densidad: al tomar $-\log$, $e^{-|\beta|/b}$ deja $|\beta|$ y $e^{-\beta^2/2\tau^2}$ deja β^2. Buscar la previa de L_1 es buscar la campana que lleva un valor absoluto en el exponente, y esa es la de Laplace.

Tres cosas con esta lectura

1. **La regularización deja de ser un truco.** Es un supuesto declarado sobre la magnitud de los efectos, y por tanto discutible.
2. **La elección entre L_1 y L_2 se vuelve sustantiva**: ¿cree usted que unos pocos atributos lo explican todo, o que muchos aportan un poco?
3. **λ tiene interpretación**, y por tanto rangos razonables se pueden argumentar antes de buscarlos.

Y cómo no

Así no

✗ Probar varios λ y quedarse con el que da mejor error en el conjunto de prueba.

Después de veinte valores probados contra el test, el test es un conjunto de entrenamiento caro. El número reportado ya no es insesgado.

Así sí

✓ Validación cruzada **dentro del conjunto de entrenamiento**, con el test intacto hasta el final.

Validación cruzada: partir el entrenamiento en k trozos, ajustar k veces dejando uno fuera cada vez, y promediar el error de los k trozos excluidos.

Es el corolario 2 de la semana 1: el conjunto de prueba es un recurso que se gasta. El protocolo completo —incluida la validación anidada, para cuando además se comparan modelos— es la semana 7, y es el ítem 3 de la lista de cotejo del taller 2.

EN UNA LÍNEA

Lo que hay que llevarse

Al elegir la pérdida y la penalización usted afirma dos cosas sobre su fenómeno:

LO QUE USTED ESCRIBE	LO QUE ESTÁ AFIRMANDO
Error cuadrático	«Los errores son gaussianos y del mismo tamaño en todo el rango»
Entropía cruzada	«La etiqueta es una Bernoulli»
Penalización L_2 (ridge)	«Los coeficientes son pequeños, y ninguno es exactamente cero»
Penalización L_1 (lasso)	«Casi todos los coeficientes son cero; unos pocos son grandes»

> Ninguna es una preferencia técnica. Las cuatro son afirmaciones discutibles, y por eso van declaradas en la sección de métodos.