Regularización

Clase 4, segunda parte · L_1, L_2 y su lectura bayesiana

Unidad 2 · Modelos supervisados y su fundamento

Invalid Date

ERM puro se rompe en tres situaciones

- **Más atributos que casos** ($p > n$): $X^\top X$ es singular y hay infinitas soluciones exactas.
- **Atributos colineales**: la solución existe pero es inestable —cambios mínimos en los datos mueven $\hat{\beta}$ enormemente.
- **Clases separables** en logística: la verosimilitud no tiene máximo y $\|\beta\| \to \infty$.

> Los tres son el mismo problema: **la muestra no basta para determinar** β. Y de la semana 2 sabemos qué hace falta entonces —un supuesto añadido.

1

Ridge, o L_2

Añadir un término que no viene de los datos

$$\hat{\beta}_{\text{ridge}} = \arg\min_{\beta} \underbrace{\sum_{i=1}^{n} \left(y_i - \beta^\top \tilde{x}_i\right)^2}_{\text{ajuste a los datos}} + \lambda \underbrace{\sum_{j=1}^{p} \beta_j^2}_{\text{complejidad}}$$

- $\lambda = 0$ devuelve mínimos cuadrados. $\lambda \to \infty$ lleva todos los coeficientes a cero.
- **El intercepto no se penaliza.** Penalizarlo haría que el modelo dependiera del origen de la escala de y.
- **Los atributos deben estandarizarse antes**, o la penalización castigará más a los medidos en unidades pequeñas.

Sigue habiendo forma cerrada

$$\hat{\beta}_{\text{ridge}} = \left(X^\top X + \lambda I\right)^{-1} X^\top y$$

> Sumar λI hace la matriz invertible **siempre**, incluso con $p > n$ o con colinealidad perfecta.

El problema mal planteado deja de estarlo. Ese es, históricamente, el motivo por el que ridge se inventó: no para generalizar mejor, sino para poder resolver.

Sesgo a cambio de varianza

Lo que se pierde

$\hat{\beta}_{\text{ridge}}$ es **sesgado**: encoge los coeficientes hacia cero, y en promedio subestima su magnitud.

Lo que se gana

La varianza cae, y cae más de lo que sube el sesgo al cuadrado.

El error total baja.

> Es la semana 3, hecha una palanca: λ es el mando que reparte el error entre sesgo y varianza.

Existe siempre un $\lambda > 0$ que reduce el error esperado respecto de mínimos cuadrados. La demostración está en Hastie et al., §3.4.

2

Lasso, o L_1

Un cambio de exponente con una consecuencia cualitativa.

Valor absoluto en vez de cuadrado

$$\hat{\beta}_{\text{lasso}} = \arg\min_{\beta} \sum_{i=1}^{n} \left(y_i - \beta^\top \tilde{x}_i\right)^2 + \lambda \sum_{j=1}^{p} |\beta_j|$$

- No hay forma cerrada: se resuelve numéricamente, pero el problema sigue siendo convexo.
- **Produce ceros exactos.** Con λ suficientemente grande, algunos coeficientes valen exactamente cero, no «casi cero».
- Por tanto **selecciona atributos** además de encoger.

La geometría de la restricción

Ambos problemas equivalen a minimizar el error **dentro de una región**:

L_2: una bola

$\sum \beta_j^2 \leq t$ es una esfera. Su superficie es **lisa**: las curvas de nivel del error la tocan, casi seguro, en un punto con todas las coordenadas distintas de cero.

L_1: un rombo

$\sum |\beta_j| \leq t$ tiene **vértices sobre los ejes**. Las curvas de nivel tocan la región en un vértice con alta probabilidad, y en un vértice hay coordenadas que valen cero.

> Los ceros de Lasso no son un efecto numérico: son las esquinas de la región de restricción.

No son intercambiables

	RIDGE (L_2)	LASSO (L_1)
Coeficientes nulos	No	**Sí**
Atributos correlacionados	Los encoge **juntos**	Elige **uno** casi al azar
Cuando muchos atributos importan poco	Mejor	Peor
Cuando pocos atributos importan mucho	Peor	**Mejor**
Interpretabilidad del modelo final	Baja: sobreviven todos	Alta: sobreviven pocos
Solución cerrada	Sí	No

> La elección entre L_1 y L_2 es un **supuesto sobre la estructura del problema**: si usted cree que solo unos pocos atributos importan, eso es L_1.

Cuando hace falta lo de ambos

$$\lambda \left[\alpha \sum_j |\beta_j| + \frac{1-\alpha}{2} \sum_j \beta_j^2 \right]$$

Selecciona como L_1 pero mantiene juntos los grupos de atributos correlacionados como L_2. El precio es **un hiperparámetro más**, y con él una oportunidad más de ajustar contra el conjunto de prueba.

3

La lectura bayesiana

De dónde sale, en realidad, el término de penalización.

Máxima verosimilitud con una distribución previa

En la primera parte vimos que minimizar una pérdida es maximizar una verosimilitud. Si además ponemos una distribución previa sobre β y maximizamos la posterior:

$$\hat{\beta}_{\text{MAP}} = \arg\max_{\beta} \; \log p(y \mid X, \beta) + \log p(\beta)$$

El primer término es la verosimilitud —la pérdida. **El segundo es la penalización.**

L_2 es gaussiana, L_1 es de Laplace

Previa gaussiana → ridge

$$\beta_j \sim N(0, \tau^2)$$

$$-\log p(\beta) \propto \sum_j \beta_j^2$$

«Los coeficientes son pequeños, y ninguno es exactamente cero.»

Previa de Laplace → lasso

$$\beta_j \sim \text{Laplace}(0, b)$$

$$-\log p(\beta) \propto \sum_j |\beta_j|$$

Pico agudo en cero: «muchos coeficientes son exactamente cero».

> Y λ resulta ser σ^2/τ^2: la razón entre el ruido de los datos y la dispersión que usted admite en los coeficientes.

Tres cosas con esta lectura

1. **La regularización deja de ser un truco.** Es un supuesto declarado sobre la magnitud de los efectos, y por tanto discutible.
2. **La elección entre L_1 y L_2 se vuelve sustantiva**: ¿cree usted que unos pocos atributos lo explican todo, o que muchos aportan un poco?
3. **λ tiene interpretación**, y por tanto rangos razonables se pueden argumentar antes de buscarlos.

Y cómo no

Así no

✗ Probar varios λ y quedarse con el que da mejor error **en el conjunto de prueba**.

Después de veinte valores probados contra el test, el test es un conjunto de entrenamiento caro. **El número reportado ya no es insesgado.**

Así sí

✓ Validación cruzada **dentro del conjunto de entrenamiento**, con el test intacto hasta el final.

Y si además se comparan modelos, **validación anidada**.

Es el corolario 2 de la semana 1: el conjunto de prueba es un recurso que se gasta. El protocolo completo es la semana 7, y **es el ítem 3 de la lista de cotejo del taller 2**.

EN UNA LÍNEA

Lo que hay que llevarse

> Regularizar es añadir a los datos un supuesto sobre la magnitud de los efectos. La pérdida dice qué distribución tienen los errores; la penalización, qué distribución tienen los coeficientes. Ninguna de las dos es una preferencia técnica.

Semana 5: máquinas de soporte vectorial, árboles y ensambles. **Seminario 2** (Breiman) y **tutoría 1**: su problema de tesis formulado como tarea de aprendizaje. **Taller 2 esta semana.**