Márgenes, árboles y ensambles

Clase 5 · Tres sesgos inductivos distintos, y cómo se combinan

Unidad 2 · Modelos supervisados y su fundamento

Invalid Date

Un sesgo inductivo, y sus límites

La semana pasada trabajamos con modelos lineales: **efecto aditivo, pendiente constante**, y regularización para controlar la capacidad.

> Hoy vemos tres familias con sesgos inductivos completamente distintos, y una idea —el ensamble— que no es un modelo sino una forma de combinar cualquiera de ellos.

1

Márgenes y kernels

Entre todos los separadores, el más holgado

Si dos clases son separables por un hiperplano, hay **infinitos** hiperplanos que las separan. Todos tienen riesgo empírico cero.

> El sesgo inductivo de las SVM es preferir el que deja **el mayor margen** a ambos lados.

Es exactamente el segundo lugar del sesgo de la semana 2: un criterio de preferencia entre hipótesis que ajustan igual de bien.

Maximizar el margen es minimizar una norma

$$\min_{w,b} \ \frac{1}{2}\|w\|^2 \quad \text{sujeto a} \quad y_i\left(w^\top x_i + b\right) \ \geq \ 1 \ \ \forall i$$

- El margen vale $2/\|w\|$, así que maximizarlo es minimizar la norma.
- Solo importan los puntos que **tocan** el margen: los **vectores de soporte**.
- El resto de los datos podría borrarse sin cambiar la solución.

Cuando no hay separación perfecta

Se admiten violaciones $\xi_i \geq 0$, con un precio:

$$\min_{w,b,\xi} \ \frac{1}{2}\|w\|^2 + C\sum_{i=1}^{n} \xi_i$$

C grande

Violar el margen es caro. El modelo se ajusta a los datos. **Poca regularización.**

C pequeño

Violar es barato. Margen ancho y más errores tolerados. **Mucha regularización.**

Comparando con la semana pasada: C hace el papel de $1/\lambda$. Es el mismo mando de sesgo y varianza, con otro nombre.

Separar en un espacio en el que sí se puede

Si los datos no son separables en $\mathcal{X}$, se los lleva a un espacio de mayor dimensión $\phi(x)$ donde sí lo sean. **El truco** es que la solución solo depende de productos internos:

$$K(x, x') = \phi(x)^\top \phi(x')$$

y K se calcula **sin construir nunca** ϕ. Con el kernel gaussiano, ϕ vive en un espacio de dimensión infinita.

La pregunta que casi nadie hace

KERNEL	QUÉ AFIRMA SOBRE EL PROBLEMA
Lineal	La frontera es un hiperplano en los atributos originales
Polinomial de grado d	Importan las interacciones hasta orden d
Gaussiano (RBF)	**La similitud decae con la distancia euclídea**, a escala γ

> El kernel gaussiano supone que su noción de «parecido» es la distancia euclídea en los atributos que usted midió, escalados como usted los escaló.

2

Árboles

Partir el espacio, recursivamente

Un árbol elige un atributo y un umbral, parte los datos en dos, y repite en cada mitad. La predicción es constante dentro de cada región final.

Lo que hace bien

Interacciones y no linealidades, sin declararlas. Atributos en escalas distintas, sin estandarizar. Datos mixtos numéricos y categóricos.

Lo que supone

Que la frontera es **paralela a los ejes** y por regiones constantes.

Una frontera diagonal la aproxima con una escalera.

Varianza altísima

- El primer corte se elige mirando todos los datos. Cambiar unos pocos casos puede cambiar ese corte.
- Y si cambia el primer corte, **cambia todo el árbol de ahí para abajo**.
- Un árbol sin podar tiene riesgo empírico cero: es el memorizador de la semana 1.

> Sesgo bajo, varianza enorme. Es exactamente el perfil que un ensamble puede arreglar.

3

Ensambles

No son modelos: son formas de combinar modelos.

Promediar reduce la varianza, y solo la varianza

Entrene B modelos sobre B remuestreos con reemplazo de la muestra, y promedie.

Si los modelos fueran **independientes**, con varianza σ^2 cada uno:

$$\mathrm{Var}\left(\frac{1}{B}\sum_{b=1}^{B}\hat{h}_b\right) = \frac{\sigma^2}{B}$$

- El **sesgo no cambia**: el promedio de modelos insesgados sigue siendo insesgado.
- Por eso bagging conviene a modelos de sesgo bajo y varianza alta —**árboles profundos**.
- Y no conviene a modelos ya estables, como una regresión lineal regularizada.

El problema es la correlación

Con modelos correlacionados a nivel ρ, la varianza del promedio es

$$\rho\,\sigma^2 + \frac{1-\rho}{B}\,\sigma^2 \xrightarrow[B\to\infty]{} \rho\,\sigma^2$$

> Añadir árboles **no baja** de $\rho\sigma^2$. Para mejorar hay que reducir ρ.

La idea de Breiman: en cada corte, considerar solo un **subconjunto aleatorio de atributos**. Los árboles se parecen menos y el promedio mejora.

La estrategia opuesta

Bagging y bosques

Modelos **profundos** en paralelo, independientes.

Sesgo bajo, varianza alta → **se reduce la varianza**.

Potenciación de gradiente

Modelos **poco profundos** en secuencia; cada uno corrige el residuo del anterior.

Sesgo alto, varianza baja → **se reduce el sesgo**.

> Bagging y potenciación atacan términos distintos de la descomposición de la semana 3. Por eso no son intercambiables ni compiten por lo mismo.

Cómo se elige entre estas familias

1. **¿Qué forma tiene la frontera en su problema?** Suave y global → kernel. Escalonada, por umbrales de operación → árboles.
2. **¿Sus atributos son homogéneos o heterogéneos?** Distancias euclídeas exigen escalas comparables; los árboles no.
3. **¿Necesita explicar el modelo?** Un árbol pequeño se lee; un bosque de 500 no. Semana 13.
4. **¿Su problema es de sesgo o de varianza?** El diagnóstico de la semana 3 decide si conviene bagging o potenciación.

EN UNA LÍNEA

Lo que hay que llevarse

> Márgenes, particiones y promedios son tres sesgos inductivos distintos, no tres niveles de sofisticación. La pregunta nunca es cuál es mejor, sino cuál supone algo cierto sobre su problema.

Hoy: seminario 2 con los dos Breiman, y **tutoría 1** —su problema de tesis formulado como tarea de aprendizaje. **Semana 6:** métricas, calibración y taller 3.