Métricas

Clase 6, primera parte · Por qué la métrica por defecto casi siempre miente

Unidad 3 · Evaluación y diseño experimental

Invalid Date

Un clasificador con 99,2 % de acierto

Un sistema detecta fallas en 400 bombas. En tres años hubo 31 fallas sobre 14 400 bombas-mes. El modelo alcanza **99,2 % de acierto**.

> Prediga siempre «no falla» y obtendrá **99,8 %**. Sin modelo, sin datos, sin nada.

- El acierto de la clase mayoritaria es la referencia real, y casi nunca se reporta.
- Con 0,2 % de positivos, cualquier métrica global está dominada por la clase que no interesa.
- Y esto no es un caso extremo: es la situación normal en detección de fallas, diagnóstico y fraude.

1

La matriz de confusión

Todo lo demás son razones entre sus cuatro casillas.

Y ningún resumen las captura todas

	PREDICE POSITIVO	PREDICE NEGATIVO
Es positivo	Verdadero positivo (VP)	Falso negativo (**FN**)
Es negativo	Falso positivo (**FP**)	Verdadero negativo (VN)

> Un escalar es una proyección de cuatro números en uno. **Toda métrica escalar descarta información**, y la pregunta es cuál descarta.

Cada una responde una pregunta distinta

$$\text{Sensibilidad} = \frac{VP}{VP + FN} \qquad \text{Precisión} = \frac{VP}{VP + FP}$$

Sensibilidad (o exhaustividad)

«De todas las fallas que ocurrieron, ¿cuántas detecté?»

Denominador: **los positivos reales**. No depende de la prevalencia.

Precisión

«De todas las alertas que emití, ¿cuántas eran fallas?»

Denominador: **mis predicciones positivas**. Sí depende de la prevalencia.

La media que oculta el compromiso

$$F_1 = \frac{2 \cdot \text{Precisión} \cdot \text{Sensibilidad}}{\text{Precisión} + \text{Sensibilidad}}$$

- Es la media armónica: castiga que una de las dos sea baja.
- **Pondera precisión y sensibilidad por igual**, lo que es una afirmación sobre costos.
- Si en su problema una falla no detectada cuesta cien veces una alerta falsa, F_1 es la métrica equivocada.

Existe F_β, que pondera la sensibilidad β veces más. Usarla obliga a declarar β —y eso ya es un avance.

Casi ningún modelo predice clases

> Un clasificador produce un **puntaje continuo**. La clase aparece solo cuando usted fija un umbral.

- El umbral 0,5 no tiene nada de especial: es un valor por defecto de la biblioteca.
- Mover el umbral cambia toda la matriz de confusión, y por tanto todas las métricas.
- **El umbral es una decisión de operación**, no una propiedad del modelo.

2

Curvas

Si el umbral es una decisión, hay que evaluar sobre todos los umbrales.

Sensibilidad frente a tasa de falsos positivos

La curva recorre todos los umbrales, graficando

$$\text{TVP} = \frac{VP}{VP + FN} \qquad \text{contra} \qquad \text{TFP} = \frac{FP}{FP + VN}$$

- El área bajo la curva, **AUC-ROC**, es la probabilidad de que un positivo al azar reciba mayor puntaje que un negativo al azar.
- Ambos ejes tienen denominadores **dentro de una sola clase**.
- Por eso **la ROC no cambia con la prevalencia**. Y eso, que suena a virtud, es su trampa.

Con clases desbalanceadas, engaña

Con 0,2 % de positivos, el denominador de la TFP —los negativos— es enorme.

> Miles de falsos positivos apenas mueven la TFP, y la curva se ve espléndida mientras el sistema es inutilizable en operación.

Un ejemplo concreto: 14 400 casos, 31 positivos. Con TFP $= 0{,}05$ hay **718 falsos positivos** por 31 fallas reales. La ROC apenas lo nota; el jefe de mantenimiento sí.

La curva que sí lo nota

Grafica **precisión** contra **sensibilidad**, recorriendo los mismos umbrales.

Por qué sirve aquí

La precisión tiene FP en el denominador junto a VP, no junto a VN. Los falsos positivos **pesan**.

La línea base cambia

Un clasificador aleatorio tiene precisión constante igual a la **prevalencia**.

Con 0,2 % de positivos, la línea base es 0,002 —no 0,5.

Por eso el área bajo esta curva no es comparable entre conjuntos con prevalencias distintas, mientras que el AUC-ROC sí. Cada una tiene su trampa.

Qué usar, y cuándo

	AUC-ROC	AUC PRECISIÓN-EXHAUSTIVIDAD
Sensible a la prevalencia	No	**Sí**
Los falsos positivos pesan	Poco	**Mucho**
Comparable entre conjuntos distintos	**Sí**	No
Línea base	0,5 siempre	La prevalencia
Apropiada con desbalance fuerte	No	**Sí**

> Ninguna es «la buena». La pregunta es qué quiere afirmar, y la respuesta se escribe **antes** de ver los resultados.

3

Costos asimétricos

La parte que casi ninguna tesis hace, y la que decide si el sistema sirve.

La única métrica que responde a la pregunta real

Si c_{FN} es el costo de una falla no anticipada y c_{FP} el de una alerta falsa:

$$\text{Costo esperado} = c_{FN} \cdot FN + c_{FP} \cdot FP$$

- No hace falta conocer los costos exactos: **basta la razón** c_{FN} / c_{FP}.
- Esa razón la da el problema, no el algoritmo, y suele conocerse mejor de lo que se cree.
- Y determina el umbral óptimo, que rara vez es 0,5.

Sale de la razón de costos

Con probabilidades bien calibradas, el umbral que minimiza el costo esperado es

$$t^\star = \frac{c_{FP}}{c_{FP} + c_{FN}}$$

- Si una falla cuesta 100 veces una inspección: $t^\star = 1/101 \approx 0{,}01$.
- Es decir: **alertar ante un 1 % de probabilidad de falla**, no ante un 50 %.
- El umbral por defecto habría sido 50 veces demasiado conservador.

La fórmula supone que las probabilidades están calibradas. **Si no lo están, el umbral óptimo no significa nada** —y eso es la segunda parte de la clase.

Tres exigencias

1. **Reporte la matriz de confusión**, no solo el escalar. Permite recalcular cualquier métrica y es media tabla.
2. **Justifique la métrica por el problema**, y hágalo **antes** de ver los resultados. Elegirla después de mirarlos es seleccionar la fluctuación favorable —el sesgo optimista de la semana 1.
3. **Declare la razón de costos**, aunque sea aproximada, y derive de ahí el umbral. Si no puede, dígalo en las limitaciones.

Lo que hay que llevarse

> No existe la métrica correcta: existe la métrica que corresponde a la estructura de costos de su problema. Usar la de la biblioteca es afirmar que todos los errores cuestan lo mismo —y en su tesis casi nunca es cierto.