Métricas

Clase 6, primera parte · Por qué la métrica por defecto casi siempre miente

Unidad 3 · Evaluación y diseño experimental

LA PREGUNTA DE HOY

Un clasificador con 99,2 % de acierto

Un sistema detecta fallas en 400 bombas. En tres años hubo 31 fallas sobre 14 400 bombas-mes. El modelo alcanza **99,2 % de acierto**.

> Prediga siempre «no falla» y obtendrá **99,8 %**. Sin modelo, sin datos, sin nada.

- El acierto de la clase mayoritaria es la referencia real, y casi nunca se reporta.
- Con 0,2 % de positivos, cualquier métrica global está dominada por la clase que no interesa.
- Y esto no es un caso extremo: es la situación normal en detección de fallas, diagnóstico y fraude.

1

La matriz de confusión

Todo lo demás son razones entre sus cuatro casillas.

CUATRO CASILLAS

Y ningún resumen las captura todas

	PREDICE POSITIVO	PREDICE NEGATIVO
Es positivo	Verdadero positivo (VP)	Falso negativo (**FN**)
Es negativo	Falso positivo (**FP**)	Verdadero negativo (VN)

> Un escalar es una proyección de cuatro números en uno. **Toda métrica escalar descarta información**, y la pregunta es cuál descarta.

Cada una responde una pregunta distinta

$$\text{Sensibilidad} = \frac{VP}{VP + FN} \qquad \text{Precisión} = \frac{VP}{VP + FP}$$

Sensibilidad (o exhaustividad)

«De todas las fallas que ocurrieron, ¿cuántas detecté?»

Denominador: **los positivos reales**. No depende de la prevalencia.

Precisión

«De todas las alertas que emití, ¿cuántas eran fallas?»

Denominador: **mis predicciones positivas**. Sí depende de la prevalencia.

La media que oculta el compromiso

$$F_1 = \frac{2 \cdot \text{Precisión} \cdot \text{Sensibilidad}}{\text{Precisión} + \text{Sensibilidad}}$$

- Es la media armónica: castiga que una de las dos sea baja.
- **Pondera precisión y sensibilidad por igual**, lo que es una afirmación sobre costos.
- Si en su problema una falla no detectada cuesta cien veces una alerta falsa, F_1 es la métrica equivocada.

Existe F_β, que pondera la sensibilidad β veces más. Usarla obliga a declarar β —y eso ya es un avance.

Casi ningún modelo predice clases

> Un clasificador produce un **puntaje continuo**. La clase aparece solo cuando usted fija un umbral.

- El umbral 0,5 no tiene nada de especial: es un valor por defecto de la biblioteca.
- Mover el umbral cambia toda la matriz de confusión, y por tanto todas las métricas.
- El umbral es una **decisión de operación**, no una propiedad del modelo.

2

Curvas

Si el umbral es una decisión, hay que evaluar sobre todos los umbrales.

Sensibilidad frente a tasa de falsos positivos

La curva recorre todos los umbrales, graficando

$$\text{TVP} = \frac{VP}{VP + FN} \qquad \text{contra} \qquad \text{TFP} = \frac{FP}{FP + VN}$$

- El área bajo la curva, AUC-ROC, es la probabilidad de que un positivo al azar reciba mayor puntaje que un negativo al azar.
- Ambos ejes tienen denominadores **dentro de una sola clase**.
- Por eso la ROC no cambia con la prevalencia. Y eso, que suena a virtud, es su trampa.

Con clases desbalanceadas, engaña

Con 0,2 % de positivos, el denominador de la TFP —los negativos— es enorme.

> Miles de falsos positivos apenas mueven la TFP, y la curva se ve espléndida mientras el sistema es inutilizable en operación.

Un ejemplo concreto: 14 400 casos, 31 positivos. Con TFP $= 0{,}05$ hay 718 falsos positivos por 31 fallas reales. La ROC apenas lo nota; el jefe de mantenimiento sí.

La curva que sí lo nota

Grafica precisión contra sensibilidad, recorriendo los mismos umbrales.

Por qué sirve aquí

La precisión tiene FP en el denominador junto a VP, no junto a VN. Los falsos positivos pesan.

La línea base cambia

Un clasificador aleatorio tiene precisión constante igual a la prevalencia.

Con 0,2 % de positivos, la línea base es **0,002** —no 0,5.

Por eso el área bajo esta curva no es comparable entre conjuntos con prevalencias distintas, mientras que el AUC-ROC sí. Cada una tiene su trampa.

LA COMPARACIÓN

Qué usar, y cuándo

	AUC-ROC	AUC PRECISIÓN-EXHAUSTIVIDAD
Sensible a la prevalencia	No	Sí
Los falsos positivos pesan	Poco	Mucho
Comparable entre conjuntos distintos	Sí	No
Línea base	0,5 siempre	La prevalencia
Apropiada con desbalance fuerte	No	Sí

> Ninguna es «la buena». La pregunta es qué quiere afirmar, y la respuesta se escribe **antes** de ver los resultados.

3

Costos asimétricos

La parte que casi ninguna tesis hace, y la que decide si el sistema sirve.

La única métrica que responde a la pregunta real

Si c_{FN} es el costo de una falla no anticipada y c_{FP} el de una alerta falsa:

$$\text{Costo esperado} = c_{FN} \cdot FN + c_{FP} \cdot FP$$

- No hace falta conocer los costos exactos: **basta la razón c_{FN} / c_{FP}**.
- Esa razón la da el problema, no el algoritmo, y suele conocerse mejor de lo que se cree.
- Y determina el umbral óptimo, que rara vez es 0,5.

Sale de la razón de costos

Con probabilidades bien calibradas, el umbral que minimiza el costo esperado es

$$t^\star = \frac{c_{FP}}{c_{FP} + c_{FN}}$$

- Si una falla cuesta 100 veces una inspección: $t^\star = 1/101 \approx 0{,}01$.
- Es decir: alertar ante un **1 %** de probabilidad de falla, no ante un 50 %.
- El umbral por defecto habría sido 50 veces demasiado conservador.

La fórmula supone que las probabilidades están calibradas. Si no lo están, el umbral óptimo no significa nada —y eso es la segunda parte de la clase.

Tres exigencias

1. **Reporte la matriz de confusión**, no solo el escalar. Permite recalcular cualquier métrica y es media tabla.
2. **Justifique la métrica por el problema**, y hágalo antes de ver los resultados. Elegirla después de mirarlos es seleccionar la fluctuación favorable —el sesgo optimista de la semana 1.
3. **Declare la razón de costos**, aunque sea aproximada, y derive de ahí el umbral. Si no puede, dígalo en las limitaciones.

EN UNA LÍNEA

Lo que hay que llevarse

> No existe la métrica correcta: existe la métrica que corresponde a la estructura de costos de su problema. Usar la de la biblioteca es afirmar que todos los errores cuestan lo mismo —y en su tesis casi nunca es cierto.