Calibración de probabilidades

Clase 6, segunda parte · Cuando el 0,8 del modelo no significa 80 %

Unidad 3 · Evaluación y diseño experimental

Toda la primera parte descansa en algo

> El umbral óptimo $t^\star = c_{FP} / (c_{FP} + c_{FN})$ solo tiene sentido si el número que produce el modelo **es una probabilidad**.

¿Cuando su modelo dice 0,8, ocurre el evento el 80 % de las veces?

Para la mayoría de los modelos de uso común, la respuesta es **no**. Y casi ninguna tesis lo comprueba.

1

Qué es estar calibrado

DEFINICIÓN

Que el número signifique lo que dice

$$\Pr\big(y = 1 \mid \hat{p}(x) = q\big) = q \qquad \text{para todo } q \in [0, 1]$$

- Entre todos los casos a los que el modelo asigna 0,3, deben ser positivos aproximadamente el 30 %.
- Es una propiedad **distinta** de la capacidad de discriminar.
- Un modelo puede ordenar perfectamente y estar pésimamente calibrado.
- Y al revés: predecir siempre la prevalencia está perfectamente calibrado y es inútil.

Dos ejes independientes

	DISCRIMINA BIEN	DISCRIMINA MAL
Calibrado	Lo que se quiere	Predecir la prevalencia siempre
Descalibrado	Ordena bien, pero el número miente	Inútil

> El AUC-ROC mide solo el eje horizontal. Es invariante a cualquier transformación monótona de los puntajes, así que **no ve la calibración en absoluto**.

El diagrama de fiabilidad

Se agrupan las predicciones en intervalos, y en cada uno se compara la probabilidad media predicha con la frecuencia observada de positivos.

- La diagonal es la calibración perfecta.
- **Por debajo** de la diagonal: el modelo es **sobreconfiado** —promete más de lo que cumple.
- **Por encima**: subconfiado.

Es un gráfico de diez líneas de código y aparece en una minoría ínfima de los artículos publicados.

Dos números

$$\mathrm{ECE} = \sum_{m=1}^{M} \frac{|B_m|}{n} \left| \bar{y}(B_m) - \bar{p}(B_m) \right|$$

Error de calibración esperado: la discrepancia media entre lo prometido y lo observado, ponderada por cuántos casos caen en cada intervalo.

$$\mathrm{Brier} = \frac{1}{n} \sum_{i=1}^{n} \left(\hat{p}_i - y_i \right)^2$$

Puntaje de Brier: error cuadrático sobre probabilidades. Mezcla calibración y discriminación en un solo número —cómodo, y por eso mismo menos diagnóstico.

2

Por qué los modelos no están calibrados

LAS CAUSAS

Cada familia se descalibra a su manera

FAMILIA	CÓMO SE DESCALIBRA
Regresión logística	**Bien calibrada** por construcción: maximiza la verosimilitud Bernoulli
SVM	No produce probabilidades. `predict_proba` las fabrica *a posteriori*
Bosques aleatorios	Promedio de votos; **evita los extremos**, subconfiado cerca de 0 y de 1
Potenciación de gradiente	Suele quedar **sobreconfiada**
Redes profundas	**Muy sobreconfiadas**, y empeora con la capacidad

> Solo la primera fila está calibrada porque su función objetivo lo exige. En las demás, la calibración es un subproducto accidental.

El caso que más sorprende

Guo et al. (2017) documentaron que las redes modernas están **mucho más descalibradas** que las de los años noventa, y que la descalibración **crece con la capacidad**.

- Una red que acierta el 95 % puede declarar confianza media del 99 %.
- La causa: se sigue minimizando entropía cruzada mucho después de alcanzar error de entrenamiento cero.
- La entropía cruzada premia la confianza, y sin nada que la frene, la infla.

Es una de las lecturas de reserva del módulo, y es directamente pertinente si su proyecto usa modelos profundos.

Y cuándo se puede vivir sin ello

Importa mucho

- Umbral derivado de costos
- Combinar el modelo con otras fuentes
- Priorizar una lista de intervenciones
- Cualquier decisión que use el **valor**

Importa poco

- Solo se necesita **ordenar**
- El umbral se fija por capacidad operativa: «inspeccionar las 20 más riesgosas»

> Si su tesis deriva un umbral de una razón de costos —lo que la primera parte recomienda—, la calibración deja de ser opcional.

3

Cómo se arregla

Una función monótona sobre los puntajes

Se ajusta g tal que $g(\hat{p})$ esté calibrado. **Como g es monótona, el orden no cambia** y el AUC-ROC queda intacto: se arregla la calibración sin tocar la discriminación.

Platt (sigmoide)

$$g(p) = \frac{1}{1 + e^{-(ap+b)}}$$

Dos parámetros. Funciona con pocos datos; supone que la distorsión tiene forma de S.

Isotónica

Cualquier función monótona creciente, no paramétrica.

Más flexible, y **sobreajusta con pocos datos**. Regla práctica: desde unos mil casos.

EL ERROR QUE HAY QUE EVITAR

Recalibrar con los datos de entrenamiento

Así no

✗ Ajustar g con las predicciones sobre el conjunto con que se entrenó el modelo.

Ahí el modelo ya está sobreajustado: sus probabilidades son **artificialmente buenas**, y g aprende a corregir una distorsión que no existirá en producción.

Así sí

✓ Un conjunto de **calibración** separado, o validación cruzada.

`CalibratedClassifierCV` lo hace por pliegues. Y el conjunto de prueba sigue intacto hasta el final.

Es el corolario 2 de la semana 1 otra vez: la recalibración es una decisión, y toda decisión tomada sobre un conjunto lo gasta.

CUÁL ELEGIR

Regla práctica

SITUACIÓN	MÉTODO
Menos de ~1000 casos de calibración	**Platt**
Más de ~1000, distorsión de forma rara	**Isotónica**
Modelo ya calibrado (logística sin regularizar)	**Ninguno**, pero verifíquelo
Red profunda	**Escalado de temperatura**: un solo parámetro sobre los logits

> Y en todos los casos: **muestre el diagrama de fiabilidad antes y después.** Es la evidencia de que la recalibración hizo algo.

Tres exigencias

1. **Muestre el diagrama de fiabilidad** de su modelo final, y reporte ECE o Brier junto a la métrica de discriminación.
2. **Si deriva el umbral de costos, recalibre primero** —y hágalo con datos que no sean ni de entrenamiento ni de prueba.
3. **Si no calibra, dígalo**, y no interprete las probabilidades como tales. Un puntaje sirve para ordenar; solo eso.

EN UNA LÍNEA

Lo que hay que llevarse

> Discriminar y calibrar son cosas distintas, y las métricas habituales solo miden la primera. Si sus decisiones usan el valor de la probabilidad y no solo su orden, tiene que comprobar que ese valor significa algo.

Semana 7: protocolos de validación y fuga de información. **Seminario 3**: Kapoor y Narayanan (2023) y Demšar (2006) —la reseña 3 se entrega 48 h antes. **Taller 3 esta semana.**