Protocolos de validación y fuga de información

Clase 7 · Cómo se estima el riesgo cuando los datos son escasos

Unidad 3 · Evaluación y diseño experimental

DÓNDE QUEDAMOS

Seis semanas repitiendo lo mismo

- **Semana 1** — el conjunto de prueba es un recurso que se gasta.
- **Semana 4** — elegir λ contra el test lo gasta.
- **Semana 6** — recalibrar contra el test lo gasta.

> Hoy dejamos de advertirlo y damos el procedimiento. Y vemos por qué el problema no es de estudiantes: está en **294 artículos publicados**.

1

Los protocolos

Estimar $R_{\mathcal{D}}$ sin poder muestrear de $\mathcal{D}$

En la semana 1 generábamos casos nuevos a voluntad porque conocíamos $\mathcal{D}$. En un problema real es imposible.

> Todos los protocolos son variantes de una misma idea: apartar datos, no mirarlos, y usarlos una sola vez.

La diferencia entre ellos está en cuánto desperdician y cuánta varianza tiene la estimación que producen.

Partir una vez

Una partición: entrenamiento y prueba.

A favor

Simple, barato, y el único viable si entrenar cuesta días.

En contra

Varianza altísima con n pequeño: el resultado depende de qué partición le tocó.

Y desperdicia: el modelo se entrena con menos datos de los que hay.

> Un solo hold-out con pocos cientos de casos produce un número que otra semilla no reproduce. Es el corolario 3 de la semana 1.

Partir k veces y promediar

$$\hat{R}_{VC} = \frac{1}{k}\sum_{j=1}^{k} R_{S_j}\left(\hat{h}_{-j}\right)$$

- Se divide en k pliegues; cada uno hace de prueba una vez.
- Cada caso se usa para entrenar $k-1$ veces y para evaluar exactamente una.
- $k = 5$ o $k = 10$ son los valores habituales, y la razón es empírica, no teórica.
- **Estratificada** en clasificación: cada pliegue conserva la proporción de clases.

Porque una validación cruzada también es aleatoria

La partición en pliegues es una decisión al azar. Repetir la validación cruzada con varias semillas y promediar reduce esa varianza.

> Reportar «0,91 ± 0,03 sobre 10 repeticiones de validación cruzada estratificada de 5 pliegues, semillas 1–10» es lo que la semana 1 pedía. Esto es **cómo** se hace.

La desviación entre repeticiones **no es un intervalo de confianza**: los pliegues comparten datos y no son independientes. Es una medida de estabilidad, y hay que llamarla así.

Cuando además hay que elegir algo

Si se ajustan hiperparámetros, hacen falta dos niveles:

- **Bucle interno** — elige los hiperparámetros, usando solo datos de entrenamiento.
- **Bucle externo** — estima el riesgo del procedimiento completo, incluida esa elección.

> Lo que el bucle externo estima no es el riesgo de un modelo: es el riesgo de **su método de construir modelos**. Y eso es lo que se replica en otro laboratorio.

2

Fuga de información

Cuando el conjunto de prueba se contamina sin que nadie se dé cuenta.

DEFINICIÓN

Información que no debería estar

> Hay fuga cuando el procedimiento de estimación usa, directa o indirectamente, información que **no estará disponible en el momento de predecir**.

- Casi nunca es deshonestidad. Casi siempre es no advertir que un paso era una decisión.
- El síntoma es un resultado sospechosamente bueno.
- Y no aparece en el código como un error: **el código corre perfectamente**.

LA TAXONOMÍA

Kapoor y Narayanan (2023)

TIPO	EN QUÉ CONSISTE
Sin conjunto de prueba limpio	No hay partición, o se usó más de una vez
Preprocesamiento sobre todos los datos	Escalado, imputación, selección de atributos
Atributo ilegítimo	Un atributo que codifica la etiqueta o el futuro
Partición inválida	Los datos no son i.i.d. y la partición aleatoria los separa mal
Muestreo no representativo	La población de prueba no es la de aplicación

Documentado en **294 artículos publicados** de 17 disciplinas, con efectos que en varios casos anulaban por completo el resultado reportado.

EL CASO MÁS CARO

Seleccionar atributos antes de particionar

> Con 50 casos y 5 000 atributos **completamente aleatorios**, elegir los 100 más correlacionados con la etiqueta y luego validar cruzadamente da un acierto del **100 %**.

- No hay ninguna señal. La etiqueta es una moneda.
- La selección miró **todas** las etiquetas, incluidas las de los pliegues de validación.
- Los atributos elegidos son los que, por azar, se parecían a la etiqueta en esos casos.

El cuaderno de esta semana lo reproduce sobre 40 réplicas: en las 40 el procedimiento con fuga supera el 75 %, con mediana 1,000. El correcto da 0,540. Es el ejemplo de Hastie et al. §7.10.2, y sigue apareciendo en la literatura publicada.

LA REGLA

Todo lo que mira los datos va dentro del pliegue

Va dentro

- Escalado y normalización
- Imputación de faltantes
- Selección de atributos
- Reducción de dimensionalidad
- Remuestreo de clases
- Elección de hiperparámetros
- Recalibración

Puede ir fuera

- Recodificar unidades con una constante conocida
- Descartar atributos por razones del dominio, sin mirar la etiqueta
- Filtrar casos por un criterio anterior al estudio

> En la práctica: **use una tubería**. Lo que está dentro de un `Pipeline` se reestima en cada pliegue; lo que está fuera, no.

3

Cuando i.i.d. es falso

El supuesto que la semana 1 anunció como primer sospechoso.

SI SUS DATOS…	LA PARTICIÓN ALEATORIA FALLA PORQUE…	USE
Son una serie temporal	Entrena con el futuro para predecir el pasado	Partición temporal
Tienen medidas repetidas del mismo equipo o sujeto	El mismo sujeto queda a ambos lados	Partición por grupos
Vienen de varias plantas o centros	Se estima el desempeño dentro de centros conocidos	Dejar un centro fuera
Están agrupados espacialmente	La vecindad filtra información	Partición por bloques

> La pregunta que decide la partición es: **¿qué tendrá que predecir el modelo cuando se use?** La partición debe imitar esa situación.

Tres exigencias

1. **Declare el protocolo antes de correr el primer experimento.** Es el hito de la semana 9, y es la razón de que sea un hito.
2. **Justifique la partición por la estructura de sus datos**, no por costumbre. Si usó partición aleatoria, diga por qué es válida.
3. **Diga cuántas veces miró el conjunto de prueba.** Si fueron varias, el número que reporta no es insesgado, y hay que decirlo.

EN UNA LÍNEA

Lo que hay que llevarse

> Un protocolo de validación no mide el desempeño de un modelo: **imita las condiciones en que el modelo se usará**. Si la imitación es mala, el número es irrelevante por muy bien calculado que esté.

Hoy: seminario 3 con Kapoor y Narayanan (2023) y Demšar (2006). **Semana 8:** comparación estadística de algoritmos, y taller 4.