Protocolos de validación y fuga de información

Clase 7 · Cómo se estima el riesgo cuando los datos son escasos

Unidad 3 · Evaluación y diseño experimental

Invalid Date

Seis semanas repitiendo lo mismo

- **Semana 1** — el conjunto de prueba es un recurso que se gasta.
- **Semana 4** — elegir λ contra el test lo gasta.
- **Semana 6** — recalibrar contra el test lo gasta.

> Hoy dejamos de advertirlo y damos el procedimiento. Y vemos por qué el problema no es de estudiantes: está en **294 artículos publicados**.

1

Los protocolos

Estimar $R_{\mathcal{D}}$ sin poder muestrear de $\mathcal{D}$

En la semana 1 generábamos casos nuevos a voluntad porque conocíamos $\mathcal{D}$. **En un problema real es imposible.**

> Todos los protocolos son variantes de una misma idea: apartar datos, no mirarlos, y usarlos una sola vez.

La diferencia entre ellos está en cuánto desperdician y cuánta varianza tiene la estimación que producen.

Partir una vez

Una partición: entrenamiento y prueba.

A favor

Simple, barato, y el único viable si entrenar cuesta días.

En contra

Varianza altísima con n pequeño: el resultado depende de qué partición le tocó.

Y desperdicia: el modelo se entrena con menos datos de los que hay.

> Un solo *hold-out* con pocos cientos de casos produce un número que otra semilla no reproduce. Es el corolario 3 de la semana 1.

Partir k veces y promediar

Se divide en k pliegues; cada uno hace de prueba una vez.

$$\widehat{R}_{VC} = \frac{1}{k} \sum_{j=1}^{k} R_{S_j}\left(\hat{h}_{-j}\right)$$

- Cada caso se usa para entrenar $k-1$ veces y para evaluar exactamente una.
- $k = 5$ o $k = 10$ son los valores habituales, y la razón es empírica, no teórica.
- **Estratificada** en clasificación: cada pliegue conserva la proporción de clases.

Porque una validación cruzada también es aleatoria

La partición en pliegues es una decisión al azar. **Repetir** la validación cruzada con varias semillas y promediar reduce esa varianza.

> Reportar «0,91 ± 0,03 sobre 10 repeticiones de validación cruzada estratificada de 5 pliegues, semillas 1–10» es lo que la semana 1 pedía. Esto es cómo se hace.

La desviación entre repeticiones **no** es un intervalo de confianza: los pliegues comparten datos y no son independientes. Es una medida de estabilidad, y hay que llamarla así.

Cuando además hay que elegir algo

Si se ajustan hiperparámetros, hacen falta **dos niveles**:

- **Bucle interno** — elige los hiperparámetros, usando solo datos de entrenamiento.
- **Bucle externo** — estima el riesgo del **procedimiento completo**, incluida esa elección.

> Lo que el bucle externo estima no es el riesgo de un modelo: es el riesgo de **su método de construir modelos**. Y eso es lo que se replica en otro laboratorio.

2

Fuga de información

Cuando el conjunto de prueba se contamina sin que nadie se dé cuenta.

DEFINICIÓN

Información que no debería estar

> Hay fuga cuando el procedimiento de estimación usa, directa o indirectamente, información que no estará disponible en el momento de predecir.

- Casi nunca es deshonestidad. Casi siempre es **no advertir que un paso era una decisión**.
- El síntoma es un resultado sospechosamente bueno.
- Y no aparece en el código como un error: el código corre perfectamente.

Kapoor y Narayanan (2023)

TIPO	EN QUÉ CONSISTE
Sin conjunto de prueba limpio	No hay partición, o se usó más de una vez
Preprocesamiento sobre todos los datos	Escalado, imputación, selección de atributos
Atributo ilegítimo	Un atributo que codifica la etiqueta o el futuro
Partición inválida	Los datos no son i.i.d. y la partición aleatoria los separa mal
Muestreo no representativo	La población de prueba no es la de aplicación

Documentado en **294 artículos publicados** de 17 disciplinas, con efectos que en varios casos anulaban por completo el resultado reportado.

Seleccionar atributos antes de particionar

> Con 50 casos y 5 000 atributos **completamente aleatorios**, elegir los 100 más correlacionados con la etiqueta y luego validar cruzadamente da un acierto del **100 %**.

- No hay ninguna señal. La etiqueta es una moneda.
- La selección miró **todas** las etiquetas, incluidas las de los pliegues de validación.
- Los atributos elegidos son los que, por azar, se parecían a la etiqueta **en esos casos**.

El cuaderno de esta semana lo reproduce sobre 40 réplicas: **en las 40** el procedimiento con fuga supera el 75 %, con mediana 1,000. El correcto da 0,540. Es el ejemplo de Hastie et al. §7.10.2, y sigue apareciendo en la literatura publicada.

Todo lo que mira los datos va dentro del pliegue

Va dentro

- Escalado y normalización - Imputación de faltantes - Selección de atributos - Reducción de dimensionalidad - Remuestreo de clases - Elección de hiperparámetros - Recalibración

Puede ir fuera

- Recodificar unidades con una constante conocida - Descartar atributos por razones del dominio, sin mirar la etiqueta - Filtrar casos por un criterio anterior al estudio

> En la práctica: use una **tubería**. Lo que está dentro de un `Pipeline` se reestima en cada pliegue; lo que está fuera, no.

3

Cuando i.i.d. es falso

El supuesto que la semana 1 anunció como primer sospechoso.

SI SUS DATOS…	LA PARTICIÓN ALEATORIA FALLA PORQUE…	USE
Son una serie temporal	Entrena con el futuro para predecir el pasado	**Partición temporal**
Tienen medidas repetidas del mismo equipo o sujeto	El mismo sujeto queda a ambos lados	**Partición por grupos**
Vienen de varias plantas o centros	Se estima el desempeño *dentro* de centros conocidos	**Dejar un centro fuera**
Están agrupados espacialmente	La vecindad filtra información	**Partición por bloques**

> La pregunta que decide la partición es: **¿qué tendrá que predecir el modelo cuando se use?** La partición debe imitar esa situación.

Tres exigencias

1. **Declare el protocolo antes de correr el primer experimento.** Es el hito de la semana 9, y es la razón de que sea un hito.
2. **Justifique la partición por la estructura de sus datos**, no por costumbre. Si usó partición aleatoria, diga por qué es válida.
3. **Diga cuántas veces miró el conjunto de prueba.** Si fueron varias, el número que reporta no es insesgado, y hay que decirlo.

EN UNA LÍNEA

Lo que hay que llevarse

> Un protocolo de validación no mide el desempeño de un modelo: **imita las condiciones en que el modelo se usará.** Si la imitación es mala, el número es irrelevante por muy bien calculado que esté.

Hoy: seminario 3 con Kapoor y Narayanan (2023) y Demšar (2006). **Semana 8:** comparación estadística de algoritmos, y **taller 4**.