# Comparar dos algoritmos

Clase 8, primera parte · Por qué el promedio no basta

Unidad 3 · Evaluación y diseño experimental

Invalid Date

# Vuelve, y ahora la resolvemos

> «Nuestro modelo alcanza 0,91 de AUC, superando el 0,89 del método de referencia.»

- ¿Es 0,02 una diferencia, o es la muestra que le tocó?
- ¿Sobre cuántos conjuntos de datos vale ese «superando»?
- ¿Y con qué prueba se sostiene?

> Hoy y la próxima hora: cómo se responde eso sin engañarse.

1

# Qué se está comparando

Antes de elegir una prueba hay que saber cuál es la pregunta.

# Y se confunden todo el tiempo

1. **¿Es $A$ mejor que $B$ en *este* conjunto de datos?** Pregunta sobre una distribución concreta. Es la de una aplicación.
2. **¿Es $A$ mejor que $B$ en *esta clase* de problemas?** Pregunta sobre una población de conjuntos de datos. Es la de un artículo metodológico.
3. **¿Es $A$ mejor que $B$ en general?** No tiene respuesta: es No Free Lunch, semana 2.

> La prueba estadística que corresponde es distinta en (1) y en (2). Y la (3) no se responde con estadística sino con humildad.

# De dónde viene la diferencia observada

| FUENTE | QUÉ LA MUEVE |
|---|---|
| **Muestra** | Qué casos le tocaron. La más grande, y no se puede reducir con más cómputo |
| **Partición** | Qué pliegues salieron |
| **Inicialización** | Semilla del algoritmo, orden de los lotes |
| **Hiperparámetros** | El presupuesto de búsqueda que dio a cada método |

> Una comparación que fija todo salvo el algoritmo mide una diferencia que puede no sobrevivir a cambiar la semilla.

# La única comparación que aprovecha la información

> Compare siempre $A$ y $B$ **sobre los mismos datos y las mismas particiones.**

### No pareado

Se comparan dos distribuciones de desempeño. La variabilidad **entre conjuntos** domina y tapa la diferencia entre métodos.

### Pareado

Se analiza la **diferencia caso a caso**. La variabilidad común se cancela y queda solo lo que separa a los métodos.

# Lo que hace válida o inválida la comparación

- **Mismo protocolo de partición** para ambos métodos.
- **Mismo presupuesto de búsqueda de hiperparámetros**, declarado en número de configuraciones o en tiempo.
- **Mismo preprocesamiento**, salvo lo que el método exija por su naturaleza —y entonces se dice.

> Si su método recibió más cómputo que la referencia, usted midió el cómputo, no el método.

2

# La trampa de la validación cruzada

El error más común al comparar, y el menos evidente.

# Tengo 10 números por método, hago una prueba t

Validación cruzada de 10 pliegues da diez diferencias. Parece un caso de manual: prueba $t$ pareada sobre diez observaciones.

> Y está mal. La prueba $t$ supone observaciones **independientes**, y los pliegues no lo son.

# Los pliegues comparten datos

Dos pliegues cualesquiera de una validación cruzada de $k$ pliegues comparten $\frac{k-2}{k-1}$ de sus datos de entrenamiento.

$$k = 10 \implies \text{comparten el } 88{,}9\,\%$$

- Los modelos entrenados en dos pliegues son casi el mismo modelo.
- Sus errores están **correlacionados positivamente**.
- La varianza de la media se **subestima**, y el estadístico $t$ se **infla**.

# Cuánto miente, medido

Datos **sin ninguna señal**: ambos algoritmos valen 0,5 y la nula es verdadera por construcción. Una prueba válida al 5 % rechazaría el 5 % de las veces.

| ESQUEMA DE REMUESTREO | RECHAZA | INFLACIÓN |
|---|---|---|
| Validación cruzada, 10 pliegues | 7,0 % | 1,4× |
| Validación cruzada, 5 pliegues | 9,5 % | 1,9× |
| Submuestreo repetido, 30 veces | **40,5 %** | **8,1×** |
| Submuestreo repetido, 100 veces | **63,0 %** | **12,6×** |

> La validación cruzada infla poco. El **submuestreo repetido** es catastrófico, y **empeora al añadir repeticiones.**

# El número de remuestreos no es el $n$

- Cada remuestreo adicional **no aporta datos nuevos**: son los mismos casos, barajados otra vez.
- Pero sí reduce la varianza *aparente* del promedio de diferencias.
- La prueba $t$ divide por esa varianza y lee la reducción como **certeza**.

> Su $n$ estadístico son los **casos**, o los **conjuntos de datos**. Nunca las veces que barajó los mismos casos.

Es el resultado de Dietterich (1998) y de Nadeau y Bengio (2003). La corrección de Nadeau-Bengio ajusta la varianza por el solapamiento, y es lo mínimo exigible si va a usar submuestreo repetido.

# Tres salidas, en orden de preferencia

1. **Comparar sobre varios conjuntos de datos**, y hacer la prueba entre conjuntos. Es la segunda parte de la clase, y la salida limpia.
2. **Validación cruzada repetida corregida** —la corrección de Nadeau y Bengio ajusta la varianza por el solapamiento. Mejor que nada.
3. **Reportar la dispersión sin prueba**, diciendo explícitamente que no se hace inferencia. Honesto, y a veces lo único posible.

> Lo que **no** es aceptable es hacer la prueba $t$ ingenua y presentar el valor $p$ como si significara algo.

3

# Pruebas sobre un conjunto de datos

Cuando la pregunta es la número 1 y solo hay un conjunto.

# Para clasificación, sobre un conjunto de prueba

Se cuentan los casos en que los dos clasificadores **discrepan**:

| | $B$ ACIERTA | $B$ FALLA |
|---|---|---|
| **$A$ acierta** | $n_{00}$ | $n_{01}$ |
| **$A$ falla** | $n_{10}$ | $n_{11}$ |

$$\chi^2 = \frac{\left(|n_{01} - n_{10}| - 1\right)^2}{n_{01} + n_{10}}$$

- Solo usa las casillas de desacuerdo. Los aciertos y fallos comunes no informan.
- **No exige reentrenar**: se aplica sobre las predicciones de un único conjunto de prueba.
- Es la recomendación de Dietterich cuando entrenar es caro.

# Cuando hay varias medidas pareadas

Prueba de rangos con signo sobre las diferencias pareadas. **No supone normalidad**: usa el orden de las magnitudes, no sus valores.

### Por qué se prefiere a la $t$

Las diferencias de desempeño entre algoritmos rara vez son normales, y con pocas observaciones no se puede comprobar que lo sean.

### Qué necesita

Observaciones **independientes**. Sobre pliegues de validación cruzada tiene el mismo problema que la $t$.

Su lugar natural es **entre conjuntos de datos**.

# Lo que el valor $p$ no dice

> Con suficientes datos, **toda** diferencia es significativa. La pregunta relevante es si es **grande**.

- Reporte la **magnitud** de la diferencia en las unidades del problema.
- Y un intervalo para ella, no solo un valor $p$.
- Y pregúntese si esa magnitud cambia alguna decisión.

---

Una mejora de 0,003 en AUC puede ser altamente significativa y completamente irrelevante para el ingeniero que va a usar el sistema.

# Lo que hay que llevarse

> Comparar bien empieza antes de la prueba estadística: mismo protocolo, mismo presupuesto, diseño pareado. Y la prueba $t$ sobre pliegues de validación cruzada, que es lo que casi todo el mundo hace, no es válida.