Comparar dos algoritmos

Clase 8, primera parte · Por qué el promedio no basta

Unidad 3 · Evaluación y diseño experimental

Vuelve, y ahora la resolvemos

> «Nuestro modelo alcanza 0,91 de AUC, superando el 0,89 del método de referencia.»

- ¿Es 0,02 una diferencia, o es la muestra que le tocó?
- ¿Sobre cuántos conjuntos de datos vale ese «superando»?
- ¿Y con qué prueba se sostiene?

Hoy y la próxima hora: cómo se responde eso sin engañarse.

1

Qué se está comparando

Antes de elegir una prueba hay que saber cuál es la pregunta.

Y se confunden todo el tiempo

1. **¿Es A mejor que B en este conjunto de datos?** Pregunta sobre una distribución concreta. Es la de una aplicación.
2. **¿Es A mejor que B en esta clase de problemas?** Pregunta sobre una población de conjuntos de datos. Es la de un artículo metodológico.
3. **¿Es A mejor que B en general?** No tiene respuesta: es No Free Lunch, semana 2.

> La prueba estadística que corresponde es distinta en (1) y en (2). Y la (3) no se responde con estadística sino con humildad.

De dónde viene la diferencia observada

FUENTE	QUÉ LA MUEVE
Muestra	Qué casos le tocaron. La más grande, y no se puede reducir con más cómputo
Partición	Qué pliegues salieron
Inicialización	Semilla del algoritmo, orden de los lotes
Hiperparámetros	El presupuesto de búsqueda que dio a cada método

> Una comparación que fija todo salvo el algoritmo mide una diferencia que puede no sobrevivir a cambiar la semilla.

La única comparación que aprovecha la información

Compare siempre A y B **sobre los mismos datos y las mismas particiones**.

No pareado

Se comparan dos distribuciones de desempeño. La variabilidad entre conjuntos domina y tapa la diferencia entre métodos.

Pareado

Se analiza la diferencia caso a caso. La variabilidad común se cancela y queda solo lo que separa a los métodos.

Lo que hace válida o inválida la comparación

- Mismo protocolo de partición para ambos métodos.
- Mismo presupuesto de búsqueda de hiperparámetros, declarado en número de configuraciones o en tiempo.
- Mismo preprocesamiento, salvo lo que el método exija por su naturaleza —y entonces se dice.

> Si su método recibió más cómputo que la referencia, usted midió el cómputo, no el método.

2

La trampa de la validación cruzada

El error más común al comparar, y el menos evidente.

Tengo 10 números por método, hago una prueba t

Validación cruzada de 10 pliegues da diez diferencias. Parece un caso de manual: prueba t pareada sobre diez observaciones.

> Y está mal. La prueba t supone observaciones independientes, y los pliegues no lo son.

Los pliegues comparten datos

Dos pliegues cualesquiera de una validación cruzada de k pliegues comparten $\frac{k-2}{k-1}$ de sus datos de entrenamiento.

$$k = 10 \quad \Longrightarrow \quad \text{comparten el } 88{,}9\,\%$$

- Los modelos entrenados en dos pliegues son casi el mismo modelo.
- Sus errores están correlacionados positivamente.
- La varianza de la media se subestima, y el estadístico t se infla.

LA CONSECUENCIA

Cuánto miente, medido

Datos sin ninguna señal: ambos algoritmos valen 0,5 y la nula es verdadera por construcción. Una prueba válida al 5 % rechazaría el 5 % de las veces.

ESQUEMA DE REMUESTREO	RECHAZA	INFLACIÓN
Validación cruzada, 10 pliegues	7,0 %	1,4×
Validación cruzada, 5 pliegues	9,5 %	1,9×
Submuestreo repetido, 30 veces	40,5 %	8,1×
Submuestreo repetido, 100 veces	63,0 %	12,6×

> La validación cruzada infla poco. El submuestreo repetido es catastrófico, y empeora al añadir repeticiones.

El número de remuestreos no es el n

- Cada remuestreo adicional no aporta datos nuevos: son los mismos casos, barajados otra vez.
- Pero sí reduce la varianza aparente del promedio de diferencias.
- La prueba t divide por esa varianza y lee la reducción como certeza.

> Su n estadístico son los casos, o los conjuntos de datos. Nunca las veces que barajó los mismos casos.

Es el resultado de Dietterich (1998) y de Nadeau y Bengio (2003). La corrección de Nadeau-Bengio ajusta la varianza por el solapamiento, y es lo mínimo exigible si va a usar submuestreo repetido.

QUÉ HACER

Tres salidas, en orden de preferencia

1. **Comparar sobre varios conjuntos de datos**, y hacer la prueba entre conjuntos. Es la segunda parte de la clase, y la salida limpia.
2. **Validación cruzada repetida corregida** —la corrección de Nadeau y Bengio ajusta la varianza por el solapamiento. Mejor que nada.
3. **Reportar la dispersión sin prueba**, diciendo explícitamente que no se hace inferencia. Honesto, y a veces lo único posible.

> Lo que **no** es aceptable es hacer la prueba t ingenua y presentar el valor p como si significara algo.

3

Pruebas sobre un conjunto de datos

Cuando la pregunta es la número 1 y solo hay un conjunto.

Para clasificación, sobre un conjunto de prueba

Se cuentan los casos en que los dos clasificadores **discrepan**:

	B ACIERTA	B FALLA
A acierta	n_{00}	n_{01}
A falla	n_{10}	n_{11}

$$\chi^2 = \frac{\left(|n_{01} - n_{10}| - 1\right)^2}{n_{01} + n_{10}}$$

- Solo usa las casillas de desacuerdo. Los aciertos y fallos comunes no informan.
- **No exige reentrenar**: se aplica sobre las predicciones de un único conjunto de prueba.
- Es la recomendación de Dietterich cuando entrenar es caro.

Cuando hay varias medidas pareadas

Prueba de rangos con signo sobre las diferencias pareadas. **No supone normalidad**: usa el orden de las magnitudes, no sus valores.

Por qué se prefiere a la t

Las diferencias de desempeño entre algoritmos rara vez son normales, y con pocas observaciones no se puede comprobar que lo sean.

Qué necesita

Observaciones **independientes**. Sobre pliegues de validación cruzada tiene el mismo problema que la t.

Su lugar natural es **entre conjuntos de datos**.

Lo que el valor p no dice

> Con suficientes datos, **toda** diferencia es significativa. La pregunta relevante es si es **grande**.

- Reporte la **magnitud** de la diferencia en las unidades del problema.
- Y un intervalo para ella, no solo un valor p.
- Y pregúntese si esa magnitud cambia alguna decisión.

Una mejora de 0,003 en AUC puede ser altamente significativa y completamente irrelevante para el ingeniero que va a usar el sistema.

EN UNA LÍNEA

Lo que hay que llevarse

> Comparar bien empieza antes de la prueba estadística: mismo protocolo, mismo presupuesto, diseño pareado. Y la prueba t sobre pliegues de validación cruzada, que es lo que casi todo el mundo hace, no es válida.