Varios conjuntos, varios algoritmos

Clase 8, segunda parte · Friedman, comparaciones múltiples y tamaño del efecto

Unidad 3 · Evaluación y diseño experimental

Invalid Date

¿Es *A* mejor en *esta clase* de problemas?

La primera parte resolvió la comparación sobre un conjunto de datos. Pero una afirmación metodológica —«los árboles ganan en datos tabulares»— es sobre una **población de problemas**.

> La unidad de análisis deja de ser el caso y pasa a ser **el conjunto de datos**.

1

El procedimiento de Demšar

Demšar (2006), la lectura del seminario pasado. Es el estándar del área.

Una matriz de desempeño

N conjuntos de datos, k algoritmos. Cada celda es el desempeño estimado con un protocolo **idéntico** para todos.

	ALGORITMO 1	ALGORITMO 2	...	ALGORITMO K
Conjunto 1	x_{11}	x_{12}		x_{1k}
Conjunto 2	x_{21}	x_{22}		x_{2k}
...				
Conjunto N	x_{N1}	x_{N2}		x_{Nk}

- Cada fila es una observación pareada: los k algoritmos ven **los mismos datos**.
- N debería ser al menos **10**, y preferiblemente más de 20.

Y no los valores directamente

> Los desempeños **no son comparables entre conjuntos**: un 0,72 en un problema difícil puede ser mejor que un 0,95 en uno fácil.

Demšar propone reemplazar cada fila por los **rangos** de los algoritmos dentro de esa fila, y trabajar con el rango medio de cada algoritmo:

$$R_j = \frac{1}{N} \sum_{i=1}^{N} r_{ij}$$

- Promediar AUC entre conjuntos distintos **no significa nada**. Promediar rangos, sí.
- Los rangos son robustos a valores atípicos y no suponen ninguna distribución.

¿Difieren los algoritmos entre sí?

Hipótesis nula: **todos** los algoritmos son equivalentes, y los rangos medios son iguales.

$$\chi_F^2 = \frac{12N}{k(k+1)} \left[\sum_{j=1}^{k} R_j^2 - \frac{k(k+1)^2}{4} \right]$$

- Es el equivalente no paramétrico del ANOVA de medidas repetidas.
- Es una prueba **ómnibus**: dice que hay diferencias, no cuáles.
- Si no se rechaza, **se detiene ahí**. No se buscan pares.

Y si se rechaza, ¿qué pares difieren?

Dos algoritmos difieren si sus rangos medios se separan más que la **diferencia crítica**:

$$DC = q_\alpha \sqrt{\frac{k(k+1)}{6N}}$$

Se representa con un **diagrama de diferencia crítica**: los algoritmos en una recta por rango medio, y una barra que une los que no se distinguen.

Es la figura estándar del área, y comunica en un vistazo lo que una tabla de valores p no comunica en una página.

Bonferroni-Dunn

Cuando la pregunta es «¿mi método supera al de referencia?» y no «¿cuáles de todos difieren?», hay menos comparaciones y por tanto más potencia.

- Se comparan $k - 1$ pares en vez de $k(k-1)/2$.
- La corrección es menor y la prueba detecta diferencias más pequeñas.
- **Declararlo de antemano** es lo que lo hace legítimo.

2

Comparaciones múltiples

Por qué hace falta corregir, y qué pasa si no se hace.

Con suficientes pruebas, algo sale significativo

Si hace m pruebas independientes al nivel α y **no hay ninguna diferencia real**, la probabilidad de al menos un falso positivo es

$$1 - (1 - \alpha)^m$$

M PRUEBAS	PROBABILIDAD DE AL MENOS UN FALSO POSITIVO
1	5 %
5	23 %
10	**40 %**
20	**64 %**

Tres, y qué controlan

MÉTODO	CONTROLA	COMENTARIO
Bonferroni	Tasa de error familiar	Simple y muy conservador: divide α entre m
Holm	Tasa de error familiar	Secuencial, uniformemente más potente que Bonferroni. **Úselo en vez de él**
Benjamini-Hochberg	Tasa de falsos descubrimientos	Más potente; admite una proporción de falsos positivos entre los rechazos

> Holm domina a Bonferroni: misma garantía, más potencia. No hay razón para usar Bonferroni salvo la costumbre.

El grado de libertad del investigador

> La corrección solo cubre las pruebas que usted **declara**. No cubre las decisiones que tomó mirando los datos.

- Probar cinco métricas y reportar la que favorece.
- Probar tres particiones y quedarse con la mejor.
- Añadir conjuntos de datos hasta que la diferencia sea significativa.
- Excluir un conjunto «atípico» después de ver el resultado.

Ninguna corrección estadística arregla esto. Lo único que lo arregla es **declarar el análisis antes de hacerlo** —el hito de la semana 9.

3

Qué reportar

Sin esto, la comparación no es evaluable

1. **Cuántos conjuntos**, cuáles, y por qué esos.
2. **El protocolo**, idéntico para todos los métodos, con la partición justificada.
3. **El presupuesto de hiperparámetros** por método, en configuraciones o en tiempo.
4. **La tabla completa** de desempeños, no solo el resumen.
5. **La prueba usada y la corrección aplicada**, declaradas de antemano.
6. **El tamaño del efecto** en las unidades del problema, con su intervalo.

Y qué no

Se puede decir

«Sobre estos 18 conjuntos tabulares de tamaño medio, A obtiene un rango medio significativamente mejor que B (Friedman $p < 0{,}01$, Holm), con una diferencia mediana de 0,03 en AUC.»

No se puede decir

✗ «A es mejor que B.»

✗ «A es el estado del arte.»

✗ «B es equivalente a A» a partir de un resultado no significativo.

> La tercera es la más frecuente y la más falaz: **no rechazar la nula no es aceptarla.**

EN UNA LÍNEA

Lo que hay que llevarse

> Decir «mejor» exige una población de problemas declarada, un protocolo idéntico, un presupuesto igual, una prueba elegida de antemano y un tamaño del efecto que importe. Todo lo demás es una anécdota bien formateada.

Semana 9: ingeniería de atributos, PCA y aprendizaje de representaciones. **Tutoría 2** y el hito de **diseño experimental** —donde se declara, por escrito y antes de correr nada, todo lo que hoy vimos. **Taller 4 esta semana.**