Varios conjuntos, varios algoritmos

Clase 8, segunda parte · Friedman, comparaciones múltiples y tamaño del efecto

Unidad 3 · Evaluación y diseño experimental

¿Es A mejor en esta clase de problemas?

La primera parte resolvió la comparación sobre un conjunto de datos. Pero una afirmación metodológica —«los árboles ganan en datos tabulares»— es sobre una **población de problemas**.

> La unidad de análisis deja de ser el caso y pasa a ser el conjunto de datos.

1

El procedimiento de Demšar

Demšar (2006), la lectura del seminario pasado. Es el estándar del área.

Una matriz de desempeño

N conjuntos de datos, k algoritmos. Cada celda es el desempeño estimado con un protocolo **idéntico** para todos.

	ALGORITMO 1	ALGORITMO 2	...	ALGORITMO K
Conjunto 1	x_{11}	x_{12}		x_{1k}
Conjunto 2	x_{21}	x_{22}		x_{2k}
...				
Conjunto N	x_{N1}	x_{N2}		x_{Nk}

- Cada fila es una observación **pareada**: los k algoritmos ven los mismos datos.
- N debería ser al menos 10, y preferiblemente más de 20.

Y no los valores directamente

> Los desempeños no son comparables entre conjuntos: un 0,72 en un problema difícil puede ser mejor que un 0,95 en uno fácil.

Demšar propone reemplazar cada fila por los **rangos** de los algoritmos dentro de esa fila, y trabajar con el rango medio de cada algoritmo:

$$R_j = \frac{1}{N} \sum_{i=1}^{N} r_{ij}$$

- Promediar AUC entre conjuntos distintos no significa nada. Promediar rangos, sí.
- Los rangos son robustos a valores atípicos y no suponen ninguna distribución.

¿Difieren los algoritmos entre sí?

Hipótesis nula: todos los algoritmos son equivalentes, y los rangos medios son iguales.

$$\chi_F^2 = \frac{12N}{k(k+1)} \left[\sum_{j=1}^{k} R_j^2 - \frac{k(k+1)^2}{4} \right]$$

- Es el equivalente no paramétrico del ANOVA de medidas repetidas.
- Es una prueba **ómnibus**: dice que hay diferencias, no cuáles.
- **Si no se rechaza, se detiene ahí.** No se buscan pares.

Y si se rechaza, ¿qué pares difieren?

Dos algoritmos difieren si sus rangos medios se separan más que la diferencia crítica:

$$DC = q_\alpha \sqrt{\frac{k(k+1)}{6N}}$$

Se representa con un **diagrama de diferencia crítica**: los algoritmos en una recta por rango medio, y una barra que une los que no se distinguen.

Es la figura estándar del área, y comunica en un vistazo lo que una tabla de valores p no comunica en una página.

Bonferroni-Dunn

Cuando la pregunta es «¿mi método supera al de referencia?» y no «¿cuáles de todos difieren?», hay menos comparaciones y por tanto más potencia.

- Se comparan $k - 1$ pares en vez de $k(k-1)/2$.
- La corrección es menor y la prueba detecta diferencias más pequeñas.
- **Declararlo de antemano** es lo que lo hace legítimo.

2

Comparaciones múltiples

Por qué hace falta corregir, y qué pasa si no se hace.

Con suficientes pruebas, algo sale significativo

Si hace m pruebas independientes al nivel α y no hay ninguna diferencia real, la probabilidad de al menos un falso positivo es $1 - (1 - \alpha)^m$.

M PRUEBAS	PROBABILIDAD DE AL MENOS UN FALSO POSITIVO
1	5 %
5	23 %
10	40 %
20	64 %

Tres, y qué controlan

MÉTODO	CONTROLA	COMENTARIO
Bonferroni	Tasa de error familiar	Simple y muy conservador: divide α entre m
Holm	Tasa de error familiar	Secuencial, **uniformemente más potente** que Bonferroni. Úselo en vez de él
Benjamini-Hochberg	Tasa de falsos descubrimientos	Más potente; admite una proporción de falsos positivos entre los rechazos

> Holm domina a Bonferroni: misma garantía, más potencia. No hay razón para usar Bonferroni salvo la costumbre.

LO QUE NO SE CORRIGE

El grado de libertad del investigador

> La corrección solo cubre las pruebas que usted **declara**. No cubre las decisiones que tomó mirando los datos.

- Probar cinco métricas y reportar la que favorece.
- Probar tres particiones y quedarse con la mejor.
- Añadir conjuntos de datos hasta que la diferencia sea significativa.
- Excluir un conjunto «atípico» después de ver el resultado.

Ninguna corrección estadística arregla esto. Lo único que lo arregla es declarar el análisis antes de hacerlo —el hito de la semana 9.

3

Qué reportar

Sin esto, la comparación no es evaluable

1. Cuántos conjuntos, cuáles, y por qué esos.
2. El protocolo, idéntico para todos los métodos, con la partición justificada.
3. El presupuesto de hiperparámetros por método, en configuraciones o en tiempo.
4. La tabla completa de desempeños, no solo el resumen.
5. La prueba usada y la corrección aplicada, declaradas de antemano.
6. El tamaño del efecto en las unidades del problema, con su intervalo.

Y qué no

Se puede decir

«Sobre estos 18 conjuntos tabulares de tamaño medio, A obtiene un rango medio significativamente mejor que B (Friedman $p < 0{,}01$, Holm), con una diferencia mediana de 0,03 en AUC.»

No se puede decir

✗ «A es mejor que B.»

✗ «A es el estado del arte.»

✗ «B es equivalente a A» a partir de un resultado no significativo.

> La tercera es la más frecuente y la más falaz: **no rechazar la nula no es aceptarla.**

EN UNA LÍNEA

Lo que hay que llevarse

> Decir «mejor» exige una población de problemas declarada, un protocolo idéntico, un presupuesto igual, una prueba elegida de antemano y un tamaño del efecto que importe. Todo lo demás es una anécdota bien formateada.

Semana 9: ingeniería de atributos, PCA y aprendizaje de representaciones. **Tutoría 2** y el **hito de diseño experimental** —donde se declara, por escrito y antes de correr nada, todo lo que hoy vimos. **Taller 4 esta semana.**