Ingeniería de atributos

Clase 9, primera parte · La representación es parte del modelo

Unidad 4 · Representación, dimensionalidad y aprendizaje no supervisado

Invalid Date

Ocho semanas dando $\mathcal{X}$ por hecho

Desde la semana 1 escribimos $h : \mathcal{X} \to \mathcal{Y}$ como si $\mathcal{X}$ viniera dado.

> No viene dado. **Definir $\mathcal{X}$ es la primera decisión modeladora**, y suele importar más que la elección del algoritmo.

1

Qué es un atributo

Volvemos a las 400 bombas

Un sensor de vibración muestrea a 1 kHz. Tres años de operación. ¿Cuál es el vector x de una bomba-mes?

- ¿Las 2 600 millones de muestras crudas?
- ¿Media, desviación, máximo y mínimo del mes?
- ¿La energía en cinco bandas de frecuencia?
- ¿La tendencia respecto de los tres meses anteriores?

> Cada opción es una **hipótesis sobre qué información del fenómeno es pertinente**. Ninguna es neutral, y ninguna la elige el algoritmo.

Semana 2, otra vez

> Elegir la representación es elegir **qué distinciones puede hacer el modelo**. Lo que la representación no distingue, ningún algoritmo lo recupera.

Ejemplo

Con «hora del día» como número de 0 a 23, las 23:00 y las 00:00 están a 23 unidades de distancia.

Para un modelo basado en distancias, la medianoche es el punto más lejano del día anterior.

El remedio

Codificar como $\left(\sin \frac{2\pi t}{24}, \cos \frac{2\pi t}{24}\right)$: dos atributos que respetan la circularidad.

Es un supuesto declarado, no un truco.

Y cuál rinde más

TRABAJO	EN QUÉ CONSISTE	CUÁNTO RINDE
Construcción	Crear atributos con conocimiento del dominio	**Mucho**, y es lo menos automatizable
Transformación	Escalar, transformar, codificar	Depende del modelo
Selección	Descartar los que no aportan	Poco, y es donde está la fuga
Extracción	Combinar en menos dimensiones (PCA)	Segunda parte de la clase

> La primera fila es la que más mejora resultados en una tesis en ingeniería, y la única que exige saber del fenómeno.

2

Transformaciones y sus supuestos

Cuándo hace falta y cuándo no

FAMILIA	¿NECESITA ESCALADO?	POR QUÉ
Lineales regularizadas	**Sí**	La penalización castiga por magnitud del coeficiente
k-NN, SVM con kernel, agrupamiento	**Sí**	Se basan en distancias
Redes neuronales	**Sí**	Por la optimización, no por el modelo
Árboles y ensambles de árboles	**No**	Solo comparan umbrales dentro de cada atributo

> El escalado se estima **solo con entrenamiento**, y se aplica al resto. Es el ítem 4 de la lista de cotejo y la fuga más frecuente.

Tres opciones, tres supuestos

- **Uno-de-K** — ningún orden supuesto. Explota la dimensión con muchas categorías.
- **Ordinal** — supone un orden **y** que las distancias entre niveles son comparables. Rara vez cierto.
- **Por objetivo** — sustituye la categoría por un resumen de y. Potente, y **fuga de información si no se hace dentro del pliegue**.

> La tercera es la que más problemas causa en la práctica: usa la etiqueta, así que es entrenamiento, y va dentro del pliegue.

Cuando el supuesto del modelo no calza

- **Logaritmo** — para variables positivas con cola pesada. Convierte efectos multiplicativos en aditivos, que es lo que un modelo lineal puede representar.
- **Raíz** — para conteos, estabiliza la varianza cuando esta crece con la media.
- **Box-Cox y Yeo-Johnson** — buscan la potencia que más acerca a la normalidad, con un parámetro que hay que **ajustar dentro del pliegue**.

> Cada transformación es una afirmación sobre la forma del efecto. Aplicarla «porque mejora el resultado» y no declararla es ajustar mirando la respuesta.

La decisión que casi nadie declara

- **¿Por qué faltan?** Al azar, al azar dado lo observado, o **de forma informativa** —el sensor falla justo cuando la máquina está en un régimen extremo.
- Si faltan de forma informativa, **la falta es un atributo**, y borrar esas filas sesga el estudio.
- Toda imputación es un modelo, y se **ajusta dentro del pliegue**.

> Añadir un indicador binario de «faltaba» cuesta una columna y a veces es el atributo más informativo del conjunto.

3

Selección, y sus trampas

Y qué cuesta cada una

FAMILIA	CÓMO FUNCIONA	RIESGO
Filtro	Puntúa cada atributo contra y, sin modelo	Ignora interacciones; barato
Envoltura	Prueba subconjuntos entrenando el modelo	Caro, y **selecciona mirando el desempeño**
Incrustada	La selección es parte del ajuste (L_1)	La más limpia; semana 4

> Las tres miran la etiqueta. Las tres, por tanto, son **entrenamiento** y van dentro del pliegue.

Lo que ya vimos, y conviene no olvidar

> Seleccionar atributos antes de particionar da **acierto perfecto sobre ruido puro**: 50 casos, 5 000 atributos aleatorios, mediana 1,000 en 40 de 40 réplicas.

Es el cuaderno de la semana 7. Se repite aquí porque la selección de atributos es donde el error ocurre, y esta es la clase donde se habla de atributos.

Menos de lo que se cree

- Los modelos regularizados **ya manejan** atributos irrelevantes. Ridge los encoge; Lasso los anula.
- La selección previa añade una decisión más al procedimiento, y por tanto una oportunidad más de fuga.
- **Sí sirve** cuando el objetivo es interpretar, o cuando medir cada atributo cuesta dinero.

> Si su razón para seleccionar es «mejorar el desempeño», probablemente no la necesita. Si es «reducir el costo de medición» o «entender el fenómeno», sí.

Lo que hay que llevarse

> La representación no es preprocesamiento: es parte del modelo, y codifica qué distinciones puede hacer. Todo lo que mire la etiqueta —codificar, imputar, seleccionar— es entrenamiento, y va dentro del pliegue.