Reducción de dimensionalidad

Clase 9, segunda parte · PCA, y qué supone

Unidad 4 · Representación, dimensionalidad y aprendizaje no supervisado

Invalid Date

¿Se pueden combinar atributos sin mirar la etiqueta?

La primera parte terminó con un problema: construir atributos es caro y seleccionarlos rinde poco.

> ¿Y si en vez de **elegir** unos pocos atributos los **combinamos** todos en menos dimensiones?

Eso es la extracción de características. Su forma clásica es el análisis de componentes principales, y como todo lo demás en este módulo, **supone algo**.

1

Qué hace PCA

Buscar las direcciones de mayor variación

> Encontrar la dirección w_1 en la que los datos, proyectados, tienen **máxima varianza**. Después la siguiente, ortogonal a la primera. Y así.

$$w_1 = \arg\max_{\|w\|=1} \ \mathrm{Var}\big(Xw\big) = \arg\max_{\|w\|=1} \ w^\top \Sigma\, w$$

donde Σ es la matriz de covarianza de los datos **centrados**.

Es un problema de valores propios

Los w_j son los **vectores propios** de Σ, y los valores propios λ_j son la varianza capturada por cada dirección:

$$\Sigma w_j = \lambda_j w_j, \qquad \text{varianza explicada por } j = \frac{\lambda_j}{\sum_l \lambda_l}$$

- Las componentes son **ortogonales** entre sí y están ordenadas por λ decreciente.
- En la práctica se calcula por **descomposición en valores singulares** de X, que es más estable que formar Σ.

O PCA mide unidades, no estructura

> PCA maximiza varianza, y la varianza depende de las unidades. Una presión en pascales tiene varianza millones de veces mayor que la misma presión en bares.

Sin estandarizar

La primera componente apunta al atributo con la escala más grande. **No dice nada del fenómeno.**

Estandarizando

Todos los atributos aportan igual varianza de partida, y la estructura que emerge es de correlación, no de unidades.

Y la estandarización se estima **solo con entrenamiento**. PCA también: `fit` en entrenamiento, `transform` en el resto.

Tres criterios, ninguno definitivo

- **Varianza acumulada** — quedarse con las que sumen el 90 % o 95 %. Arbitrario, y depende de cuánto ruido haya.
- **Codo del gráfico de sedimentación** — visual, subjetivo, y a veces no hay codo.
- **Desempeño del modelo posterior** — el único criterio ligado al objetivo, y por tanto **hay que elegirlo dentro del pliegue**.

> Si elige el número de componentes mirando el conjunto de prueba, acaba de gastar el conjunto de prueba. El número de componentes es un hiperparámetro.

QUÉ SE GANA

Cuatro cosas, y no todas son la misma

- **Menos dimensiones** para modelos que sufren con muchas —y por tanto menos varianza, semana 3.
- **Descorrelación**: las componentes son ortogonales, lo que ayuda a los modelos lineales.
- **Visualización** en dos o tres dimensiones.
- **Compresión**, reconstruyendo con error controlado.

> Nótese lo que **no** está en la lista: interpretabilidad. Una componente es una combinación de todos los atributos originales.

2

Qué supone, y cuándo falla

Tres, y los tres son fuertes

1. **Que la estructura es lineal.** PCA solo encuentra subespacios planos. Una variedad curva la aproxima mal.
2. **Que varianza es igual a información.** Es el supuesto más fuerte y el menos examinado.
3. **Que las direcciones importantes son ortogonales.** En muchos fenómenos físicos los factores subyacentes están correlacionados.

Varianza no es información

> PCA no sabe qué es y. Puede descartar exactamente la dirección que discrimina, si esa dirección tiene poca varianza.

Un banco de 20 sensores con un **modo común** dominante —la carga del equipo— y la información en el **desequilibrio** entre grupos de sensores:

	VARIANZA EXPLICADA	ACIERTO
PCA, 1 componente	**97,0 %**	**0,535**
LDA, 1 componente (mira y)	—	**0,922**
Los 20 sensores originales	100 %	0,927

> Misma dimensionalidad, resultados opuestos. Y el criterio del «90 % de varianza acumulada» se queda **exactamente** con la componente inútil.

Y por eso es más seguro

Lo bueno

PCA **no mira la etiqueta**. Aplicarlo al conjunto completo no filtra información sobre y.

Lo que sigue estando mal

Sí filtra información sobre la **distribución de x** en el conjunto de prueba.

Y en un estudio que simula predecir sobre datos futuros, esa información tampoco estará disponible.

> La regla operativa no cambia: **ajuste PCA dentro del pliegue**. El riesgo es menor que con la selección supervisada, pero no es cero.

- Cuando usa **árboles o ensambles**: no sufren con dimensión alta, y las combinaciones lineales destruyen su capacidad de partir por umbrales interpretables.
- Cuando necesita **interpretar** qué atributos importan.
- Cuando los atributos son **ya pocos** y significativos.
- Cuando la estructura es claramente **no lineal**.

3

Más allá de lo lineal

Tres alternativas

MÉTODO	PARA QUÉ SIRVE	ADVERTENCIA
PCA con kernel	Subespacios no lineales	Hereda la elección del kernel, semana 5
t-SNE, UMAP	**Visualización** en 2D	**No** producen una transformación aplicable a datos nuevos de forma estable
Autocodificadores	Representación no lineal aprendida	Necesitan muchos datos; unidad 5

> t-SNE y UMAP son herramientas de **exploración visual**, no de preprocesamiento. Usar sus coordenadas como atributos de un modelo es un error frecuente.

Cuatro exigencias

1. **Declare su representación como decisión modeladora**, con la justificación del dominio. Es la primera sección del diseño experimental.
2. **Estandarice antes de PCA**, y ajuste ambos dentro del pliegue.
3. **Trate el número de componentes como hiperparámetro**, no como una constante elegida mirando la varianza acumulada.
4. **No use t-SNE como preprocesamiento.** Para explorar, sí; para alimentar un modelo, no.

EN UNA LÍNEA

Lo que hay que llevarse

> PCA encuentra las direcciones de mayor varianza, y varianza no es lo mismo que información sobre la etiqueta. Es una herramienta útil con un supuesto fuerte, y como todo en este módulo, hay que declararlo.

Esta semana: tutoría 2 y el hito de **diseño experimental** —el protocolo completo, por escrito, antes de correr el primer experimento. **Semana 10:** agrupamiento y el problema de su validación.