Agrupamiento

Clase 10, primera parte · Tres algoritmos, tres definiciones de «grupo»

Unidad 4 · Representación, dimensionalidad y aprendizaje no supervisado

Se acabaron las etiquetas

Nueve semanas de aprendizaje supervisado. Todo el aparato —riesgo, validación, métricas, comparación— descansaba en tener y.

> Sin y no hay riesgo que estimar, no hay conjunto de prueba que gastar, y no hay forma de decir que un resultado es correcto.

Y sin embargo hay que decidir: cuántos grupos, con qué algoritmo, con qué distancia. Todas esas decisiones siguen siendo sesgo inductivo, semana 2. **Solo que ahora nada las verifica.**

1

Qué es un grupo

No hay una definición

> No existe una definición de «grupo» independiente del algoritmo. Cada algoritmo define qué es un grupo por la forma en que lo busca.

IDEA DE GRUPO	ALGORITMO QUE LA ENCARNA
Puntos cercanos a un centro común	k-medias
Región de densidad alta separada por densidad baja	DBSCAN
Puntos que se van uniendo por proximidad	Jerárquico
Puntos generados por la misma componente de una mezcla	Mezcla de gaussianas

CONSECUENCIA

Todos los algoritmos siempre encuentran grupos

> k-medias con $k = 3$ devuelve tres grupos incluso sobre ruido uniforme. No puede hacer otra cosa: es lo que se le pidió.

- El algoritmo nunca dice «aquí no hay estructura».
- Los índices internos —silueta, Davies-Bouldin— tampoco lo dicen de forma fiable.
- **Encontrar grupos no es evidencia de que existan.**

El cuaderno de esta semana agrupa datos uniformes y mide qué opinan los índices internos.

2

Tres algoritmos, tres supuestos

Minimizar la dispersión dentro de los grupos

$$\min_{C_1,\ldots,C_k} \sum_{j=1}^{k} \sum_{x \in C_j} \|x - \mu_j\|^2$$

- El problema es NP-difícil; Lloyd es un algoritmo iterativo que converge a un óptimo **local**.
- Depende de la inicialización: `k-means++` y varios reinicios son obligatorios.
- Requiere fijar k de antemano.

Cuatro cosas, y ninguna es inocente

1. **Grupos esféricos**, porque usa distancia euclídea al centro.
2. **De tamaño similar**, porque minimiza la suma total de dispersiones.
3. **De varianza similar**, por la misma razón.
4. **Que k es conocido.**

> Con grupos alargados, de densidades muy distintas o anidados, k-medias falla —y falla **en silencio**, devolviendo una partición perfectamente plausible.

No hay que fijar k de antemano

Se construye un árbol uniendo iterativamente lo más cercano. El dendrograma se corta a la altura que se quiera.

CRITERIO DE ENLACE	QUÉ TIENDE A PRODUCIR
Simple (mínimo)	Grupos alargados, encadenados
Completo (máximo)	Grupos compactos y de tamaño similar
Promedio	Intermedio
Ward	Similar a k-medias: minimiza el aumento de varianza

> El criterio de enlace **es** el supuesto sobre la forma de los grupos. Cambiarlo cambia el resultado por completo.

Densidad, y la posibilidad de decir «esto es ruido»

Dos parámetros: un radio ε y un mínimo de vecinos. Un punto es **núcleo** si tiene al menos ese número de vecinos dentro de ε.

Lo que gana

- No hay que fijar k
- Encuentra grupos de forma arbitraria
- Marca puntos como **ruido**: es el único que admite «este caso no pertenece a ningún grupo»

Lo que cuesta

- ε es difícil de elegir y muy sensible
- Falla con grupos de densidades muy distintas
- En dimensión alta, las distancias se concentran y ε deja de discriminar

COMPARACIÓN

Cuál elegir, y por qué

	K-MEDIAS	JERÁRQUICO	DBSCAN
Hay que fijar k	Sí	No (se corta después)	No
Forma de los grupos	Esférica	Según el enlace	Arbitraria
Tolera densidades distintas	Sí	Sí	No
Marca ruido	No	No	Sí
Escala a n grande	Sí	No	Intermedio
Determinista	No	Sí	Sí

> La pregunta no es cuál es mejor sino **cuál define «grupo» como usted lo define** en su problema.

3

La distancia

La decisión que precede a todas las demás.

Elegir la distancia es elegir el resultado

> Todos estos métodos operan sobre una noción de «parecido». Cambiarla cambia los grupos, con el mismo algoritmo y los mismos datos.

- **Euclídea** — supone atributos comparables y de igual importancia. Exige estandarizar.
- **Manhattan** — menos sensible a valores extremos en una coordenada.
- **Coseno** — ignora la magnitud, mide solo la dirección. Para texto o perfiles.
- **Distancias con pesos** — cuando el dominio dice que unos atributos importan más.

Donde las distancias dejan de significar

En dimensión alta, la distancia entre el punto más cercano y el más lejano tiende a igualarse:

$$\frac{d_{\max} - d_{\min}}{d_{\min}} \longrightarrow 0 \qquad \text{cuando } p \to \infty$$

> Si todos los puntos están a la misma distancia de todos, la noción de vecindad se vacía —y con ella el agrupamiento.

De ahí que reducir dimensionalidad antes de agrupar sea habitual. Con la advertencia de la semana pasada: PCA puede descartar justamente la dirección que separa los grupos.

EN UNA LÍNEA

Lo que hay que llevarse

> No hay una definición de «grupo»: cada algoritmo define la suya al buscarla. Y todos encuentran grupos siempre, incluso donde no los hay. Elegir algoritmo y distancia es declarar qué se considera un grupo en su problema.