Validar sin etiquetas

Clase 10, segunda parte · Por qué el índice interno no zanja la discusión

Unidad 4 · Representación, dimensionalidad y aprendizaje no supervisado

Ya tiene sus grupos. ¿Y ahora?

La primera parte terminó con una afirmación incómoda: todos los algoritmos encuentran grupos siempre, incluso sobre ruido.

> Entonces, ¿cómo se distingue un agrupamiento que **descubre** algo de uno que **inventa** algo?

Sin etiquetas no hay riesgo esperado que estimar. Todo el aparato de las unidades 1 y 3 queda fuera de juego.

1

Índices internos y su límite

El índice interno más usado

Para cada punto i, con $a(i)$ la distancia media a su propio grupo y $b(i)$ la distancia media al grupo vecino más cercano:

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i),\, b(i)\}} \quad \in \quad [-1, 1]$$

- Cerca de 1: el punto está mucho más cerca de los suyos que de los otros.
- Cerca de 0: está en la frontera.
- Negativo: probablemente está en el grupo equivocado.

Compacidad y separación, nada más

> Los índices internos miden si los grupos son compactos y separados **según la misma distancia con que se construyeron**. Es casi una tautología.

- La silueta favorece a k-medias, porque ambos usan distancia euclídea al centro.
- Un agrupamiento de DBSCAN, con grupos alargados, obtiene silueta baja aunque sea correcto.
- Comparar algoritmos por silueta es comparar cuál se parece más a k-medias.

EL EXPERIMENTO DECISIVO

Índices sobre datos sin ninguna estructura

Se generan puntos uniformes en un cuadrado —sin grupos de ningún tipo— y se aplica k-medias con $k = 2, 3, \ldots, 10$.

> La silueta produce un máximo, y ese máximo señala un «número óptimo de grupos» que no existe.

	SILUETA OBSERVADA	MÁXIMO DEL NULO	¿SUPERA?
Cuatro grupos reales	0,737	0,414	sí
Uniforme, sin estructura	0,441	0,467	no

Su valor absoluto no es interpretable; comparado con una referencia nula, sí. El cuaderno de esta semana lo mide.

> Un índice interno nunca responde «¿hay grupos?». Solo responde «dado que voy a partir en k grupos con esta distancia, ¿qué k da la partición más compacta?».

- Reportar «silueta = 0,42» sin referencia no informa de nada.
- Reportar «silueta = 0,42, frente a 0,38 sobre datos permutados» sí informa.

2

Qué sí funciona

Cuatro cosas, y ninguna es un índice.

Comparar contra la ausencia de estructura

> La **estadística de brecha**: compare la dispersión de su agrupamiento con la que obtendría sobre datos sin estructura con el mismo rango y la misma dimensión.

$$\text{Brecha}(k) = \mathbb{E}_{\text{nulo}}[\log W_k] - \log W_k$$

- El nulo se genera por permutación de columnas, o uniforme en el envolvente convexo.
- Si la brecha no crece con k, no hay evidencia de estructura.
- Es lo más cercano a una prueba de hipótesis que existe aquí.

Sirve para refutar, no para confirmar

Se agrupa varias veces sobre submuestras del 80 % y se mide cuánto coinciden las particiones, con el índice de Rand ajustado.

Estabilidad baja

Los grupos no son fiables. Es una **refutación válida**.

Estabilidad alta

No dice nada. Puede ser estructura, o puede ser geometría del algoritmo.

> Sobre un rectángulo uniforme, k-medias con $k = 2$ siempre parte por la mitad del lado más largo. Es determinista, y por tanto perfectamente estable —sin que haya ningún grupo.

Es el resultado de Ben-David, von Luxburg y Pál (2006). El cuaderno lo comprueba en todo el rango de k: sobre datos uniformes, la estabilidad es casi idéntica a la de datos con estructura.

Cuando hay algo con qué contrastar

Aunque no tenga etiquetas de grupo, casi siempre tiene alguna variable que **no usó para agrupar**.

- ¿Los grupos difieren en esa variable de forma sustantiva?
- ¿Corresponden a algo que el experto del dominio reconoce?
- ¿Predicen algo que importa —costo, falla, duración?

> Esta es la validación que convence a un revisor, y la única que conecta el agrupamiento con una consecuencia.

En qué creer, y en qué orden

1. **Utilidad para una tarea posterior** — los grupos mejoran una decisión medible.
2. **Validación externa** — corresponden a algo que no se usó para construirlos.
3. **Referencia nula** — hay más estructura que en datos permutados. Es lo único que responde «¿hay grupos?».
4. **Estabilidad** — solo sirve para refutar: baja refuta, alta no confirma.
5. **Índice interno solo** — no distingue nada, y es lo único que casi todos reportan.

3

Detección de anomalías

El mismo problema, con una asimetría que ayuda.

No es clasificación desbalanceada

Clasificación desbalanceada

Hay ejemplos de **ambas** clases, aunque pocos de una. Se puede aprender la clase rara.

Detección de anomalías

Se modela **solo lo normal**, y se marca lo que no encaja.

Se usa cuando las anomalías son escasas, heterogéneas o aún no observadas.

> Si tiene suficientes ejemplos de fallas y son parecidas entre sí, use clasificación supervisada. La detección de anomalías es para cuando no puede.

Y qué supone cada uno

MÉTODO	QUÉ CONSIDERA ANÓMALO
Bosque de aislamiento	Lo que se aísla con pocos cortes aleatorios
Factor de atipicidad local	Lo que tiene densidad menor que sus vecinos
SVM de una clase	Lo que cae fuera de la frontera que encierra los datos
Error de reconstrucción	Lo que un autocodificador o PCA reconstruye mal

> Los cuatro definen «anómalo» de forma distinta, y por tanto marcan casos distintos. Es la primera parte de la clase otra vez.

El problema real

> Sin etiquetas de anomalía no hay forma de estimar la tasa de falsos negativos: **no se sabe qué se dejó pasar**.

- Lo que sí se puede: revisar manualmente las m más anómalas y medir la precisión@m.
- Y declarar explícitamente que la sensibilidad es desconocida.
- Con el tiempo, las anomalías confirmadas construyen un conjunto etiquetado, y entonces se pasa a supervisado.

EN UNA LÍNEA

Lo que hay que llevarse

> Sin etiquetas, ningún índice puede decirle si sus grupos son reales. Lo único que convence es que sirvan para algo, que correspondan a algo que no usó, y que se reproduzcan. El índice interno es lo más débil y lo que casi todos reportan.

Esta semana: taller 5 —validación de agrupamientos. **Semana 11:** perceptrón multicapa, retropropagación y **seminario 4** con Grinsztajn, Oyallon y Varoquaux (2022). La reseña 4 se entrega 48 h antes.