Perceptrón multicapa y retropropagación

Clase 11 · Qué cambia, qué no, y qué se supone

Unidad 5 · Fundamentos operativos del aprendizaje profundo

Nada de lo anterior deja de valer

> Una red neuronal es una familia $\mathcal{H}$ más, con su sesgo inductivo, su capacidad y su compromiso sesgo-varianza.

- Se entrena minimizando riesgo empírico regularizado: semanas 1 y 4.
- Su pérdida sale de una verosimilitud: semana 4.
- Se evalúa con los mismos protocolos: semana 7.
- Y se compara con las mismas pruebas: semana 8.

1

La arquitectura

Transformación afín más no linealidad

$$h^{(l)} = \sigma\left(W^{(l)} h^{(l-1)} + b^{(l)}\right)$$

- Sin σ, componer capas da otra transformación afín: toda la red colapsa a una regresión lineal.
- La no linealidad es lo único que aporta capacidad al apilar.
- La capa final no lleva σ: produce los *logits*, y sobre ellos va la verosimilitud de la semana 4.

Y por qué ReLU desplazó a las demás

ACTIVACIÓN	PROBLEMA
Sigmoide, tangente hiperbólica	Saturan: el gradiente se desvanece en las capas profundas
ReLU $\max(0, z)$	No satura en el lado positivo; barata; el gradiente es 0 o 1
Variantes (Leaky, GELU)	Mitigan las «neuronas muertas» de ReLU

> El cambio a ReLU no fue un refinamiento teórico: fue lo que hizo entrenables las redes profundas.

El teorema que se cita mal

> Una red con una capa oculta y suficientes unidades puede aproximar cualquier función continua en un compacto con la precisión que se quiera.

- Dice que **existe** tal red. No dice cuántas unidades, ni que se pueda encontrar.
- No dice nada sobre generalización: es representación, no aprendizaje.
- Es el término de **aproximación** de la semana 1, y solo ese.

Por qué apilar en vez de ensanchar

> Existen funciones que una red profunda representa con un número de unidades **exponencialmente menor** que una red poco profunda.

Y hay un argumento más útil para la práctica: la profundidad impone un **sesgo inductivo de composición** —características simples que se combinan en otras más complejas.

- En imágenes: bordes → texturas → partes → objetos. El sesgo es correcto.
- En datos tabulares heterogéneos, esa jerarquía composicional a menudo no existe.

2

Cómo se entrena

Es la regla de la cadena, organizada

$$\frac{\partial L}{\partial W^{(l)}} = \underbrace{\frac{\partial L}{\partial h^{(l)}}}_{\text{viene de arriba}} \cdot \frac{\partial h^{(l)}}{\partial W^{(l)}}$$

- Se propaga hacia atrás el gradiente respecto de las activaciones, capa por capa.
- Reutiliza los cálculos: el costo es del mismo orden que una pasada hacia adelante.
- **No es un algoritmo de aprendizaje**: es un método eficiente de derivar.

Y por qué el ruido ayuda

Se actualiza con el gradiente de un lote pequeño, no de todos los datos:

$$\theta_{t+1} = \theta_t - \eta \nabla_\theta L_{\text{lote}}(\theta_t)$$

- Cada paso es barato, y con datos grandes es la única opción viable.
- El ruido del muestreo ayuda a escapar de mínimos locales pobres.
- Y sesga la solución hacia mínimos «anchos», que generalizan mejor. Es **regularización implícita**.

> Ese sesgo del optimizador es el tercer lugar del sesgo inductivo de la semana 2, y en redes es determinante.

En orden

1. **Tasa de aprendizaje η.** El más sensible con diferencia. Demasiado alta diverge; demasiado baja no llega.
2. **Tamaño del lote.** Interactúa con η: lotes grandes suelen exigir tasas mayores.
3. **Arquitectura**: profundidad y anchura.
4. **Regularización**: decaimiento de pesos, abandono, detención temprana.

> Y todos se eligen con validación **dentro del entrenamiento**. Cada uno es otra oportunidad de gastar el conjunto de prueba —semana 7.

Cuatro mecanismos, y qué son en realidad

MECANISMO	QUÉ ES
Decaimiento de pesos	Penalización L_2 de la semana 4, con otro nombre
Abandono (*dropout*)	Anula unidades al azar; se aproxima a un ensamble, semana 5
Detención temprana	Se para antes de converger. Es un hiperparámetro de capacidad
Normalización por lotes	Estabiliza la optimización, y de paso regulariza

> Ninguno es nuevo. Son las ideas de las unidades 2 y 3, aplicadas a otra familia.

Qué mirar mientras entrena

- Ambas curvas bajan y se estabilizan → puede convenir **más capacidad**.
- La de entrenamiento baja y la de validación sube → **sobreajuste**; regularice o detenga antes.
- Ninguna baja → revise **la tasa de aprendizaje** antes que la arquitectura.
- La de entrenamiento oscila violentamente → tasa demasiado alta, o lote demasiado pequeño.

> La curva de aprendizaje es el diagnóstico de sesgo y varianza de la semana 3, observado durante el ajuste.

3

Qué supone, y cuándo no conviene

Suavidad y composición

> Una red con activaciones continuas y entrenada por gradiente prefiere funciones **suaves**. Y la profundidad presupone que las características se **componen** jerárquicamente.

Donde acierta

Imágenes, audio, texto: señales con estructura local, jerárquica y con invarianzas conocidas que la arquitectura codifica.

Donde falla

Datos tabulares: funciones a trozos, umbrales de operación, atributos heterogéneos sin relación espacial ni jerárquica.

Grinsztajn, Oyallon y Varoquaux (2022)

> En datos tabulares heterogéneos, los árboles superan a las redes bajo presupuesto equivalente de ajuste.

Sus tres razones, que son sesgo inductivo puro:

1. Las redes son **sesgadas hacia funciones suaves**, y muchos objetivos tabulares no lo son.
2. Los **atributos poco informativos** dañan más a las redes que a los árboles.
3. Las redes **no son invariantes a la rotación**, y en datos tabulares eso es una desventaja.

OBJETIVO	RED	ÁRBOLES
Suave	**0,824**	0,795
A trozos	0,793	**0,822**

TRADUCIDO A SU TESIS

Cuatro criterios de decisión

1. **¿Sus datos tienen estructura local o jerárquica?** Si no, el sesgo de la red no le sirve.
2. **¿Cuántos casos tiene?** Con miles y no millones, los ensambles suelen ganar.
3. **¿Puede pagar el ajuste?** Una red mal ajustada pierde contra un ensamble por defecto.
4. **¿Necesita probabilidades?** Las redes están muy descalibradas —semana 6— y empeora con la capacidad.

EN UNA LÍNEA

Lo que hay que llevarse

> Una red profunda no es una categoría aparte: es una familia con un sesgo inductivo muy concreto —suavidad y composición jerárquica — que es extraordinariamente bueno donde ese supuesto vale, y peor que un ensamble donde no vale.

Semana 12: aprendizaje por transferencia y ajuste fino; cuándo un modelo profundo es preferible a un ensamble; costo computacional y energético. **Taller 6.**