Aprendizaje por transferencia

Clase 12, primera parte · Reutilizar representaciones, y cuándo no se puede

Unidad 5 · Fundamentos operativos del aprendizaje profundo

Usted no tiene un millón de casos

Las redes profundas necesitan muchos datos. Una tesis en ingeniería tiene, con suerte, algunos miles.

> La transferencia propone reutilizar lo aprendido en una tarea con muchos datos para resolver otra con pocos.

Y como todo en este módulo, descansa en un supuesto: que ambas tareas **comparten estructura**. Cuando el supuesto falla, no solo no ayuda: perjudica.

1

Qué se transfiere

Las capas aprenden cosas distintas

En una red profunda entrenada sobre imágenes, las primeras capas detectan bordes y texturas; las últimas, objetos completos.

> Las capas iniciales aprenden regularidades del **dominio**; las finales, la **tarea** concreta.

- Los bordes son bordes en cualquier problema de visión.
- «Perro o gato» solo importa en el problema original.
- La transferencia se apoya exactamente en esa separación.

Tres cosas que se confunden

TÉRMINO	QUÉ SIGNIFICA
Transferencia	Reutilizar un modelo entrenado en otra tarea o dominio
Ajuste fino	Seguir entrenando ese modelo con los datos propios
Extracción de características	Congelar el modelo y usar sus activaciones como atributos

> El ajuste fino **modifica** los pesos; la extracción de características **no**. Son estrategias distintas con requisitos de datos muy distintos.

FORMALIZADO

Dos distribuciones y dos tareas

Con dominio $\mathcal{D}$ y tarea $\mathcal{T}$:

$$\mathcal{D} = \{\mathcal{X},\ P(X)\} \qquad \mathcal{T} = \{\mathcal{Y},\ f\}$$

- **Cambio de dominio**: $\mathcal{D}_{\text{origen}} \neq \mathcal{D}_{\text{destino}}$. Mismas etiquetas, distinta distribución de entrada. Otro sensor, otra planta, otra población.
- **Cambio de tarea**: $\mathcal{T}_{\text{origen}} \neq \mathcal{T}_{\text{destino}}$. Mismos datos, otra pregunta.
- El caso habitual es **ambos a la vez**.

¿Qué comparten sus dos problemas?

- **¿La modalidad?** Imagen, señal temporal, texto, tabla.
- **¿La física subyacente?** Dos sensores de vibración comparten más que un sensor y una encuesta.
- **¿La estructura de la etiqueta?** Binaria, multiclase, continua.

> Si no puede nombrar qué comparten, no tiene una justificación para transferir —tiene una esperanza.

2

Las estrategias

Ordenadas por cuántos datos propios exigen.

La opción de pocos datos

Se congela la red preentrenada, se toman las activaciones de una capa intermedia como vector de atributos, y se entrena un modelo simple encima.

Cuándo

Pocos datos propios —cientos— y dominio parecido al de origen.

Por qué funciona

Solo se estiman los parámetros del modelo simple. La capacidad efectiva es baja, y con ella la varianza —semana 3.

Y una consecuencia práctica: encima de las características se puede poner una regresión logística regularizada, o un ensamble. No hace falta que el modelo final sea una red.

Cuando hay datos suficientes

Se continúa el entrenamiento con los datos propios, con **tasa de aprendizaje baja** para no destruir lo aprendido.

- **Ajuste fino parcial**: se descongelan solo las últimas capas.
- **Ajuste fino total**: se descongela todo. Necesita más datos y más cuidado.
- **Descongelado progresivo**: se van liberando capas de arriba hacia abajo.

> La tasa de aprendizaje es aquí más crítica que en un entrenamiento desde cero: demasiado alta y se borra la representación que se quería aprovechar.

Dos ejes: cuántos datos y cuánto se parecen

	DOMINIO PARECIDO	DOMINIO DISTINTO
Pocos datos	Extracción de características	Situación difícil: capas iniciales, y poco más
Muchos datos	Ajuste fino parcial	Ajuste fino total, o entrenar desde cero

> La casilla superior derecha es la peligrosa: pocos datos y dominio distinto es donde la transferencia **perjudica** más a menudo de lo que ayuda.

UN REQUISITO QUE SE OLVIDA

El preprocesamiento del origen

> El modelo preentrenado espera sus entradas **exactamente como las vio**: mismo tamaño, mismo rango, misma normalización.

- Alimentarlo con imágenes normalizadas de otro modo degrada el resultado en silencio.
- Es un error que no produce ningún mensaje y que cuesta días encontrar.
- Y la normalización sigue estimándose solo con entrenamiento si usted la reajusta.

No cambia nada de la unidad 3

> Un modelo transferido se evalúa exactamente igual: partición justificada, sin fuga, con variabilidad y con la métrica del problema.

- Con una trampa nueva: si el conjunto de **origen** contiene datos parecidos a su conjunto de prueba, hay fuga —y usted no la controla.
- Es una categoría de fuga que Kapoor y Narayanan no podían anticipar en 2023 y que hoy es real con modelos entrenados sobre corpus enormes.

3

Cuándo no funciona

Cuando el origen estorba

> Si las tareas no comparten estructura, el modelo transferido rinde **peor** que uno entrenado desde cero con los mismos datos.

- El sesgo inductivo del origen es incorrecto para el destino, y lo arrastra.
- Y es difícil de detectar sin la comparación explícita.
- Por eso el taller 6 exige siempre **la línea base entrenada desde cero**.

Sin ella no se puede afirmar que la transferencia aportó algo.

Donde casi no hay qué transferir

- Las columnas de dos tablas distintas no tienen relación: no hay bordes ni fonemas que reutilizar.
- La transferencia entre tablas se limita a casos con esquema compartido.
- Los modelos tabulares fundacionales existen y son un área activa, pero no son el estándar.

> Si su problema es tabular, la transferencia probablemente no es su herramienta. Es la conclusión del seminario de la semana pasada, aplicada aquí.

EN UNA LÍNEA

Lo que hay que llevarse

> Transferir es apostar a que dos problemas comparten estructura. Si puede nombrar qué comparten, es un argumento; si no, es una esperanza. Y sin línea base entrenada desde cero, no hay forma de saber cuál de las dos era.