El costo como criterio

Clase 12, segunda parte · Cuándo un modelo profundo es preferible a un ensamble

Unidad 5 · Fundamentos operativos del aprendizaje profundo

Once semanas sin hablar de costo

Todo el módulo ha comparado métodos por su riesgo esperado. Ni una vez hemos preguntado cuánto cuesta obtenerlo.

> Y el costo no es un detalle de implementación: es parte de la afirmación. Un método que gana con cien veces más cómputo no ha ganado en el mismo sentido.

1

Qué costos hay

CUATRO COSTOS

Y se confunden constantemente

COSTO	QUÉ MIDE	CUÁNDO IMPORTA
Desarrollo	Búsqueda de hiperparámetros, experimentos fallidos	Es el que más consume, y el que menos se reporta
Entrenamiento final	Un ajuste del modelo elegido	Lo único que suele aparecer en los artículos
Inferencia	Predecir un caso, en producción	El que domina a lo largo de la vida del sistema
Mantenimiento	Reentrenar, revalidar, vigilar el desplazamiento	El que nadie presupuesta

> Reportar solo el segundo es como reportar el precio del vehículo y no el del combustible.

Entrenar una vez, predecir un millón

- Un modelo se entrena decenas de veces durante el desarrollo, y luego muy pocas.
- Se usa para predecir durante años.
- La huella total suele estar dominada por la **inferencia**, no por el entrenamiento.

> La pregunta operativa no es «¿cuánto cuesta entrenarlo?» sino «¿cuánto cuesta tenerlo funcionando cinco años?».

La condición de la semana 8

> Comparar dos métodos exige el mismo presupuesto, declarado en unidades verificables.

- Número de configuraciones de hiperparámetros evaluadas.
- Tiempo de cómputo, con el hardware especificado.
- Y **por método**: si uno recibió 200 configuraciones y otro 10, la comparación no existe.

El cuaderno de la semana pasada lo hace explícito: 12 configuraciones para cada familia. Ese número es parte del resultado.

Por qué las comparaciones favorecen a lo nuevo

- El método propio se ajusta con dedicación durante semanas.
- La línea base se ejecuta con los valores por defecto.
- Y el resultado se presenta como una comparación entre métodos.

> No hace falta mala fe. Basta con dedicar más esfuerzo a lo propio, que es lo natural.

2

El costo energético

- Porque es un costo real con consecuencias materiales, y la unidad 6 trata de la confiabilidad de los sistemas.
- Porque cada vez más revistas y congresos piden declararlo.
- Y porque un método que exige recursos inaccesibles **no es reproducible** —lo que lo saca del método científico.

> El último punto es el que conecta con este módulo: si nadie puede repetir su experimento, su resultado no es verificable.

CÓMO SE ESTIMA

Una cuenta sencilla

$$E \approx P \times t \times \mathrm{PUE}, \qquad \mathrm{CO_2} = E \times I$$

- P: potencia del hardware, en kilovatios. t: tiempo, en horas.
- **PUE**: eficiencia del centro de datos, típicamente entre 1,1 y 1,6.
- I: intensidad de carbono de la red eléctrica, en kg de $\mathrm{CO_2}$ por kWh. Varía por país en más de un orden de magnitud.

En Chile, la intensidad de la red ha bajado sustancialmente con la entrada de renovables, así que el mismo experimento tiene huellas distintas según el año y la hora.

La lista mínima

1. **Hardware**: modelo de CPU o GPU, y cuántas.
2. **Tiempo total de cómputo**, incluido el desarrollo, no solo el ajuste final.
3. **Número de experimentos ejecutados**, aunque no se reporten.
4. Si se puede, **energía en kWh**; y si se estima CO_2, con qué intensidad de red.

> El punto 3 es el más incómodo y el más informativo: dice cuántas veces miró los datos antes de llegar al resultado que publica.

La pregunta que rara vez se hace

> ¿La mejora obtenida justifica el costo incurrido? Y esa comparación se hace en las unidades del problema, no en las del artículo.

Ejemplo

+0,004 de AUC, con 40 veces más cómputo de entrenamiento y 12 veces más de inferencia.

La pregunta

¿Cambia esa mejora alguna decisión en la planta?

Si no, el resultado es cierto y es **irrelevante**.

3

Cómo se decide

La forma correcta de presentarlo

> Grafique desempeño contra costo. Un método **domina** a otro si es mejor en ambos ejes. Los no dominados forman la frontera, y entre ellos la elección es del problema, no del método.

- Elimina la pregunta mal planteada de «cuál es el mejor».
- Hace visible cuánto cuesta cada décima adicional.
- Y muestra si su método aporta algo o si está por debajo de la frontera.

Es lo que se pide en el taller 6, y es una figura, no una tabla.

Cuándo un modelo profundo es preferible

1. **La modalidad lo pide**: imagen, audio, texto, señal con estructura local.
2. **Hay datos suficientes**, o un modelo preentrenado pertinente.
3. **La ganancia es sustantiva** en las unidades del problema, no en la tercera decimal.
4. **El costo de inferencia es viable** durante toda la vida del sistema.
5. **Hay capacidad de mantenerlo**: reentrenar, vigilar, revalidar.

> Si falla el punto 1, los demás no importan. Si fallan el 4 o el 5, el sistema no llega a producción por muy bueno que sea el resultado.

TRADUCIDO A SU TESIS

Tres exigencias

1. **Declare el presupuesto de cómputo por método**, en configuraciones y en tiempo, con el hardware especificado.
2. **Incluya siempre una línea base simple**, ajustada con el mismo cuidado. Una regresión regularizada o una potenciación por defecto.
3. **Presente la frontera de desempeño frente a costo**, y justifique su elección sobre ella.

EN UNA LÍNEA

Lo que hay que llevarse

> El costo no es un apéndice del resultado: es parte de la afirmación. Un método que gana con cien veces más cómputo ha ganado otra cosa, y no declararlo hace la comparación incomparable.

Esta semana: taller 6 —modelo profundo frente a ensamble, con presupuesto declarado. **Semana 13:** interpretabilidad, **seminario 5** (Rudin; Lundberg y Lee) y **tutoría 3** con resultados preliminares.