Interpretabilidad

Clase 13 · Modelos transparentes frente a explicaciones post hoc

Unidad 6 · Interpretabilidad, incertidumbre y confiabilidad

¿Por qué predijo eso?

Un modelo marca la bomba 217 como próxima a fallar. El jefe de mantenimiento pregunta por qué.

- «Porque el modelo es transparente y aquí está la regla.»
- «Porque un segundo método, aplicado sobre el modelo, dice que estos atributos pesaron.»

> Hay dos respuestas posibles, y la diferencia entre ellas es el contenido de la clase de hoy.

1

Qué significa interpretar

NO HAY UNA DEFINICIÓN

Y esa es parte del problema

> «Interpretable» no tiene definición formal. Se usa para cosas distintas que conviene separar.

QUÉ SE QUIERE	PREGUNTA
Transparencia	¿Puedo seguir el cálculo que llevó a esta predicción?
Explicación local	¿Por qué **este caso** obtuvo esta predicción?
Importancia global	¿Qué atributos usa el modelo **en general**?
Contrafactual	¿Qué tendría que cambiar para obtener otra predicción?

La pregunta que decide qué sirve

- **Para usted, que modela** — depurar, detectar fuga, encontrar atributos ilegítimos.
- **Para el experto del dominio** — verificar que el modelo usa lo que debe.
- **Para quien recibe la decisión** — entender, y poder objetar.
- **Para el regulador** — auditar y establecer responsabilidad.

> Un método útil para depurar puede ser inútil —o engañoso— para justificar una decisión ante quien la sufre.

Los que se leen directamente

FAMILIA	QUÉ SE LEE
Regresión lineal o logística regularizada	Los coeficientes, si los atributos están en escalas comparables
Árbol de decisión poco profundo	El camino de reglas, literalmente
Listas de reglas, sistemas de puntuación	La regla que se aplicó
Modelos aditivos generalizados	El efecto de cada atributo, por separado

> Y una advertencia que este módulo ya dio: los coeficientes de un Lasso son **inestables** con atributos correlacionados. Transparente no siempre es fiable.

Y por qué Rudin lo discute

> Se da por sentado que interpretabilidad y desempeño se intercambian: para entender hay que renunciar a acertar.

- En datos tabulares estructurados, la diferencia suele ser **pequeña o nula**.
- En imágenes y texto, el compromiso **es real**.
- Rudin sostiene que en el primer caso el compromiso se afirma **sin comprobarlo**.

2

Explicaciones post hoc

Cuando el modelo ya está y hay que explicarlo desde fuera.

La más simple

Se permuta al azar una columna y se mide cuánto empeora el desempeño.

$$I_j = R_{\text{permutado}(j)} - R_{\text{original}}$$

- Barata, y aplicable a cualquier modelo.
- Con atributos **correlacionados**, engaña: permutar uno no destruye la información, que sigue en su correlacionado.
- Y genera puntos imposibles: una presión alta con una temperatura baja que nunca coexisten.

Un modelo simple, localmente

Alrededor del caso a explicar se generan puntos perturbados, se etiquetan con el modelo original, y se ajusta un modelo lineal ponderado por cercanía.

La idea

Cualquier función es aproximadamente lineal si se mira lo bastante cerca.

Los problemas

El resultado depende de cómo se perturba y de qué es «cerca».

Y es **inestable**: dos ejecuciones sobre el mismo caso pueden dar explicaciones distintas.

Valores de Shapley, con axiomas

Reparte la predicción entre los atributos según el reparto de la teoría de juegos cooperativos:

$$\phi_j = \sum_{S \subseteq F \setminus \{j\}} \frac{|S|!\,(|F| - |S| - 1)!}{|F|!} \left[f(S \cup \{j\}) - f(S) \right]$$

- Es el **único** reparto que satisface simultáneamente eficiencia, simetría, nulidad y aditividad.
- Esos axiomas son su gran argumento, y también el origen del malentendido.

Tres malentendidos frecuentes

- ✕ **No es causal.** Dice cómo el modelo reparte su predicción, no cómo el mundo produce el resultado.
- ✕ **Los axiomas garantizan el reparto, no la verdad.** Es único dado el modelo; si el modelo es malo, la explicación es un reparto exacto de algo incorrecto.
- ✕ **Con atributos correlacionados**, las aproximaciones prácticas evalúan combinaciones que no existen en los datos.

> Un valor SHAP alto significa «este atributo movió mucho la predicción **de este modelo**». No significa «este atributo causa el fenómeno».

El hecho incómodo

> Dos modelos con **el mismo desempeño** sobre los mismos datos pueden dar explicaciones **completamente distintas.**

Es el *conjunto Rashomon*. Seis modelos con un rango de AUC de **0,041** —indistinguibles — sobre datos donde `x1` es casi copia de `x0`:

	REPARTO DE IMPORTANCIA HACIA `x0`
Logística	**88,8 %**
Potenciación	57,5 %
Bosque	49,5 %
Red (64,32)	**12,1 %**

Señalan atributos distintos como el más importante, y ninguno se equivoca: la información es la misma y la pregunta no tiene respuesta en los datos.

3

La objeción de Rudin

Rudin (2019), en cuatro pasos

1. Una explicación post hoc es, por definición, **una aproximación al modelo**. Si fuera exacta, sería el modelo.
2. Una aproximación fiel al modelo es inútil si el modelo es opaco; una aproximación simple es infiel.
3. En decisiones de alto riesgo, una explicación infiel es **peor que ninguna**: produce confianza injustificada.
4. Y en datos estructurados, un modelo interpretable suele rendir casi igual, así que el compromiso que justificaría la caja negra no existe.

Porque el argumento no es unánime

- En imágenes, audio y texto, el compromiso **sí** existe y es grande.
- Un modelo transparente puede ser demasiado grande para leerse: un árbol de 400 hojas es opaco en la práctica.
- Y las explicaciones post hoc son muy útiles **para depurar** —detectar fuga, atributos ilegítimos, artefactos.

> La síntesis razonable: para depurar, use lo que quiera; para justificar una decisión sobre una persona, use un modelo que se pueda leer.

Cuatro exigencias

1. **Diga para quién** es la interpretabilidad. Depurar y justificar no son lo mismo.
2. **Mida el compromiso en su problema**: entrene un modelo transparente y reporte cuánto pierde. Si pierde poco, tiene que explicar por qué usa la caja negra.
3. **Reporte la estabilidad** de sus explicaciones sobre réplicas o semillas. Una explicación inestable no sostiene nada.
4. **No interprete importancias como causas** sin el aparato causal que lo permita.

EN UNA LÍNEA

Lo que hay que llevarse

> Una explicación post hoc explica **el modelo, no el mundo**, y no es única: hay muchos modelos igual de buenos que la contradicen. Si va a fundamentar una decisión sobre alguien, la pregunta no es cómo explicar la caja negra sino por qué usarla.

Hoy: seminario 5 —el último— con Rudin (2019) y Lundberg y Lee (2017), y **tutoría 3** con resultados preliminares. **Semana 14:** cuantificación de la incertidumbre, calibración y predicción conforme.