# Interpretabilidad

Clase 13 · Modelos transparentes frente a explicaciones *post hoc*

Unidad 6 · Interpretabilidad, incertidumbre y confiabilidad

Invalid Date

# ¿Por qué predijo eso?

Un modelo marca la bomba 217 como próxima a fallar. El jefe de mantenimiento pregunta por qué.

> Hay dos respuestas posibles, y la diferencia entre ellas es el contenido de la clase de hoy.

- **«Porque el modelo es transparente y aquí está la regla.»**
- **«Porque un segundo método, aplicado sobre el modelo, dice que estos atributos pesaron.»**

1

# Qué significa interpretar

# Y esa es parte del problema

> «Interpretable» no tiene definición formal. Se usa para cosas distintas que conviene separar.

| QUÉ SE QUIERE | PREGUNTA |
|---|---|
| **Transparencia** | ¿Puedo seguir el cálculo que llevó a esta predicción? |
| **Explicación local** | ¿Por qué **este** caso obtuvo **esta** predicción? |
| **Importancia global** | ¿Qué atributos usa el modelo en general? |
| **Contrafactual** | ¿Qué tendría que cambiar para obtener otra predicción? |

# La pregunta que decide qué sirve

- **Para usted, que modela** — depurar, detectar fuga, encontrar atributos ilegítimos.
- **Para el experto del dominio** — verificar que el modelo usa lo que debe.
- **Para quien recibe la decisión** — entender, y poder objetar.
- **Para el regulador** — auditar y establecer responsabilidad.

> Un método útil para depurar puede ser inútil —o engañoso— para justificar una decisión ante quien la sufre.

# Los que se leen directamente

| FAMILIA | QUÉ SE LEE |
|---|---|
| Regresión lineal o logística regularizada | Los coeficientes, si los atributos están en escalas comparables |
| Árbol de decisión **poco profundo** | El camino de reglas, literalmente |
| Listas de reglas, sistemas de puntuación | La regla que se aplicó |
| Modelos aditivos generalizados | El efecto de cada atributo, por separado |

> Y una advertencia que este módulo ya dio: los coeficientes de un Lasso son **inestables** con atributos correlacionados. Transparente no siempre es fiable.

# Y por qué Rudin lo discute

> Se da por sentado que interpretabilidad y desempeño se intercambian: para entender hay que renunciar a acertar.

- En **datos tabulares estructurados**, la diferencia suele ser pequeña o nula.
- En imágenes y texto, el compromiso es real.
- Rudin sostiene que en el primer caso **el compromiso se afirma sin comprobarlo**.

2

# Explicaciones *post hoc*

Cuando el modelo ya está y hay que explicarlo desde fuera.

# La más simple

Se permuta al azar una columna y se mide cuánto empeora el desempeño.

$$I_j = R_{\text{permutado}(j)} - R_{\text{original}}$$

- Barata, y aplicable a cualquier modelo.
- **Con atributos correlacionados, engaña**: permutar uno no destruye la información, que sigue en su correlacionado.
- Y genera puntos imposibles: una presión alta con una temperatura baja que nunca coexisten.

# Un modelo simple, localmente

Alrededor del caso a explicar se generan puntos perturbados, se etiquetan con el modelo original, y se ajusta un **modelo lineal ponderado por cercanía**.

### La idea

Cualquier función es aproximadamente lineal si se mira lo bastante cerca.

### Los problemas

El resultado depende de **cómo se perturba** y de **qué es «cerca»**.

Y es **inestable**: dos ejecuciones sobre el mismo caso pueden dar explicaciones distintas.

# Valores de Shapley, con axiomas

Reparte la predicción entre los atributos según el reparto de la teoría de juegos cooperativos:

$$\phi_j = \sum_{S \subseteq F \setminus \{j\}} \frac{|S|!\,(|F| - |S| - 1)!}{|F|!} \Big[ f(S \cup \{j\}) - f(S) \Big]$$

- Es el **único** reparto que satisface simultáneamente eficiencia, simetría, nulidad y aditividad.
- Esos axiomas son su gran argumento, y también el origen del malentendido.

# Tres malentendidos frecuentes

- ✕ **No es causal.** Dice cómo el modelo reparte su predicción, **no** cómo el mundo produce el resultado.
- ✕ **Los axiomas garantizan el reparto, no la verdad.** Es único dado el modelo; si el modelo es malo, la explicación es un reparto exacto de algo incorrecto.
- ✕ **Con atributos correlacionados**, las aproximaciones prácticas evalúan combinaciones que **no existen** en los datos.

> Un valor SHAP alto significa «este atributo movió mucho la predicción **de este modelo**». No significa «este atributo causa el fenómeno».

# El hecho incómodo

> Dos modelos con **el mismo desempeño** sobre los mismos datos pueden dar explicaciones **completamente distintas.**

Es el *conjunto Rashomon*: el conjunto de modelos casi igual de buenos. Con atributos correlacionados, ese conjunto es grande, y sus miembros discrepan sobre qué importa.

Seis modelos con un rango de AUC de **0,041** —indistinguibles— sobre datos donde `x1` es casi copia de `x0`:

| | REPARTO DE IMPORTANCIA HACIA `x0` |
|---|---|
| Logística | **88,8 %** |
| Potenciación | 57,5 % |
| Bosque | 49,5 % |
| Red (64,32) | **12,1 %** |

3

# La objeción de Rudin

# Rudin (2019), en cuatro pasos

1. Una explicación *post hoc* es, por definición, **una aproximación** al modelo. Si fuera exacta, sería el modelo.
2. Una aproximación **fiel** al modelo es inútil si el modelo es opaco; una aproximación **simple** es infiel.
3. En decisiones de alto riesgo, una explicación infiel es **peor que ninguna**: produce confianza injustificada.
4. Y en datos estructurados, un modelo interpretable suele rendir **casi igual**, así que el compromiso que justificaría la caja negra **no existe**.

# Porque el argumento no es unánime

- En **imágenes, audio y texto**, el compromiso sí existe y es grande.
- Un modelo transparente puede ser **demasiado grande** para leerse: un árbol de 400 hojas es opaco en la práctica.
- Y las explicaciones *post hoc* son **muy útiles para depurar** —detectar fuga, atributos ilegítimos, artefactos.

> La síntesis razonable: **para depurar, use lo que quiera; para justificar una decisión sobre una persona, use un modelo que se pueda leer.**

# Cuatro exigencias

1. **Diga para quién** es la interpretabilidad. Depurar y justificar no son lo mismo.
2. **Mida el compromiso** en su problema: entrene un modelo transparente y reporte cuánto pierde. Si pierde poco, tiene que explicar por qué usa la caja negra.
3. **Reporte la estabilidad** de sus explicaciones sobre réplicas o semillas. Una explicación inestable no sostiene nada.
4. **No interprete importancias como causas** sin el aparato causal que lo permita.

EN UNA LÍNEA

# Lo que hay que llevarse

> Una explicación *post hoc* explica el modelo, no el mundo, y no es única: hay muchos modelos igual de buenos que la contradicen. Si va a fundamentar una decisión sobre alguien, la pregunta no es cómo explicar la caja negra sino por qué usarla.

---

**Hoy:** seminario 5 —el último— con Rudin (2019) y Lundberg y Lee (2017), y **tutoría 3** con resultados preliminares. **Semana 14:** cuantificación de la incertidumbre, calibración y predicción conforme.