Predicción conforme

Clase 14, primera parte · Garantías sin suponer casi nada

Unidad 6 · Interpretabilidad, incertidumbre y confiabilidad

La semana 6 dejó un problema abierto

Vimos que las probabilidades de la mayoría de los modelos no significan lo que dicen, y que recalibrar ayuda pero no da ninguna **garantía**.

> ¿Existe alguna forma de acompañar una predicción con una garantía que se pueda **demostrar**?

- Sin suponer que el modelo está bien especificado.
- Sin suponer una distribución paramétrica de los errores.
- Y con validez **a muestra finita**, no asintótica.

1

La idea

De un valor a un conjunto

> En vez de predecir un valor, se predice un **conjunto** que contiene la verdad con una probabilidad declarada.

Regresión

En vez de «la vida útil restante es de 42 días», un intervalo: entre 31 y 58 días, con 90 % de cobertura.

Clasificación

En vez de «clase A», un conjunto: $\{A, B\}$, con 90 % de cobertura.

El tamaño del conjunto es la incertidumbre.

Lo que se puede demostrar

Con un nivel α elegido de antemano, el conjunto $C(x)$ cumple:

$$\Pr\big(y_{n+1} \in C(x_{n+1})\big) \;\geq\; 1 - \alpha$$

- Vale para **cualquier** modelo, incluso uno pésimo.
- Vale a **muestra finita**: no es asintótica.
- El único supuesto es la **intercambiabilidad** de los datos, más débil que i.i.d.

El único supuesto

> Los datos son intercambiables si la probabilidad conjunta no cambia al reordenarlos.

- Es más débil que i.i.d.: todo conjunto i.i.d. es intercambiable, no al revés.
- Pero **series temporales no lo son**: el orden importa.
- Ni datos con desplazamiento de distribución, que es la segunda parte de la clase.

La intuición, en una línea

> Si su nuevo caso es intercambiable con los de calibración, su «rareza» es igualmente probable de caer en cualquier posición del ranking.

- Con n casos de calibración, la probabilidad de que el nuevo caso sea más raro que todos ellos es $1/(n+1)$.
- Elegir el cuantil adecuado del ranking controla esa probabilidad.
- Y eso es todo el teorema: es un argumento de simetría, como No Free Lunch.

2

El procedimiento

Cuatro pasos. Cabe en veinte líneas de código.

El procedimiento completo

1. **Particione**: entrenamiento y calibración. Un tercer conjunto, como en la semana 6.
2. **Entrene** el modelo con el de entrenamiento. Cualquier modelo.
3. **Puntúe la no conformidad** de cada caso de calibración: una medida de cuánto sorprende. Para regresión, $s_i = |y_i - \hat{y}_i|$.
4. **Tome el cuantil** $\lceil (n+1)(1-\alpha) \rceil / n$ de esos puntajes. Ese es el radio del intervalo.

> $$C(x_{n+1}) = \left[\hat{y}_{n+1} - \hat{q},\ \hat{y}_{n+1} + \hat{q}\right]$$

El puntaje cambia, el resto no

Con $\hat{p}_y(x)$ la probabilidad que el modelo asigna a la clase verdadera:

$$s_i = 1 - \hat{p}_{y_i}(x_i) \quad \Longrightarrow \quad C(x) = \{\, y : \; 1 - \hat{p}_y(x) \leq \hat{q} \,\}$$

- Se incluye toda clase cuya probabilidad supere un umbral derivado del cuantil.
- El tamaño del conjunto varía por caso: ahí está la incertidumbre.
- Y **no hace falta que $\hat{p}$ esté calibrado**: la garantía no lo exige.

Se paga en tamaño, no en cobertura

> Un modelo malo también cumple la garantía: produce intervalos anchísimos o conjuntos con casi todas las clases.

Lo que se garantiza

La **cobertura**. Siempre, con cualquier modelo.

Lo que hay que reportar

El **tamaño medio** del conjunto. Es la medida de utilidad, y sin ella la garantía no dice nada.

Intervalos que se adaptan

El puntaje $|y - \hat{y}|$ da intervalos de ancho constante. Si la incertidumbre varía con x —lo habitual—, conviene normalizar:

$$s_i = \frac{|y_i - \hat{y}_i|}{\hat{\sigma}(x_i)}$$

con $\hat{\sigma}(x)$ un segundo modelo que predice la magnitud del error.

- El intervalo se ensancha donde el modelo es menos fiable.
- La cobertura marginal se mantiene.
- Y la cobertura por regiones mejora, aunque sigue sin estar garantizada.

3

Qué garantiza y qué no

El malentendido grave

> La garantía es **marginal**: promediada sobre todos los casos futuros. No es condicional a las características del caso.

REGIÓN	DE ANCHO FIJO	NORMALIZADO
$\lvert x_0 \rvert$ baja (ruido bajo)	0,997	0,907
media-baja	0,968	0,913
media-alta	0,877	0,895
alta (ruido alto)	**0,753**	0,907

Las dos columnas tienen cobertura marginal del 90 %. El promedio esconde que la de ancho fijo sobra donde no hace falta y falta justo donde el modelo es menos fiable. Si sus bombas son de dos fabricantes, la cobertura puede ser muy distinta en cada uno.

Conformal por grupos

- **Mondrian**: calibrar por separado dentro de cada grupo. Da cobertura garantizada por grupo.
- Necesita suficientes casos de calibración en cada grupo.
- Y los grupos hay que definirlos **de antemano**, no después de ver las coberturas.

> Es la solución práctica cuando existen subpoblaciones conocidas y relevantes.

Tres exigencias

1. **Si su modelo alimenta decisiones, reporte conjuntos y no puntos.** Cuesta veinte líneas y cambia lo que se puede afirmar.
2. **Reporte cobertura y tamaño medio.** La primera está garantizada; la segunda es la que dice si el resultado sirve.
3. **Verifique la cobertura por subgrupo** en los grupos que importen, y declare si es desigual.

EN UNA LÍNEA

Lo que hay que llevarse

> La predicción conforme da una garantía de cobertura demostrable con casi ningún supuesto, y el precio está en el **tamaño** del conjunto. Es marginal, no condicional: cubre bien en promedio y puede cubrir mal donde a usted le importa.