Robustez y desplazamiento de distribución

Clase 14, segunda parte · Cuando $\mathcal{D}$ deja de ser la misma

Unidad 6 · Interpretabilidad, incertidumbre y confiabilidad

Fijo, desconocido, y el mismo

Trece semanas suponiendo que $\mathcal{D}$ es **fija**. Toda la teoría descansa en eso: el riesgo esperado, la validación, la predicción conforme de la primera parte.

> En producción, cambia. Y cuando cambia, el número que usted reportó deja de describir el sistema.

1

Los tipos de desplazamiento

$$P(x, y) = P(y \mid x)\, P(x)$$

Y cada factor puede cambiar por separado:

TIPO	QUÉ CAMBIA	EJEMPLO
Covariable	$P(x)$	Nuevo lote de bombas, con otro régimen de operación
Etiqueta (*prior*)	$P(y)$	La tasa de fallas sube tras un cambio de proveedor
Concepto	$P(y \mid x)$	La misma vibración ya no significa lo mismo tras una modificación

> Los tres exigen respuestas distintas, y **solo el primero** es corregible sin etiquetas nuevas.

El caso corregible

$P(x)$ cambia, pero la relación $P(y \mid x)$ se mantiene.

- El modelo sigue siendo correcto **donde tiene datos**.
- El problema es que ahora se le pregunta por regiones que vio poco.
- Y su desempeño global cambia porque cambió la mezcla.

> Se corrige con **reponderación por razón de verosimilitudes**: dar más peso a los casos de entrenamiento que se parecen a los nuevos.

CONCEPTO

El caso que exige datos nuevos

$P(y \mid x)$ cambia: la misma entrada tiene ahora otra salida esperada.

- Ninguna reponderación lo arregla: la función objetivo **es otra**.
- Se necesitan etiquetas nuevas, y por tanto tiempo.
- Y se detecta con retraso, porque las etiquetas llegan después de la decisión.

> Ese retraso es la razón de que la vigilancia se haga sobre las **entradas** y no sobre el desempeño: cuando el desempeño cae, ya pasó.

El modelo cambia el mundo

> Si su modelo **actúa** —alerta, prioriza, interviene— entonces modifica el proceso que genera los datos futuros.

- Las bombas que el modelo marca se inspeccionan, y dejan de fallar.
- El modelo, evaluado después, parece haber empeorado. **Y funcionó.**
- Es el circuito de realimentación, y rompe la intercambiabilidad de raíz.

POR QUÉ IMPORTA AQUÍ

La garantía conforme también se rompe

> La predicción conforme de la primera parte supone intercambiabilidad. Bajo desplazamiento, la cobertura declarada deja de valer.

MAGNITUD DEL DESPLAZAMIENTO	COBERTURA
0,0	0,899
0,6	0,892
1,0	0,864
2,0	**0,765**

Existen variantes con pesos que la recuperan bajo desplazamiento de covariable conocido. Bajo desplazamiento de concepto, no hay solución sin datos nuevos.

2

Detectarlo

La más práctica

> Entrene un clasificador que distinga datos de entrenamiento de datos de producción. Si lo consigue, las distribuciones difieren.

- AUC cercano a 0,5: no hay evidencia de desplazamiento.
- AUC alto: hay desplazamiento, y la importancia de atributos dice **en cuál**.
- Es la misma lógica de la referencia nula de la semana 10.

Y su trampa

PRUEBA	PARA QUÉ
Kolmogórov-Smirnov	Un atributo continuo
Chi-cuadrado	Un atributo categórico
Distancia de Wasserstein	Magnitud del cambio, no solo su existencia

> Con 50 atributos son 50 pruebas: hay que corregir por multiplicidad, semana 8. Sin corregir, **siempre** encontrará desplazamiento.

Y una limitación de fondo: las pruebas por atributo no ven cambios en la estructura de dependencia. Dos atributos con marginales idénticas pueden haber cambiado su correlación.

QUÉ VIGILAR

En orden de disponibilidad

1. **Distribución de las entradas** — disponible de inmediato.
2. **Distribución de las predicciones** — también inmediata, y a menudo más sensible.
3. **Métricas de desempeño** — solo cuando llegan las etiquetas. Tarde.
4. **Señales del proceso** — cambios de proveedor, de calibración, de operación. A menudo las más informativas y las que nadie conecta con el modelo.

3

Qué hacer

De más barata a más cara

RESPUESTA	CUÁNDO
No hacer nada, y documentarlo	El desplazamiento es pequeño y el desempeño se mantiene
Reponderar	Desplazamiento de covariable, con solapamiento suficiente
Reentrenar con datos recientes	Hay etiquetas nuevas
Rechazar la predicción	El caso cae fuera del dominio conocido: **abstención**
Rediseñar	Desplazamiento de concepto profundo

> La cuarta es la más infravalorada: un sistema que dice «no sé» en los casos raros es más útil que uno que responde siempre.

LO QUE HAY QUE DECLARAR

En la tesis y en el informe

1. **La población de entrenamiento y la de aplicación**, y en qué difieren. Es la advertencia de la semana 1, ahora obligatoria.
2. **El horizonte de validez** de su modelo, y qué lo invalidaría.
3. **Qué se vigilaría en producción** y con qué frecuencia.

> Un modelo sin plan de vigilancia no es un sistema: es un experimento que alguien dejó encendido.

Volvemos a la semana 1

> «Su afirmación empírica es una afirmación sobre $\mathcal{D}$. Y $\mathcal{D}$ es la población a la que se aplicará el modelo, no la muestra que usted consiguió.»

Catorce semanas después, esa frase tiene contenido técnico:

- Qué es $\mathcal{D}$: unidad 1.
- Cómo se estima el riesgo sobre ella sin engañarse: unidad 3.
- Qué pasa cuando deja de ser la misma: hoy.

EN UNA LÍNEA

Lo que hay que llevarse

> Toda garantía de este módulo —el riesgo esperado, la validación, la cobertura conforme— vale mientras $\mathcal{D}$ sea la misma. En producción no lo es, así que un resultado sin **horizonte de validez** declarado está incompleto.

Semana 15: sesgo y equidad en modelos predictivos, reporte, listas de verificación de reproducibilidad y cierre del módulo. **El informe final se entrega esa semana.**