Sesgo y equidad

Clase 15, primera parte · Por qué no se pueden satisfacer todas las definiciones

Unidad 7 · Investigación reproducible y comunicación de resultados

Esto no es un apéndice ético

> La equidad no es un tema aparte que se añade al final: es la misma pregunta de la semana 1, hecha **por subgrupos**.

Si un promedio sobre una población heterogénea no describe a ninguno de sus subgrupos —lo dijimos con el acierto en la semana 6 y con la cobertura conforme la semana pasada— entonces todo el aparato del módulo ya venía apuntando aquí.

1

De dónde viene el sesgo

CINCO ORÍGENES

Y ninguno es «el algoritmo»

ORIGEN	EN QUÉ CONSISTE
Histórico	Los datos registran un mundo desigual. El modelo lo reproduce fielmente
De representación	Un subgrupo tiene pocos casos, y el modelo aprende peor sobre él
De medición	La etiqueta es un *proxy* imperfecto, y su error difiere por grupo
De agregación	Un solo modelo para grupos cuya relación $P(y \mid x)$ difiere
De despliegue	El sistema se usa de forma distinta a como se validó

> El algoritmo casi nunca es el origen. Es el **amplificador.**

La etiqueta que no existía

En la semana 1, el problema de las bombas incluía construir la etiqueta: «una etiqueta binaria que aún no existe».

- Si «falla» significa «se registró una falla», depende de qué bombas se inspeccionan.
- Y si se inspeccionan más las de una planta, el modelo aprenderá que esa planta falla más.
- Eso no es una propiedad de las bombas: es una propiedad del **protocolo de inspección**.

El error más frecuente

> Eliminar la variable de grupo no elimina su efecto: otros atributos la codifican.

- Código postal, historial, tipo de equipo, planta de origen.
- Con suficientes atributos, el grupo es reconstruible, y el modelo lo reconstruye si ayuda a predecir.
- Y sin el atributo, usted ya **no puede medir** la disparidad.

> Es peor que inútil: cierra los ojos sin cerrar el efecto.

Antes de medir nada

1. **Definir los grupos** que importan y por qué, antes de mirar resultados.
2. **Reportar el desempeño desagregado** por esos grupos. Es media tabla.
3. **Reportar el tamaño de cada grupo**: una métrica sobre 12 casos no significa nada.

> El paso 2 es lo mínimo exigible, y ya descarta la mayoría de los trabajos publicados.

2

Las definiciones de equidad

Hay más de veinte. Vemos las tres que importan.

Igual tasa de predicción positiva

$$\Pr(\hat{y} = 1 \mid A = a) = \Pr(\hat{y} = 1 \mid A = b)$$

- **No mira la etiqueta verdadera.**
- Adecuada cuando se cree que la etiqueta misma está sesgada.
- Y problemática cuando las tasas base difieren de verdad: obliga a errar más en un grupo.

Igual sensibilidad

$$\Pr(\hat{y} = 1 \mid y = 1, A = a) = \Pr(\hat{y} = 1 \mid y = 1, A = b)$$

- Entre quienes **sí** son positivos, la misma probabilidad de ser detectados.
- Su versión fuerte —*probabilidades igualadas*— exige además igual tasa de falsos positivos.
- Es la definición natural cuando el error de omisión es el que duele.

Que la probabilidad signifique lo mismo

$$\Pr(y = 1 \mid \hat{p} = q, A = a) = q \qquad \text{para todo grupo } a$$

- Es la calibración de la semana 6, exigida **dentro de cada grupo**.
- Sin ella, un 0,8 significa cosas distintas según el grupo, y el umbral de costos deja de valer.
- Es la definición que la industria adopta con más naturalidad, porque es la que hace utilizable el número.

Las tres no son compatibles

> Si las tasas base difieren entre grupos y el modelo no es perfecto, es **imposible** satisfacer calibración por grupo y probabilidades igualadas a la vez. No es una dificultad práctica: es un teorema.

Con prevalencias de 0,30 y 0,10 y la misma relación entre atributos y etiqueta:

ESTRATEGIA DE UMBRAL	IGUALA	Δ DEL VPP
Umbral único	TVP y TFP	0,32
Paridad demográfica	tasa positiva	0,41
Igualdad de oportunidades	TVP	0,32

Un aviso positivo vale 66 % en un grupo y 34 % en el otro, con las tres estrategias. Kleinberg, Mullainathan y Raghavan (2016); Chouldechova (2017). El cuaderno lo verifica.

3

La imposibilidad

La aritmética, en una línea

Con prevalencias $\pi_a \neq \pi_b$, la calibración obliga a que el valor predictivo positivo sea igual. Y entonces:

$$\mathrm{TFP} = \frac{\pi}{1-\pi} \cdot \frac{1-\mathrm{VPP}}{\mathrm{VPP}} \cdot \mathrm{TVP}$$

- Con VPP fijo por la calibración y π distinto, no se pueden igualar TVP y TFP a la vez.
- Cuanto más difieren las prevalencias, mayor es la brecha forzada.
- Solo hay dos escapes: predicción perfecta, o prevalencias iguales.

La elección es normativa, no técnica

> No existe «el modelo justo». Existe una elección sobre qué error repartir de qué manera, y esa elección hay que declararla y defenderla.

Lo que sí es técnico

Medir las disparidades. Cuantificar el compromiso. Mostrar la frontera de opciones.

Lo que no lo es

Decidir cuál se prefiere. Eso corresponde a quien asume las consecuencias, con el contexto y la norma aplicable.

Cuatro exigencias

1. **Reporte el desempeño desagregado** por los grupos pertinentes, con sus tamaños. Es lo mínimo.
2. **Declare qué definición de equidad adopta y por qué**, antes de ver los resultados.
3. **Muestre el compromiso**: qué se pierde en las otras definiciones al satisfacer la elegida.
4. **Documente el origen del sesgo** si lo detecta: histórico, de medición, de representación. El remedio depende de cuál sea.

EN UNA LÍNEA

Lo que hay que llevarse

> Las definiciones de equidad son incompatibles entre sí **por un teorema**, no por falta de técnica. Su trabajo consiste en medir las disparidades, exhibir el compromiso y declarar la elección —no en afirmar que su modelo es justo.