Reporte, reproducibilidad y cierre

Clase 15, segunda parte · Comunicar un resultado que se sostenga

Unidad 7 · Investigación reproducible y comunicación de resultados

Un resultado que nadie puede verificar no es un resultado

Catorce semanas sobre cómo **obtener** un resultado que se sostenga. Falta cómo **comunicarlo** de modo que otro pueda comprobarlo.

> La unidad 7 no es un bloque terminal: se instaló en el taller 1 y se ejerció en los seis talleres. Hoy solo cerramos.

1

Qué es reproducible

TRES NIVELES

Y se confunden todo el tiempo

NIVEL	QUÉ SIGNIFICA	QUIÉN LO CONSIGUE
Reproducible	Mismos datos, mismo código, mismo resultado	Debería ser siempre
Replicable	Datos nuevos, mismo método, misma conclusión	Lo que la ciencia pide
Generalizable	Otra población, misma conclusión	Lo que casi nadie comprueba

> El primero es un requisito técnico. El segundo es el estándar científico. El tercero es lo que su lector va a **suponer** si usted no lo acota.

La lista de cotejo del módulo, otra vez

Los ocho ítems con que se corrigieron los seis talleres **son** la lista de verificación de reproducibilidad:

1. El cuaderno se ejecuta completo, de cero, en entorno limpio.
2. Semillas, versiones y entorno declarados.
3. Protocolo de partición explicitado, sin fuga.
4. Toda transformación se estima solo con entrenamiento.
5. Resultados con su variabilidad, no solo la media.
6. Métrica justificada por el problema.
7. Una decisión alternativa descartada, con su razón.
8. Las afirmaciones se sostienen en la salida y no la exceden.

El que más se incumple

> «Las afirmaciones se sostienen en la salida y no la exceden.»

- «Nuestro método es superior» cuando se probó en tres conjuntos → **excede**.
- «El atributo X es el más importante» con explicaciones inestables → **excede**.
- «El modelo detecta fallas» cuando detecta el 5 % de ellas → **excede**.

> Escribir conclusiones proporcionales a la evidencia es una habilidad, y es la que distingue una tesis defendible.

Además del artículo

- **Código**, con el entorno fijado y las semillas.
- **Datos**, o su procedencia y las condiciones de acceso si no se pueden publicar.
- **El protocolo completo**, incluidas las decisiones que no funcionaron.
- **El número de experimentos realizados**, no solo los reportados.

2

Cómo se reporta

Y dónde va cada semana del módulo

SECCIÓN	QUÉ CONTIENE	SEMANA
Problema	La tarea de aprendizaje, qué es un caso, qué se predice	1
Datos	Origen, población, representación, faltantes	1, 9
Método	Familia, sesgo inductivo declarado, regularización	2, 4, 5
Protocolo	Partición justificada, sin fuga, con presupuesto	7, 8, 12
Resultados	Métrica justificada, con variabilidad y desagregada	3, 6, 15
Limitaciones	Alcance, horizonte de validez, qué lo invalidaría	2, 14

El informe final se corrige contra esta tabla: no hay ninguna sección del informe que no corresponda a alguna semana del módulo.

Limitaciones

> Es la sección que un revisor experto lee **primero**, y la que casi todos escriben al final y con desgana.

- Debe decir **bajo qué condiciones su conclusión dejaría de valer**.
- Es exactamente la tesis del módulo: «un método se justifica porque sabemos bajo qué condiciones deja de funcionar».
- Una sección de limitaciones genérica —«se necesitan más datos»— no es una limitación: es un relleno.

Cinco reglas

1. **Con variabilidad**, y diciendo sobre qué se calculó. «0,91 ± 0,03 sobre 10 repeticiones de validación cruzada, semillas 1–10.»
2. **Con el tamaño del efecto** en las unidades del problema, no solo el valor p.
3. **Desagregados** por los grupos pertinentes, con sus tamaños.
4. **Con la línea base**, ajustada con el mismo cuidado.
5. **Con el presupuesto de cómputo** por método.

> Las cinco son de semanas distintas del módulo. Ninguna es opcional.

Qué comunica cada una

FIGURA	QUÉ MUESTRA	SEMANA
Diagrama de fiabilidad	Si las probabilidades significan algo	6
Diagrama de diferencia crítica	Qué métodos se distinguen	8
Frontera de Pareto	El compromiso entre desempeño y costo	12
Desempeño desagregado	Las disparidades entre grupos	15

> Cuatro figuras. Comunican más que cuatro páginas de tabla, y son difíciles de manipular.

3

Cierre del módulo

Quince semanas, una sola idea

- **Unidad 1** — aprender es estimar $R_{\mathcal{D}}$ sin poder calcularlo, y hace falta un supuesto para que sea posible.
- **Unidad 2** — cada familia de modelos es un supuesto distinto sobre la forma del problema.
- **Unidad 3** — estimar bien exige un protocolo que no se engañe, y una comparación que admita prueba.
- **Unidades 4 y 5** — la representación y la arquitectura también son supuestos.
- **Unidad 6** — toda garantía vale mientras valga su supuesto.

> Y la unidad 7, que fue transversal: si nadie puede verificarlo, no es un resultado.

La misma del primer día

> Un método de aprendizaje automático no se justifica porque funcione. Se justifica porque sabemos **bajo qué condiciones deja de funcionar**.

Quince semanas después, esa frase tiene una lista de condiciones concretas: i.i.d., sesgo inductivo adecuado, protocolo sin fuga, métrica pertinente, comparación con presupuesto igual, intercambiabilidad, distribución estable.

Qué se califica en la defensa

> La capacidad de sostener las decisiones metodológicas bajo interrogación. No la presentación, no los resultados.

- Se pregunta por qué eligió cada cosa, y qué habría pasado si hubiera elegido otra.
- «No lo sé» es una respuesta aceptable; «no lo pensé» es la que cuesta.
- Preguntan el profesor y los pares.

EN UNA LÍNEA

Lo que hay que llevarse del módulo

> Todo resultado empírico descansa en supuestos. El trabajo del investigador no es eliminarlos —es imposible— sino declararlos, someterlos a prueba y decir qué pasaría si fueran falsos.

Se entrega el informe final. En la semana de exámenes, la defensa oral ante el curso.